Machine Translated by Google

可在www.sciencedirect.com在线获取。

可在www.sciencedirect.com网站在线获取。

科学直接

Procedia Computer Science 00 (2025) 000–000
Procedia Computer Science 270 (2025) 3582–3591

Procedia Computer Science

www.elsevier.com/locate/procedia
www.elsevier.com/locate/procedia

第29届基于知识和智能的信息与工程国际会议
系统（KES 2025）
系统（KES 2025）

多模态金融情绪模型在股票收益预测中的应用
多模态金融情绪模型在股票收益预测中的应用

Petr Hajeka, , Josef Novotnya , 米哈尔·蒙卡,b,达萨·蒙科瓦布
Petr Hajeka, , Josef Novotnya , 米哈尔·蒙卡,b,达萨·蒙科瓦布

aFaculty of Economics and Administration, University of Pardubice, Studentska 95, Pardubice, 53210, Czech Republic
aFaculty of Economics and Administration, University of Pardubice, Studentska 95, Pardubice, 53210, Czech Republic
bDepartment of Computer Science, Constantine the Philosopher University in Nitra, Tr. A. Hlinku 1, 949 74, Nitra, 斯洛伐克b 尼特拉
康斯坦丁哲学家大学计算机科学系,Tr. A. Hlinku 1, 949 74, Nitra,斯洛伐克A. Hlinku 1, 949 74, 尼特拉, 斯洛伐克

摘要:本文提
出了一种新颖

的多模态深度学习框架,用于股票收益预测,该框架整合了异构数据源:技术指标、市场投资者情绪指数以及从财报电话会议记录中提取的文本情感。所提出的模型采用了一种混合架构,结合了用于技术模态的Transformer编码器和用于市场及文本模态的神经网络。在后期融合设置中,使用模态级注意力机制来动态调整市场和文本模态的权重。我们在包含来自497个交易所的24,821个样本的大规模数据集上评估了我们的模型。我们使用包含 2010 年至 2022 年间 497 家标普 500 指数公司 24,821 个样本的大规模数据集来评估我们的模型。结果表明,我们的模型优于传统模型（LSTM、BiLSTM、CNN-LSTM）和其他融合策略,在测试集上实现了 59.94% 的方向准确率。注意力权重分析证实,所有三种模态均对预测性能有显著贡献。这些结果表明,所提出的框架在多模态环境下能够有效地预测异常股票收益。所提出的框架在多峰环境下准确预测异常股票收益的有效性。

© 2025 作者所有。由 Elsevier BV 出版。© 2025
作者所有。由 Elsevier BV 出版。© 2025
这是一篇根据 CC BY-NC-ND 许可协议（http://creativecommons.org/licenses/by-nc-nd/4.0/）发布的开放获取文章。
这是一篇根据 CC BY-NC-ND 许可协议（http://creativecommons.org/licenses/by-nc-nd/4.0/）发布的开放获取文章。
由 KES International 科学委员会负责同行评审。
由 KES International 科学委员会负责同行评审。

关键词:多模态融合;金融情绪;股票市场;预测;盈利电话会议。
关键词:多模态融合;金融情绪;股票市场;预测;财报电话会议。

1. 引言 1. 引言

股票市场是一个复杂的动态系统,受多种因素影响,包括宏观经济指标、公司业绩、政治事件,以及最重要的投资者情绪[1]。投资者情绪,广义上定义为市场参与者对金融资产的集体情绪和态度,在塑造市场趋势和价格走势方面发挥着核心作用[2]。行为金融学认为,市场参与者并非总是理性行事;相反,心理偏差和情绪会导致资产定价错误、泡沫和崩盘[1]。

因此,了解和量化投资者情绪对于改进股票市场预测模型和投资策略至关重要。

人工智能（AI）和自然语言处理（NLP）的最新进展使得情感分析成为可能。
人工智能 (AI) 和自然语言处理 (NLP) 的最新进展使得情感分析能够从新闻文章、社交媒体平台等各种数据源中提取和解读投资者情绪。

* 通讯作者。电话:+0-000-000-0000;传真:+0-000-000-0000。
* 通讯作者。电话:+0-000-000-0000;传真:+0-000-000-0000。
电子邮箱地址:author@institute.xxx 电子邮箱地址:
author@institute.xxx

1877-0509 © 2025 作者所有。由 Elsevier BV 出版。
本文为开放获取文章,遵循 CC BY-NC-ND 许可协议(http://creativecommons.org/licenses/by-nc-nd/4.0/) 1877-0509 © 2025 作者
所有。由 Elsevier BV 出版。
这是一篇根据 CC BY-NC-ND 许可协议（http://creativecommons.org/licenses/by-nc-nd/4.0/）发布的开放获取文章。
这是一篇根据 CC BY-NC-ND 许可协议（https://creativecommons.org/licenses/by-nc-nd/4.0/）发布的开放获取文章。
由 KES International 科学委员会负责同行评审。
同行评审由KES国际科学委员会负责。
10.1016 /j.procs.2025.09.177

Machine Translated by Google

分析师报告和财务报表[3]。传统的金融理论,例如法玛的有效市场假说,认为所有可获得的信息都已反映在股票价格中[4]。然而,越来越多的实证研究挑战了这一观点,表明情绪驱动的波动会造成短期市场低效,而这种低效可能被利用[5]。此外,情绪分析使研究人员和交易员能够实时量化投资者情绪,从而提供超越基本面和技术分析的市场动态洞察。研究表明,积极的情绪与看涨的市场行为相关,而消极的情绪往往先于市场下跌。这与前景理论[6]等理论相一致,该理论认为投资者对收益和损失的反应是不对称的,并进一步强化了情绪作为股票市场建模中预测变量的重要性。

过去十年,金融情绪分析取得了长足发展,越来越依赖机器学习和深度学习模型来解读和预测市场趋势[3]。早期的情绪分析主要依赖于基于词典的方法,将词语映射到预定义的情感得分。然而,诸如Transformer和循环神经网络等深度学习模型的出现,使得从文本数据中更精细地解读情绪成为可能,从而提高了股票市场预测的准确性[7]。金融情绪分析已成功应用于短期股价走势预测[8]、波动率预测[9]以及事件驱动的市场反应预测[10],展现了其在投资决策中的实用价值。

近年来,随着研究人员认识到仅基于文本的情感分析的局限性,多模态金融情感分析日益受到重视[11, 12]。金融情感通过多种渠道表达,包括文本报告、社交媒体讨论、图像、视频,甚至财报电话会议的语气[3]。

通过整合多模态数据源,例如将文本情感与财务图表线索或CEO演讲中的音频情感相结合,研究人员可以更全面地了解市场情绪。不同模态的融合提高了预测准确性,并能更深入地洞察投资者行为,使多模态情感分析成为股票市场预测领域的一项关键进步。

尽管基于情绪的股票市场预测取得了进展,但现有模型仍存在一些局限性。
许多研究仅依赖于从财经新闻或社交媒体中提取的文本情感[13, 14, 15],而忽略了其他重要的情感信号,例如基于市场的投资者情绪指数和技术指标。此外,传统的情感模型往往无法解释不同数据源之间的相互依赖性[13, 16],导致市场表征不完整,预测结果也并非最优。为了应对这些挑战,我们提出了一种新型的多模态深度学习模型,该模型融合了基于FinBERT的文本情感模态、基于市场的投资者情绪模态以及技术分析模态。通过利用这种数据源的全面融合,我们的模型旨在提供一个更稳健、更准确的股票市场预测框架,有效捕捉股票市场的动态变化。更具体地说,我们提出了一种新型的多模态深度学习模型,该模型整合了多种金融情感来源,用于股票收益预测。我们的主要贡献如下:

- 我们开发了一个框架,将基于 FinBERT 的文本情感分析与市场投资者情绪指数（VIX、Twitter 幸福指数、每日新闻情绪指数)和技术分析指标相结合。
  这种方法能够更全面地展现投资者情绪及其对股票价格的影响。
  转弯。
- 我们引入了一种新颖的跨公司注意力机制,该机制通过捕获内部信息来提高预测准确性。
  不同股票间情绪因素的相互作用。
- 我们的模型利用多头注意力机制整合多模态数据,确保能够同时反映投资者情绪的短期波动和长期趋势。这项技术解决了以往研究中数据对齐和特征融合方面的局限性。
- 我们使用涵盖 2010 年至 2022 年标普 500 指数中 497 家公司的大规模数据集验证了我们的方法。实证结果表明,我们的模型取得了具有竞争力的预测性能。

本文余下部分结构如下:第二节回顾了多模态股票市场预测的相关文献;第三节介绍了研究方法,详细阐述了模型架构和多模态融合策略;第四节描述了数据来源和特征工程;第五节介绍了实验设置,报告了实验结果,并将所提出的模型与基准模型进行了性能比较;最后,第六节总结了本文的主要发现、局限性以及未来研究方向。

Machine Translated by Google

2. 相关文献

投资者情绪分析已经发展出多种方法,从传统的调查和专家意见到自动化计算技术[3]。早期的方法主要依赖于从调查中得出的投资者情绪指数,例如美国个人投资者协会（AAII)情绪指数[17]。

随着网络讨论和财经新闻的兴起,情感分析越来越多地融合了自然语言处理（NLP)和机器学习技术,以从文本数据源中提取情感信息。情感词典、监督学习模型以及基于Transformer的深度学习模型（例如BERT和FinBERT)已被广泛用于评估投资者情绪,并显著提高了评估的准确性[18, 19, 20]。此外,还开发了专门针对金融领域的情感模型,例如FinBERT或FinLlama,以更好地捕捉金融语言的细微差别[21]。诸如情感感知词嵌入和上下文相关的Transformer等技术进一步提升了金融情感分类的准确性[3]。

以往研究表明,社交媒体情绪、财经新闻情绪和投资者讨论情绪能够预测短期股价走势[23]和市场波动[9]。然而,现有模型在处理实时情绪波动以及解释情绪与市场结果之间的因果关系方面常常面临挑战[24]。为了提高预测能力,有研究提出将金融情绪与宏观经济指标、基本面财务分析和替代数据源相结合[15, 25]。

多模态方法通过整合包括文本、数值指标、图像和音频在内的多种数据源（见表1）,已成为提升股票市场预测能力的一个很有前景的方向。诸如基于注意力机制的Transformer模型、卷积神经网络（CNN)和长短期记忆网络（LSTM)等深度学习架构已被用于有效处理多模态输入。总体而言,多模态学习能够捕捉不同金融信号之间的相互作用,从而减少单模态模型的局限性,实现更稳健的预测。

近年来,多模态股票市场预测的研究越来越注重融合不同的数据源,例如新闻文章、社交媒体情绪、财报电话会议记录和市场技术指标,以提高预测精度。例如,Wu等人[16]使用CNN-LSTM模型将历史股价与期权和期货等领先市场指标相结合,从而捕捉金融时间序列中复杂的依赖关系。类似地,Chen等人[22]提出了一种CNN-BiLSTM-ECA模型,利用高效通道注意力（ECA)来增强金融时间序列数据的特征选择。其他研究,例如[27],引入了一种基于CNN-LSTM的双通道注意力融合机制,用于提取和融合新闻情绪与股价。这些研究表明,融合多种模态可以提高预测性能,但每种方法在有效的数据融合和模型可解释性方面都面临着挑战。例如,虽然基于CNN的特征提取可以提高预测精度[27, 16],但它可能难以处理长程依赖关系。

近期研究,例如[14, 19] ,强调了财报电话会议数据的整合以及纳入其他指标（例如新冠疫情相关指标)以更好地捕捉市场动态的重要性。Sawhney等人[23]提出了一种深度注意力学习模型,将社交媒体文本与公司关联信息融合。Li和Xu [20]进一步推进了研究,将生成对抗网络（GAN)与基于Transformer的注意力机制相结合,通过选择性地关注关键市场特征来提高股价预测的准确性。然而,尽管取得了这些进展,许多模型仍然面临着模型复杂度高、异步模态整合困难等局限性[28]。此外,依赖特定的情感词典或狭窄的数据源也会限制这些方法的泛化能力[29]。

3. 研究方法

本文提出的多模态深度学习模型旨在通过整合多源投资者情绪和财务数据来提高股票收益预测的准确性。该模型由四个关键组件构成：(1)用于处理技术指标的Transformer编码器模块；(2)用于市场和文本情绪处理的密集层；(3)用于高效多模态融合的多头注意力机制;以及（4)利用股票代码嵌入进行跨公司数据整合。所提出模型的框架如图1所示。

这些组成部分的选择基于捕捉金融市场短期波动和长期依赖关系的需求。情绪驱动模型在捕捉投资者反应方面展现出良好的前景,而

Machine Translated by Google

表 1. 股票市场预测中的多模态方法。

参考资料	模式	模型
[9]	口头和声音提示	多模态深度回归（双向长短期记忆网络）
[30]	股票价格、新闻情绪[14]	多核学习 + 深度神经网络
	财报电话会议文字和音频[23]	HTML
	社交媒体文本，公司相关性[26]	深度专注学习
	股票价格、新闻情绪[27]	深度强化学习
	新闻情绪，股票价格[16]	基于 CNN-LSTM 的双通道注意力机制
	历史股票价格、领先指标（期权、期货） [15]	CNN-LSTM（SACLSTM）
	基本面指标、新闻情绪[8]	LSTM + Transformer
	新闻文章、股票价格、情绪指数	Trellis网络+情感关注
	财经新闻情绪，历史价格[13]	FinBERT + LSTM
	市场情绪、股票价格、新冠疫情指标[1] [20]	LSTM + Transformer
	股票价格、新闻情绪、社交媒体新闻	生成对抗网络 (GAN) + 基于 Transformer 的注意力机制
	本研究分析了技术指标、市场情绪和文本情绪。	跨公司关注机制

注释：HTML - 基于分层 Transformer 的多任务学习，SACLSTM - 股票序列数组卷积 LSTM。

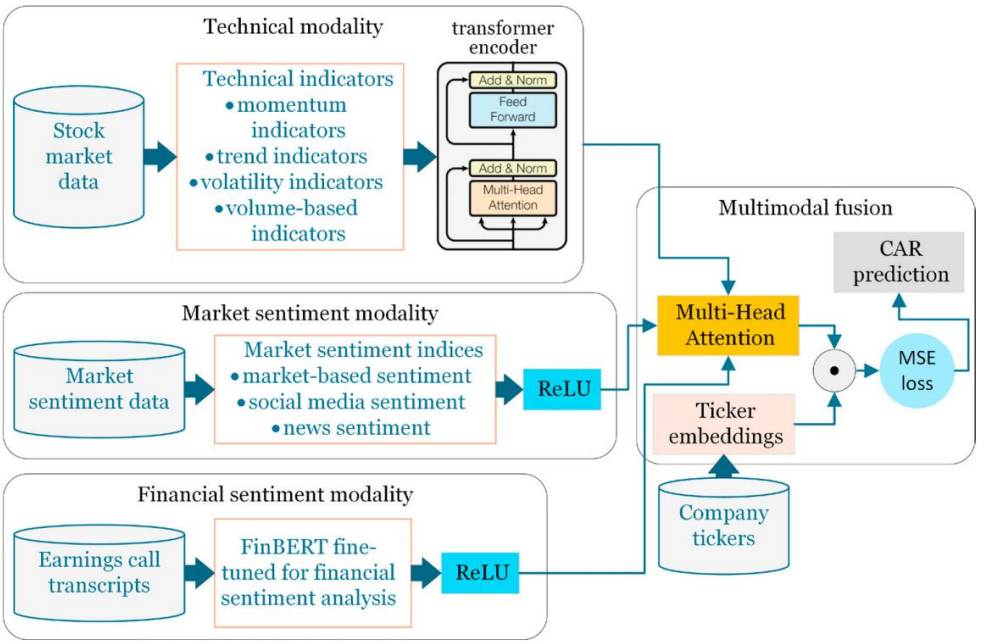


图 1. 所提出的多模态股票收益预测模型的框架。

市场数据和技术指标提供了重要的量化金融特征。通过结合这些方式
对于累计异常收益率（CAR）预测，我们的模型旨在提高预测准确性并提供一个
为投资者提供有效的决策支持工具。

3.1. 用于技术特性的变压器编码器

技术指标被广泛用于评估股票价格趋势、动量和波动性。传统模型
虽然依赖于循环神经网络，但Transformer模型在捕捉长程依赖关系方面展现出了更优越的能力。
在时间序列数据中[31]。在所提出的模型中，Transformer编码器按如下方式处理技术指标：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (1)$$

Machine Translated by Google

V 分别表示查询矩阵、键矩阵和值矩阵， dk是键向量的维度。
自注意力机制使模型能够自适应地权衡过去技术指标值的重要性。
然后对输出结果进行归一化处理：

$$H = \text{LayerNorm}(H + \text{Dropout}(\text{Attention}(Q, K, V))), \quad (2)$$

其中 H 是变压器层的输入。

3.2 市场和文本情感处理

投资者情绪（通过市场指标和文本情绪反映出来)会影响股票价格[1]。
市场情绪通过VIX指数、THI（推特幸福指数)和SSW（Shapiro、Sudhof和Wilson新闻指数)来衡量。
情感指数） [32],而财报电话会议的文本情感则使用金融领域专用Transformer模型FinBERT [33]提取。这些特征通过密集层进行处理：

$$\text{Mdense} = \text{ReLU}(\text{WmM} + \text{bm})。 \quad (3)$$

类似地,使用 FinBERT 提取的文本情感通过以下方式转换：

$$\text{Tdense} = \text{ReLU}(\text{WtT} + \text{bt}), \quad (4)$$

其中 M 和 T 分别是市场和文本情感的输入特征向量。密集层能够
非线性变换增强了从情感特征中提取预测模式的能力。

3.3. 基于注意力机制的多模态融合

为了有效地结合技术、市场和文本特征,我们采用了一种多头注意力机制。该机制并非简单地连接各个特征,而是动态地为不同的模态分配重要性权重：

$$\text{Ffusion} = \text{MultiHeadAttention}(Q = \text{Ttech}, K = [\text{Mdense}, \text{Tdense}], V = [\text{Mdense}, \text{Tdense}])。 \quad (5)$$

这种融合技术使模型能够学习哪种模态对于任何情况下的股票收益预测都更为相关。
给予足够的时间,确保模型不会过度依赖单一数据源。

3.4. 跨公司集成及股票代码嵌入

股票收益受公司特定因素的影响,例如财务状况、行业表现和竞争地位。为了将这些影响纳入考量,我们引入了股票代码嵌入： Eticker = Embedding(股票代码 ID)。
嵌入是学习到的表示,用于捕捉公司特有的特征。最终融合的表示
是通过股票代码嵌入与多模态特征的逐元素相乘得到的：

$$\text{Ocross} = \text{Ffusion} \odot \sigma(\text{WeEticker}), \quad (6)$$

其中 σ 为 sigmoid 激活函数。这种机制增强了模型在不同场景下的泛化能力。
股票并提高预测准确率。

3.5 最终预测层

最终预测层对融合的多模态特征 Y = Wf Ocross + bf进行回归,其中 Y
代表预测的CAR值。在最后阶段使用全连接层使得模型能够学习复杂的非线性函数。
输入特征与股票收益之间的关系。

Machine Translated by Google

3.6 训练和优化

该模型采用均方误差（MSE)损失进行训练：

$$L = \frac{1}{N}\sum_{i=1}^{N}(Yi - Y\ \ i)^2, \tag{7}$$

其中Yi为实际 CAR 值,Y i为预测 CAR 值。采用 Adam 优化器来提高训练效率。
通过提前停止和学习率调度来防止过拟合。

4. 数据

本研究使用的数据集包含来自标普500指数中497家上市公司的24,821个实例。
2010年至2022年间的500指数。数据来源于多个渠道,包括金融数据库和
利用财报电话会议资料库,创建一个用于股票收益预测的多模态数据集。该数据集整合了公司财报电话会议资料。
股票价格、技术指标、市场投资者情绪以及财报电话会议记录中的文本情绪分析。我们使用 yfinance Python 库收集了 497 家公司中每家公司的每日股票价格数据。
提供来自雅虎财经的历史数据。为了计算累计异常收益率（CAR），我们遵循了以下方法：
采用标准事件研究方法,以标普500指数为市场基准。累计异常收益率（CAR)的计算周期为……
以每家公司收益电话会议日期为中心,为期三天的事件窗口,即 $CARi = Ri,t - Rm,t$，
其中,Ri,t表示股票 i 在第 t 天的日收益率， Rm,t表示同一天标普 500 指数的收益率。
财报电话会议日期来自 Seeking Alpha 网站。

数据集中纳入了三个每日市场投资者情绪指标：

- VIX（波动率指数)[1]： VIX 指数由芝加哥期权交易所 (CBOE) 提供,用于衡量……
  市场对近期波动性的预期,可作为市场投资者情绪的指标。
- THI（Twitter幸福指数)2： THi通过分析整体情况来衡量社交媒体投资者情绪。
  Twitter上财经讨论的氛围。
- SSW 新闻情绪指数3:该指数捕捉财经新闻文章中的情绪变化,提供额外的信息。
  股市走势的指示信号。

技术指标源自每日股价数据,用于捕捉市场趋势、动量和波动性。
以及交易量模式。每个技术指标均采用滚动窗口法计算,以确保其在股票收益预测中的实时适用性。动量技术指标的目的是考虑

超买/超卖信号（RSI）、趋势反转（MACD)和价格变动速度（ROC）。同样,趋势
我们使用指标来纳入短期和长期趋势（50日均线和200日均线)以及趋势强度。
（ADX），而波动率则指示价格极端值和均值回归（BB）、事件驱动型波动率（ATR)以及过去
波动性对累计异常收益率（滚动波动率)的影响。最后,基于成交量的指标衡量累积/派发情况。
趋势指标（OBV)和机构买盘兴趣指标（VWAP）。所用技术指标的详细信息见表2。

我们多模态模型中的文本数据部分来源于财报电话会议记录。我们从Seeking Alpha网站收集了这些记录,方法是找到与每家公司财报电话会议对应的URL。这些记录是
然后进行处理以提取文本情感特征。为了衡量财报电话会议的情感倾向,我们采用了 Fin-BERT,这是一个专门针对金融情感分析训练的领域特定 NLP 模型⁴。每个转录文本都被分词。
句子经过 FinBERT 处理,计算句子级情感得分。情感极性得分
计算公式为 $S情感\ j=1\ Ppositive,\ j = \frac{1}{N}\sum^{N} Pnegative,\ j$,其中Ppositive, j和Pnegative, j是由 FinBERT 推导出的
其中,N 是句子 j 的正面和负面情感概率,N 是文本中的句子数量。

[1] https://www.cboe.com/tradableproducts/vix/vix historical data/
[2] hedonometer.org
[3] https://www.frbsf.org/research-and-insights/data-and-indicators/daily-news-sentiment-index/
[4] https://huggingface.co/ProsusAI/finbert

Machine Translated by Google

表2. 财务指标、其类别和公式

类别指标		方程
动量	RSI（相对强弱指数）	$RSI = 100 - \frac{100}{1+RS}$
	MACD（移动平均收敛/发散指标）	$MACD = EMA12 - EMA26$
	ROC（变化率）	$ROC = \frac{Price - Price_{-n}}{Price_{-n}} \times 100\%$
趋势	50日均线和200日均线	$EMA_t = \alpha \cdot Price_t + (1-\alpha) \cdot EMA_{t-1}, \alpha = \frac{2}{N+1}$
	ADX（平均方向指数）	$ADX = EMA\left\|\frac{DI+ - DI-}{DI+ + DI-}\right\|$
波动率	BB（布林带）	$上限 = MA + k\sigma, 下限 = MA - k\sigma$
	ATR（平均真实波幅）	$ATR = EMA(TR)$
	滚动波动率（σ）	$\sigma = \frac{1}{N-1} \sum_{i=1}^{N} (r_i - r)^2$
体积	OBV（平衡成交量）	$OBV_t = OBV_{t-1} \pm Volume_t$
	VWAP（成交量加权平均价格）	$VWAP = \frac{\sum_t 价格 \times 销量}{\sum_t 体积}$

在收集了股票价格数据、技术指标、市场情绪指数和财报电话会议记录后，我们
将所有特征合并到一个数据集中。数据集中的每个实例都对应于一次财报电话会议，并且
包括：(1)财报电话会议日期；(2)相应公司的股票代码；(3)一套技术分析数据。
（4)源自股票价格走势的指标，(5)市场情绪指标（VIX、THI、SSW），以及（6)FinBERT
根据财报电话会议记录得出的情绪评分。

5. 实验

为了评估所提出的多模态模型在股票收益预测方面的性能，我们采用了滑动误差法。
采用窗口法进行测试（滑动窗口大小为 15），确保每次预测都利用了过去的市场状况，同时保持时间上的完整性。数据集包含来自 497 家标普 500 指数公司的 24,821 个实例。
2010 年至 2022 年间，数据集被分为训练集 (70%) 和测试集 (30%)。训练阶段包括通过网格搜索优化超参数，评估不同的层配置、单元和 dropout 设置。
为了增强模型的泛化能力，我们采用了学习率。该模型使用 Adam 优化器进行训练，初始学习率为
为 5 × 10−4，根据验证性能随 epoch 数递减。

我们测试了多种配置，改变了变压器编码器层数，以实现技术特性和密度方面的优化。
用于市场和文本情感分支的单元，以及用于模态融合的注意力头。最终优化设置
选择超参数时，以最小化验证损失和最大化预测准确率为原则。最终确定的超参数如下：
具体如下：技术特点（2层变压器编码器，每层64个单元和8个注意力头），市场
情感层（2 个全连接层，分别有 32 个和 16 个单元，使用 ReLU 激活函数），文本情感层（2 个全连接层）
（32 和 16 个单元，使用 ReLU 激活函数），以及多模态融合（具有 8 个头的多头注意力机制，
然后是一个64单元的密集层）。此外，使用Adam优化器， $\beta_1 = 0.9$， $\beta_2 = 0.999$。
在所有主要分支中应用了学习率衰减和dropout（0.2)正则化以防止过拟合。为了评估
为了评估模型的性能，我们参照之前的研究[11]计算了均方根误差（RMSE)和均方根误差。
绝对误差（MAE)和方向精度（DA（%））。

深度学习实验采用 Keras 库和 TensorFlow 后端进行。模型是
在 NVIDIA Jetson AGX Xavier 平台上进行训练和测试，该平台配备 512 核 Volta GPU 和 32GB 内存。
这种设置能够高效地执行基于 Transformer 的架构和多模态融合机制。

首先，为了评估不同融合机制的影响，我们设计了所提出的多模态融合方法的三种变体。
该模型采用早期融合、晚期融合和分层融合三种方法。每种方法都旨在整合技术指标。
市场情绪和文本情绪可以通过以下方式进行分析。早期融合策略将所有模态连接起来。
输入层，将合并后的向量送入统一的神经网络进行处理。虽然简单，但早期融合假设
各模态间贡献相等且规模兼容。在后期融合设置中，每种模态均会被处理。
这些输出通过各自的子网络独立处理。之后，使用注意力机制将它们的输出融合起来。
这使得模型能够在整合之前学习特定模态的表征。最后，分层两级
该方法首先利用注意力机制将相似的模态（市场和文本情感)结合起来，然后与……融合。
它实现了更高层次的技术信号和股票代码嵌入，从而引入了一种结构化的模式整合路径。

Machine Translated by Google

我们使用三个指标（RMSE、MAE 和 DA)在测试集上评估了每种融合策略的性能。
（%），结果汇总于表3 中。

表 3. 不同融合策略的性能比较。

融合策略	RMSE	MAE	DA (%)
晚期融合 层级	4.610	3.256	59.94
融合	4.633	3.283	57.64
早期融合	4.624	3.291	56.20

如表3所示，后期融合模型取得了最佳的整体性能，尤其是在方向准确率方面（59.94%），这表明允许每种模态在融合前独立学习其表征是有效的。
集成有助于保留它们的独特特性。虽然分层融合模型引入了更结构化的集成，但其增加的复杂性可能不会转化为性能提升。早期的融合模型表现

方向准确率最低（56.20%），这进一步凸显了朴素模态拼接在金融领域的局限性。
多模态学习。

为了进一步评估所提出的多模态融合模型的有效性，我们将其性能与……进行了比较。
现有研究中使用的几种深度学习基线模型，包括 LSTM、BiLSTM 和 CNN-LSTM。每个基线模型
模型通过其各自的架构处理拼接后的多模态输入。LSTM 是一种基本的单向网络结构。
将长短期记忆网络应用于拼接后的输入向量。BiLSTM 表示双向版本。
LSTM 能够同时捕捉前向和后向的时间依赖性。CNN-LSTM 结合了卷积神经网络和 LSTM。
使用 LSTM 进行局部特征提取的层，用于序列建模。

如表4所示，所提出的模型实现了最佳的方向精度，表明其具有优异的预测能力。
能够正确捕捉异常股票收益的方向。虽然 CNN-LSTM 在某些方面略优于我们的模型。
RMSE 值较高，我们模型的方向准确率也较高，这表明其基于注意力机制的后期融合架构和
股票行情感知集成能够显著提升趋势预测能力 这在金融领域尤为重要。
预测应用。

表 4. 与现有多模态深度学习模型的比较。

模型	RMSE	MAE	DA (%)
LSTM	4.661	3.300	53.03
BiLSTM	4.639	3.306	52.16
CNN-LSTM	4.609	3.276	55.91
我们的模型	4.610	3.256	59.94

为了深入了解每种模态在预测 CAR 中的相对贡献，我们分析了后期融合模型在整个测试集上学习到的平均注意力权重。如图2 所示，市场情绪

该模式获得了最高的平均关注权重，表明汇总的投资者情绪指数具有……
在财报电话会议前后的短时间内，对CAR预测影响最大的信号是所有三种模态。这三种模态相对较强的贡献凸显了我们基于注意力机制的后期融合机制在自适应预测中的有效性。
根据每种模态在预测中的相关性对其进行加权。

我们进一步评估了一种基于预测的交易策略，该策略通过应用一个简单的模型生成每日买入/持有信号。
规则：当预测的累计异常收益率（CAR)为正时买入，否则卖出。我们使用多种交易绩效指标，将我们的策略与被动买入并持有策略进行了基准比较。表5 的结果表明，模型驱动策略
该策略平均每信号收益率为 1.9357%，而买入并持有策略的平均收益率为 0.2959%。此外，该策略还实现了……
夏普比率为 0.4002，表明该预测模型能够在保持更高收益率的同时提取超额收益。
风险收益特征良好。请注意，由于输入特征按日频率排列，因此该模型可以……
每天至少使用一次。

6. 结论

本研究提出了一种新颖的多模态深度学习框架，用于股票收益预测，该框架整合了技术分析。
指标、市场投资者情绪以及从财报电话会议记录中提取的文本情绪。

Machine Translated by Google

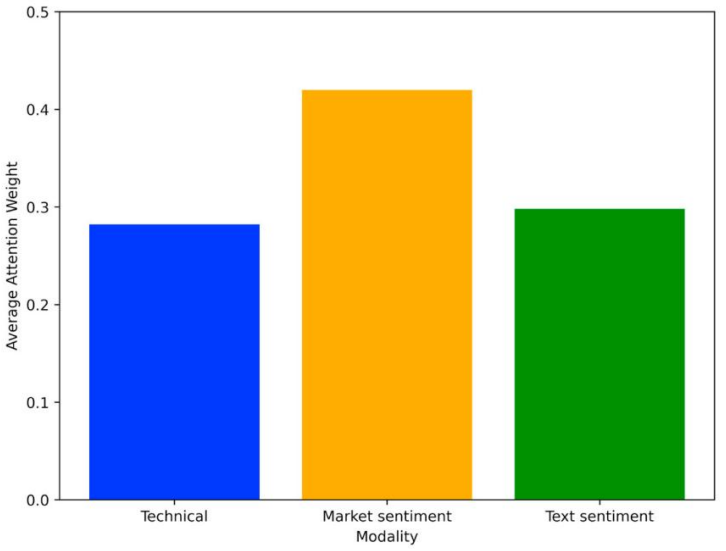


图 2. 测试数据的平均模态注意力权重。

表 5. 2023-2024 年交易业绩比较：基于预测的策略与买入并持有策略。

指标	基于预测的买入并持有策略
平均产量（%）	1.9357 0.2959
夏普比率	0.4002 0.0569

将用于技术信号的Transformer编码器与用于市场和文本情感分析的神经网络模型相结合，
通过应用基于注意力机制的后期融合机制，该模型有效地捕捉了来自异构体的各种模式。
数据模态。对来自 497 家标普 500 指数公司的 24,821 个实例的大型数据集进行了大量实验。
2010-2022 年期间的结果表明，我们的模型优于几种最先进的多模态融合策略。
分析还揭示了这三种模式都做出了相对较强的贡献，其中市场情绪发挥了重要作用。
在预测短期股票收益方面发挥着更为突出的作用。

尽管这些结果令人鼓舞，但这项研究仍存在一些局限性，这些局限性也为未来的研究指明了方向。首先，
该模型主要关注结构化的情绪和价格数据，而忽略了其他潜在的有用信息。
例如音频提示音或视觉图表等方式。其次，虽然注意力机制提供了一定的可解释性，但诸如层级式或可解释的注意力级别等进一步增强功能可以提高透明度。最后，
将分析范围扩展到国际市场、高频日内数据或特定行业模型，可能会进一步……
验证并推广所提出方法的有效性。未来的研究还可以探索强化学习。
基于多模态预测信号的学习型交易策略。

致谢

本研究由捷克科学基金会（项目编号 25-15405S）和科学基金资助。
斯洛伐克共和国教育部和斯洛伐克科学院机构[资助编号]
VEGA-1/0734/24]。

参考

[1] Baker, M. 和 Wurgler, J. (2007)。“股票市场的投资者情绪。”《经济展望杂志》 21 (2): 129–151。

Machine Translated by Google

[2] Hajek, P. 和 Novotny, J. (2024)。“超越股票价格预测中的情绪：将新闻情绪和投资者注意力与时间融合转换器相结合。”载于 IFIP 国际人工智能应用与创新会议。Cham：Springer，第 30–43 页。
[3] Du, K., Xing, F., Mao, R., and Cambria, E. (2024). “金融情绪分析：技术与应用。” ACM Computing Surveys 56（9）：1-42。
[4] Aggarwal, D. (2022). “定义和衡量市场情绪：文献综述。”《金融市场定性研究》 14（2）：270–288。
[5] Hsu, YT, Hua, M., Liu, H., and Wang, Q. (2024). “新闻情绪与投资效率：来自中国的证据。” 欧洲金融管理30 (3): 1587–1617。

[6] Reichenbach, F. 和 Walther, M. (2024)。“投资者在社交媒体上的注意力分配：前景理论的作用。”《行为经济学杂志》财务：1–18，doi：10.1080/15427560.2024.2309145。
[7] Kirtac, K. 和 Germano, G. (2024)。“使用大型语言模型进行情绪交易。”金融研究快报62: 105227。
[8] 刘文杰、葛永斌、顾永超 (2024)。“基于网格网络和情绪注意力机制的新闻驱动型股票市场指数预测”机制。”专家系统及其应用250: 123966。
[9] Qin, Y., and Yang, Y. (2019). “你说什么以及如何说很重要：利用语言和声音线索预测股票波动性。” 会议论文集计算语言学协会第 57 届年会论文集，ACL，第 390-401 页。
[10] Li, Q., Tan, J., Wang, J., and Chen, H. (2020). “基于在线新闻的多模态事件驱动LSTM股票预测模型。” IEEE知识与数据工程学报33 (10): 3323–3337。
[11] Yuan, H., Tang, Y., Xu, W., and Lau, RYK (2021). “探索多模态社交媒体数据对股票表现的影响：一项研究实证视角和分析。”互联网研究31 （3）：871-891。
[12] Das, R. 和 Singh, TD (2023)。“多模态情感分析：方法、趋势和挑战综述。” ACM Computing Surveys 55（13s）：1-38。
[13] Gu, JW, Zhong, YH, Li, SZ, Wei, CS, Dong, LT, Wang, ZY, and Yan, C. (2024). “Predicting stock prices with finbert-lstm: Integrating news sentiment analysis.” In Proceedings of the 2024 8th International Conference on Cloud and Big Data Computing, pp. 67–72.
[14] Li, J., Yang, L., Smyth, B., and Dong, R. (2020). “Maec: A multimodal aligned earnings conference call dataset for financial risk prediction.”在第 29 届 ACM 信息与知识管理国际会议论文集，第 3063-3070 页。
[15] Wang, J., Hu, Y., Jiang, TX, Tan, J., and Li, Q. (2023). “Essential tensor learning for multimodal information-driven stock movement预测。”知识库系统262: 110262。
[16] Wu, JMT, Li, Z., Herencsar, N., Vo, B., and Lin, JCW (2023). “一种基于图的 CNN-LSTM 股票价格预测算法及其领先优势指标。”多媒体系统29 (3): 1751–1770。
[17] Bu, Q. (2023). “所有情绪指标都一样吗？”行为金融杂志24 (2): 161–170。
[18] Hajek, P. 和 Henriques, R. (2024)。“利用新闻情绪和话题检测预测并购目标。”《技术预测与社会》变更201： 123270。
[19] Wang, H., Xie, Z., Chiu, DK, and Ho, KK (2025). “基于多模态市场信息融合的医药行业股票价格趋势预测”制药行业。”应用智能55 （1）：1-27。
[20] Li, S., and Xu, S. (2025). “利用 GAN 和基于 Transformer 的注意力机制增强股票价格预测。”实证经济学68 （1）：373–403。
[21] Iacovides, G., Konstantinidis, T., Xu, M., 和 Mandic, D. (2024). “FinLlama：基于 LLM 的算法金融情绪分析”交易。”载于第五届ACM国际人工智能金融会议论文集，第134-141页）。
[22] Chen, Y., Fang, R., Liang, T., Sha, Z., Li, S., Yi, Y., Zhou, W., and Song, H. (2021). “基于 CNN-BiLSTM-ECA 的股票价格预测模型。”科学编程2021 (1): 2446543。
[23] Sawhney, R., Agarwal, S., Wadhwa, A., 和 Shah, R. (2020)。“基于社交媒体文本和公司相关性的股票走势预测的深度注意力学习。” 2020 年自然语言处理实证方法会议 (EMNLP) 论文集，第 8415–8426 页。

[24] Reis, PMN 和 Pinho, C. (2021)。“重新评估情绪代理与股票收益之间的因果关系。”《股票市场研究杂志》行为金融学22 (4): 420–442。
[25] Lee, TW, Teisseyre, P., 和 Lee, J. (2023). “利用多模态融合变换器有效利用宏观经济指标进行股票方向分类。” IEEE Access 11: 10275–10287。

[26] Chen, YF, and Huang, SH (2021). “基于多模态深度强化学习的情绪影响交易系统。” 应用软件计算机112： 107788。
[27] Sun, L., Xu, W., and Liu, J. (2021). “基于 CNN-LSTM 的股票价格预测双通道注意力机制融合模型。” Trans-亚洲和低资源语言信息处理行动20 (5): 1–12。
[28] Emami Gohari, H., Dang, XH, Shah, SY 和 Zerfos, P. (2024). “面向金融时间序列预测的模态感知 Transformer”。第五届 ACM 国际金融人工智能会议论文集，第 677-685 页。
[29] Du, Z., Huang, AG, Wermers, R., and Wu, W. (2022). “语言和领域特异性：中文金融情感词典。”评论金融26 (3): 673–719。
[30] Li, X., Wu, P., and Wang, W. (2020). “Incorporating stock prices and news sentiments for stock market prediction: A case of Hong Kong.”信息处理与管理57 (5): 102212。
[31] Vaswani, A.、Shazeer, N.、Parmar, N.、Uszkoreit, J.、Jones, L.、Gomez, AN、Kaiser, L. 和 Polosukhin, I. (2017)。 “你所需要的就是注意力。”神经信息处理系统进展30： 1-11。
[32] Shapiro, AH, Sudhof, M., 和 Wilson, DJ (2022)。“衡量新闻情绪。”计量经济学杂志228 (2): 221–243。
[33] Araci, D. (2019). “Finbert：使用预训练语言模型进行金融情感分析。” arXiv 预印本 arXiv:1908.10063。