Machine Translated by Google

The Review of Financial Studies

# 通过机器进行经验资产定价学习*

顾世豪
芝加哥大学布斯商学院

布莱恩·凯利
耶鲁大学、AQR资本管理公司和美国国家经济研究局

大成秀
芝加哥大学布斯商学院

我们对机器学习方法在实证资产定价的典型问题 衡量资产风险溢价 上的应用进行了比较分析。结果表明,使用机器学习预测可以为投资者带来显著的经济收益,在某些情况下,其性能甚至比文献中领先的基于回归的策略高出一倍。我们识别出性能最佳的方法(决策树和神经网络),并发现它们预测能力的提升源于能够捕捉到其他方法无法捕捉到的非线性预测变量交互作用。所有方法都认同同一组主要的预测信号,该组信号包含动量、流动性和波动率的各种变化。 (JEL分类: C52、C55、C58、G0、G1、G17)

本文于2018年9月4日收到;编辑Andrew Karolyi于2019年9月22日做出编辑决定。作者提供了一份网络附录,可在牛津大学出版社网站上最终发表论文的链接旁找到。

*我们受益于与 Joseph Babcock、陈思(评论人)、Rob Engle、Andrea Frazzini、Amit Goyal(评论人)、Lasse Pedersen、彭琳(评论人)、Alberto Rossi(评论人)和周国富(评论人)的讨论,以及与鹿特丹伊拉斯姆斯经济学院、纽约大学、西北大学、帝国理工学院、新加坡国立大学、对外经济贸易大学、南京大学、清华大学PBC金融学院、房利美、美国证券交易委员会、香港城市大学、香港中文大学深圳金融学院、NBER暑期学院、“收益横截面新方法会议”、芝加哥量化联盟会议、挪威金融研究会议、EFA、中国国际金融会议、第十届巴舍利耶金融学会世界大会、金融工程与风险管理国际研讨会、图卢兹金融计量经济学会议、芝加哥统计学、金融计量经济学和数据科学新进展会议以及清华大学等机构的研讨会和会议参与者的交流。大数据与互联网经济学研讨会、Q集团、IQ-KAP研究奖研讨会、沃尔夫研究公司、英国NQUIRE、澳大利亚金融与银行会议、高盛全球另类风险溢价会议、AFA以及瑞士金融学院。我们衷心感谢芝加哥大学研究计算中心提供的计算支持。文中表达的观点和意见仅代表作者个人,并不一定反映AQR资本管理公司、其关联公司或其员工的观点;也不构成购买任何证券或其他金融工具的要约、要约邀请或任何建议或推荐,且不应被解释为上述任何内容。补充数据可在《金融研究评论》网站上找到。

请将信件寄至:Shihao Gu, University of Chicago, Booth School of Business, 5807 S. Woodlawn Ave., Chicago, IL 60637;电话:+1(310)869-0675。电子邮件:shihaogu@chicagobooth.edu。

《金融研究评论》 33 (2020) 2223–2273 © 作者 2020。牛津大学出版社出版。本文为开放获取文章,遵循知识共享署名-非商业性使用-禁止演绎 4.0 国际许可协议 (http://creativecommons.org/licenses/by-nc-nd/4.0/) 的条款进行分发。该协议允许以任何媒介进行非商业性复制和分发,但前提是不得以任何方式更改或改编原文,并且必须正确引用原文。如需商业用途,请联系 journals.permissions@oup.com。doi:10.1093/rfs/hhaa009

提前在线发表于2020年2月26日

本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



本文对应用于金融领域的机器学习方法进行了比较分析。我们以金融领域研究最为广泛的问题之一 股票风险溢价的衡量 为例进行探讨。

我们的主要贡献有两方面。首先,我们为机器学习方法在衡量整体市场和个股风险溢价方面的预测准确性提供了一套新的基准。这种准确性体现在两个方面。首先,与以往文献相比,我们的样本外预测$R^2$值较高,且在各种机器学习模型设定下均表现稳健。其次,更重要的是,我们证明了使用机器学习预测能为投资者带来显著的经济收益。一种利用神经网络预测对标普500指数进行时间调整的投资组合策略,其年化样本外夏普比率为0.77,而买入并持有策略的夏普比率仅为0.51。此外,一种基于个股层面神经网络预测进行仓位调整的市值加权多空十分位价差策略,其年化样本外夏普比率高达1.35,是文献中领先的基于回归的策略的两倍以上。

收益预测具有重要的经济意义。资产定价的根本目标是理解风险溢价的行为。[1]即使预期收益能够被完美观测,我们仍然需要理论来解释其行为,并需要实证分析来检验这些理论。然而,风险溢价的衡量历来十分困难:市场效率使得收益波动主要受不可预测的信息影响,从而掩盖了风险溢价。我们的研究着重探讨了在预测方面可以取得的进展,并识别出最具信息量的预测变量。这有助于解决风险溢价衡量难题,进而促进对资产定价经济机制更可靠的研究。

其次,我们将实证资产定价文献与机器学习领域相结合。相对于传统的实证资产定价方法,机器学习能够容纳更广泛的潜在预测变量和更丰富的函数形式。正是这种灵活性使我们能够拓展风险溢价计量的边界。学术界和工业界对金融领域机器学习方法的兴趣都显著增长。本文对应用于实证资产定价两大典型问题(横截面收益预测和时间序列收益预测)的机器学习方法进行了比较概述。我们认为,研究人员理解机器学习在资产定价中的作用的最佳途径是……

[1] 我们关注的是衡量超过无风险利率的条件预期股票收益。学术金融学传统上将此量称为“风险溢价”,因为它与承担股权投资风险的均衡补偿密切相关。我们交替使用“预期收益”和“风险溢价”这两个术语。人们可能对区分预期收益的不同组成部分感兴趣,例如系统性风险补偿、特质性风险补偿,甚至定价错误所致的收益。关于解决此问题的机器学习方法,请参阅 Gu、Kelly 和 Xiu (2019) 以及 Kelly、Pruitt 和 Su (2019) 的研究。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



资产定价领域的目标是将每种方法应用于熟悉的实证问题,并比较其性能。

“机器学习”的定义尚不明确,而且通常因语境而异。
我们使用该术语来描述 (a) 用于统计预测的各种高维模型集合,以及 (b) 用于模型选择和缓解过拟合的所谓“正则化”方法,以及 (c) 用于在大量潜在模型规范中进行搜索的高效算法。

机器学习方法的高维特性（本定义中的要素 (a)）增强了其相对于传统计量经济学预测技术的灵活性。这种灵活性有望更好地逼近股票风险溢价背后未知且可能复杂的数据生成过程。然而,灵活性的增强也带来了更高的过拟合风险。本机器学习定义的要素 (b) 描述了实现上的改进,强调稳定的样本外性能,以明确防止过拟合。最后,当预测变量众多时,穷举和比较所有模型排列组合变得不切实际。要素 (c) 描述了旨在以可控的计算成本逼近最优模型设定的巧妙机器学习工具。

实证资产定价的诸多方面使其成为一种特别有吸引力的方法。
利用机器学习方法进行分析的领域。
首先,现代实证资产定价研究主要集中在两个研究方向。第一个方向旨在描述和理解不同资产预期收益的差异。第二个方向则侧重于整体市场股票风险溢价的动态变化。资产风险溢价的衡量本质上是一个预测问题 风险溢价是对未来已实现超额收益的条件期望。机器学习的方法大多专门用于预测任务,因此非常适合解决风险溢价衡量问题。

其次,风险溢价的候选条件变量数量庞大。业界已经积累了数量惊人的预测因子清单,许多研究者认为这些因子具有预测收益的能力。

文献中报道的个股层面预测特征数量达数百个,而宏观经济层面的整体市场预测因子数量也仅有数十个。<sup>2</sup>此外,预测因子之间往往关系密切且高度相关。当预测因子数量接近观测值数量或预测因子高度相关时,传统的预测方法便会失效。机器学习强调变量选择和降维技术,因此非常适合应对此类具有挑战性的预测。

[2] Green等人（2013)统计了已发表或流传的草稿中330个股票层面的预测信号。Harvey、Liu和Zhu（2016)研究了316个“因子”,其中包括公司特征和共同因子,用于描述股票收益行为。他们指出,这只是文献中研究的因子的一个子集。Welch和Goyal（2008)分析了近20个用于预测整体市场收益的因子。无论是股票收益还是整体收益预测,可能都存在更多经过测试但未能预测收益因而未被报道的预测因子。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



通过减少自由度和压缩预测变量之间的冗余变异来解决问题。

第三,高维预测变量集以何种函数形式参与风险溢价计算,这一问题进一步加剧了问题的复杂性。它们应该以线性方式参与吗?如果需要非线性关系,又该采用何种形式?我们是否必须考虑预测变量之间的交互作用?诸如此类的问题导致潜在模型设定的数量迅速增加。理论文献很少提供关于如何筛选条件变量和函数形式的指导。机器学习的三个特性使其非常适合处理函数形式模糊的问题。首先是其多样性。作为一套不同方法的集合,它在模型设定搜索方面覆盖面广。其次,机器学习的方法涵盖了从广义线性模型到回归树和神经网络等多种类型,其设计初衷就是为了近似复杂的非线性关联。第三,参数惩罚和保守的模型选择准则与这些方法所涵盖的函数形式的广度相辅相成,从而避免过拟合偏差和错误发现。

我们研究了一系列候选模型,这些模型可能非常适合应对上述三个实证挑战。它们构成了研究生级别机器学习教材中常见的经典方法。[3]这包括线性回归、带惩罚的广义线性模型、通过主成分回归 (PCR) 和偏最小二乘法 (PLS) 进行降维、回归树 (包括提升树和随机森林)以及神经网络。这并非所有方法的详尽分析。

例如,我们排除了支持向量机,因为它们与我们研究的其他方法具有等价性 ,并且主要用于分类问题。尽管如此,我们的列表旨在代表机器学习工具包各个分支中的预测分析工具。

我们开展了一项大规模实证分析,研究了1957年至2016年间近3万只个股。我们的预测变量集包括每只股票的94个特征、每个特征与8个汇总时间序列变量的交互项以及74个行业虚拟变量,总计超过900个基准信号。我们的一些方法通过纳入基准信号的非线性变换和交互项,进一步扩展了这一预测变量集。我们建立了以下关于机器学习在收益预测方面的实证结论。

从最广泛的层面来看,我们的主要实证发现是,机器学习整体上具有提升我们对资产收益实证理解的潜力。它将我们庞大的预测变量数据集 (就现有文献而言)整合到一个收益预测模型中,该模型在性能上优于传统方法。

3 例如,参见 Hastie、Tibshirani 和 Friedman (2009)。

4 例如,参见 Jaggi (2013) 和 Hastie、Tibshirani 和 Friedman (2009),他们讨论了支持向量机与 lasso 的等价性。关于核技巧在收益率横截面上的应用,参见 Kozak (2019)。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



方法。直接的含义是,机器学习有助于解决实际的投资问题,例如市场择时、投资组合选择和风险管理,从而证明了其在金融科技行业业务架构中的作用。

以个股收益率对三个滞后股票层面特征（规模、账面市值比和动量)进行面板回归作为基准。

该基准模型具有诸多吸引人的特点。它简洁明了,而且由于其样本经过严格筛选（所包含的特征已被证实是最稳健的收益预测指标之一）,因此与该基准模型进行比较较为保守。Lewellen (2015) 的研究表明,该模型的性能与文献中研究的规模更大、结构更复杂的股票预测模型基本相当。

在我们的样本中（样本量更大,涵盖的日期和股票数量均多于Lewellen (2015) 研究的样本）,基准模型的样本外$R^2$值在个股收益率面板数据上为每月0.16%。当我们扩展普通最小二乘法 (OLS) 面板模型,使其包含我们900多个预测变量时,预测能力立即消失， $R^2$值骤降至负值区域。这并不令人意外。由于需要估计的参数众多,OLS回归的效率急剧下降,因此产生的样本外预测结果极不稳定。OLS的这种失效引出了我们的下一个经验事实。

当采用惩罚或降维方法时,庞大的预测变量集对于线性预测是可行的。我们发现,机器学习工具包有助于收益预测的第一个证据来自这样一个事实:弹性网络利用参数收缩和变量选择来限制回归的自由度,从而解决了普通最小二乘法（OLS)的效率低下问题。在包含 900 多个预测变量的回归中,弹性网络使样本外$R^2$值达到正值,每月提升 0.11%。

主成分回归 (PCR) 和偏最小二乘法 (PLS) 将预测变量集的维度降低到预测变量的几个线性组合,进一步将样本外R2分别提高到 0.26% 和 0.27%。

尽管存在许多可能只是“偶然”结果、给大型模型带来纯粹噪声的预测因子,但上述结论仍然成立。换句话说,只要能够控制过度参数化,简单线性模型中的高维预测因子集至少可以与现有的低维模型相媲美。

接下来,我们扩展模型,通过广义线性模型、回归树和神经网络来适应非线性预测关系。允许非线性关系显著提高了预测精度。我们发现,回归树和神经网络能够明确地提高收益预测精度,月度股票层面的$R^2$ 值在 0.33% 到 0.40% 之间。但是,广义线性模型（通过每个基准预测变量的样条函数引入非线性,但没有预测变量之间的交互作用)未能稳健地超越线性模型。这表明,允许基准预测变量之间存在（可能很复杂的)交互作用是预期收益函数中非线性关系的关键所在。作为我们分析的一部分,

本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



我们讨论了为什么广义线性模型相对来说不太适合捕捉预测变量之间的相互作用。

浅层学习优于深度学习。当我们考察一系列神经网络,从非常浅的（单隐藏层)到更深的（最多五层隐藏层)时,我们发现神经网络的性能在三层隐藏层时达到峰值,然后随着隐藏层数的增加而下降。同样,在我们的分析中,提升树和随机森林算法倾向于选择“叶子”较少的树（平均少于六个叶子）。这很可能是由于我们的收益预测问题的数据量相对较小,信噪比也很低所致,而深度学习在非金融领域（例如计算机视觉)则凭借庞大的数据集和强信号而蓬勃发展。

在预测投资组合收益时,非线性方法与基准模型之间的差距会进一步扩大。我们基于模型生成的股票层面预测结果,构建自下而上的投资组合层面收益预测。例如,考虑对标普500指数投资组合收益的自下而上预测。通过汇总基准三特征OLS模型的股票层面预测结果,我们发现标普500指数的月度预测$R^2$为-0.22%。相比之下,广义线性模型的自下而上标普500指数预测结果的$R^2$为0.71%。决策树和神经网络在此基础上进一步提升,每月样本外$R^2$在1.08%至1.80%之间。对于预测各种特征因子投资组合（例如基于规模、价值、投资、盈利能力和动量构建的投资组合）,也呈现出相同的模式。特别是,对于我们考虑的每个因子投资组合,三层神经网络都能产生正的样本外预测$R^2$。

与个股层面相比,投资组合层面的预测能力更为显著,这是因为样本中一些规模最小、流动性最差的股票的个股收益率波动较大。将股票聚合为投资组合可以消除大部分不可预测的个股层面噪声,并增强信号强度,从而有助于检测机器学习带来的预测收益。

机器学习预测带来的经济收益十分显著。我们的测试结果清晰地表明， OLS基准模型和其他线性模型在统计学上明显优于非线性机器学习工具。机器学习预测带来的经济收益　以投资组合夏普比率的形式体现　同样令人印象深刻。例如,基于自下而上神经网络预测对标普500指数进行乘数计算的投资者,其年化样本外夏普比率比买入并持有策略的投资者提高了26个百分点,达到0.77（0.51）。此外,当我们构建一个基于神经网络股票收益预测的十分位多空价差策略时,该策略的年化样本外夏普比率分别为1.35（市值加权)和2.45（等权重）。相比之下,使用基准 OLS 模型预测的类似多空策略分别可获得 0.61 和 0.83 的夏普比率。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



最成功的预测指标是价格趋势、流动性和波动性。我们研究的所有方法都得出了非常相似的最具信息量的个股层面预测指标排名,这些指标可分为三大类。首先,也是信息量最大的,是价格趋势变量,包括个股动量、行业动量和短期反转。其次是流动性变量,包括市值、成交量和买卖价差。最后,收益波动率、特质波动率、市场贝塔系数和贝塔系数的平方也是我们考虑的所有模型中的主要预测指标。

模拟可以帮助我们更好地理解机器学习的研究结果。
在网络附录A 中,我们进行了蒙特卡罗模拟,以支持上述分析结果的解释。我们将机器学习应用于来自两种不同数据生成过程的模拟数据。这两种过程都生成来自高维预测变量集的数据。但其中一种过程中,单个预测变量仅以线性加性方式进入模型;而另一种过程中,预测变量可以通过非线性变换和成对交互进入模型。当我们将机器学习方法应用于模拟数据集时,我们发现线性方法和广义线性方法在线性且无交互的设置下占主导地位,而基于树的方法和神经网络在非线性且交互的设置下表现显著更佳。

机器学习在改进风险溢价计量方面具有巨大潜力,而风险溢价计量本质上是一个预测问题。它相当于对条件期望E(ri,t+1|Ft) 进行最佳近似,其中ri,t+1表示资产收益率超过无风险利率的部分， Ft表示市场参与者的真实且不可观测的信息集。机器学习算法在这个领域表现出色。

但这些改进的预测仅仅是测量结果。这些测量结果并不能告诉我们经济机制或均衡状态。机器学习方法本身无法识别资产价格和调节变量之间深层次的基本关联。当目标是理解经济机制时,机器学习仍然可能有用。这需要经济学家添加结构将假设的机制构建到估计问题中 并决定如何引入受此结构约束的机器学习算法。目前已有文献将机器学习与均衡资产定价相结合（例如,Kelly、Pruitt 和 Su 2019;Gu、Kelly 和 Xiu 2019;Feng、Giglio 和 Xiu 即将发表）,这仍然是未来研究的一个令人兴奋的方向。

我们的研究拓展了股票收益预测的实证文献,该文献主要分为两个基本方向。第一个方向将股票预期收益的差异建模为股票层面特征的函数,Fama和French（2008)以及Lewellen（2015)的研究便是例证。该文献中的典型方法是对未来股票收益进行横截面回归分析 。

[5] 除了使用最小二乘回归外,文献还经常根据特征将资产分类到投资组合中,并研究投资组合的平均值,这是一种非参数回归形式。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



第二种方法预测收益率的时间序列,其依据是少数滞后股票特征。Welch 和 Goyal (2008)、Koijen 和 Nieuwerburgh (2011) 以及 Rapach 和 Zhou (2013) 对此进行了综述。这类文献通常对广泛的总体投资组合收益率进行时间序列回归,自变量则选择少量宏观经济预测变量。

这些传统方法存在一些潜在的严重局限性,而机器学习中更先进的统计工具可以帮助克服这些局限性。最重要的是,回归和投资组合排序并不适合处理过去五十年间文献中积累的大量预测变量。挑战在于如何在控制现有信号的同时（或者说,如何处理多重比较和错误发现问题）,评估新提出的预测变量的增量预测能力。我们的主要贡献在于,展示了当使用机器学习方法时,如何利用大量现有变量来有效地预测收益。

机器学习方法在资产定价文献中零星出现。Rapach、Strauss 和 Zhou (2013) 应用 Lasso 回归,利用所有国家的滞后收益率预测全球股票市场收益率。一些论文应用神经网络预测衍生品价格（例如 Hutchinson、Lo 和 Poggio (1994);Yao、Li 和 Tan (2000)）。Khandani、Kim 和 Lo (2010) 以及 Butaru 等人 (2016) 使用回归树预测消费者信用卡拖欠和违约情况。Sirignano、Sadhwani 和 Giesecke (2016) 构建了一个用于预测抵押贷款提前还款、拖欠和止赎的深度神经网络。Heaton、Polson 和 Witte (2016) 开发了一个用于投资组合选择的神经网络。

近年来,机器学习方法的各种变体已被用于研究股票收益的横截面特征。Harvey 和 Liu (2016) 使用自助法研究了多重比较问题。Giglio 和 Xiu (2016) 以及 Kelly、Pruitt 和 Su (2019) 使用降维方法来估计和检验因子定价模型。Moritz 和 Zimmermann (2016) 将基于树的模型应用于投资组合排序。Kozak、Nagel 和 Santosh (2020) 以及 Freyberger、Neuhierl 和 Weber (2020) 分别使用收缩和选择方法来近似随机贴现因子和预期收益的非线性函数。本文旨在同时探索多种机器学习方法来研究预期股票收益的行为,并特别强调方法之间的比较分析。

## 1. 方法论

本节介绍我们在分析中使用的一系列机器学习方法。每个小节都会介绍一种新方法,并从其三个基本要素的角度进行描述。首先是统计模型。

描述风险溢价预测方法的一般函数形式。
第二个是用于估计模型参数的目标函数。所有



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



我们的估计方法都以最小化均方预测误差 (MSE) 为基本目标。正则化是通过对 MSE 目标进行一些调整来实现的,例如添加参数化惩罚和增强对异常值的鲁棒性。这些改进旨在避免过拟合问题,并提高模型的样本外预测性能。最后,即使预测变量数量较少,当考虑非线性预测变量变换时,模型排列组合的集合也会迅速扩展。在我们原本就高维的预测变量集合中,这种扩展会更加显著。每个小节的第三部分都描述了用于高效识别给定方法所包含的所有排列组合中的最优模型的计算算法。

本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

在介绍每种方法时,我们力求对统计模型进行足够深入的描述,以便即使是没有任何机器学习背景的读者也能理解模型的基本结构,而无需查阅其他资料。同时,在讨论每种模型的计算估计方法时,我们特意保持简洁。每种算法都有许多变体,并且每种变体都有其自身的细微技术差别。为了避免读者被编程细节所困扰,我们在网络附录 B中描述了我们具体的实现选择,并建议读者参考原始文献以获取更多背景信息。网络附录 C总结了每种估计器的统计特性相关文献。

最一般而言,我们将资产的超额收益描述为一个加性函数。
预测误差模型:

$$r_{i,t+1} = E_t(r_{i,t+1}) + \epsilon_{i,t+1}, \tag{1}$$

在哪里

$$E_t(r_{i,t+1}) = g(z_{i,t}). \tag{2}$$

股票指数为 $i = 1,\ldots,N_t$ ,月份指数为 $t = 1,\ldots,T$。为了便于表述,我们假设股票面板数据是平衡的,并将缺失数据的讨论推迟到第 2.1 节。我们的目标是找到$E_t(r_{i,t+1})$关于预测变量的函数表示,以最大化对已实现$r_{i,t+1}$ 的样本外解释力。我们将这些预测变量表示为 P 维向量$z_{i,t}$ ,并假设条件预期收益率 $g(\cdot)$ 是这些预测变量的灵活函数。

尽管该框架具有灵活性,但它也施加了一些重要的限制。
$g(\cdot)$ 函数既不依赖于 i 也不依赖于 t。通过在不同的时间段和不同的股票之间保持相同的形式,该模型利用了整个面板的信息,并赋予了任何单个资产风险溢价估计的稳定性。这与标准的资产定价方法形成对比,后者在每个时间段重新估计横截面模型,或者独立地估计每只股票的时间序列模型。此外,$g(\cdot)$ 仅通过$z_{i,t}$依赖于 z 。

这意味着我们的预测不使用 t 之前的历史信息,也不使用除第 i 只股票之外的个别股票的信息。

Machine Translated by Google



1.1 通过验证进行样本分割和调整重要的初步步骤（在讨论具体模
型和正则化方法之前)是了解我们如何设计用于估计和测试的不相交子样本,并引入“超参数调整”的概念。

下文讨论的正则化程序是机器学习防止过拟合的主要防御手段,它们依赖于超参数（或同义地称为“调优参数”)的选择。这些参数对机器学习方法的性能至关重要,因为它们控制着模型的复杂度。例如,超参数包括 Lasso 和 Elastic Net 中的惩罚参数、Boosting 算法中迭代树的数量、随机森林中随机树的数量以及树的深度。在大多数情况下,对于如何“调优”超参数以获得最佳的样本外性能,理论指导甚少。<sup>6</sup>

我们遵循文献中最常见的方法,从验证样本数据中自适应地选择调参。具体来说,我们将样本划分为三个互不相交的时间段,以保持数据的时间顺序。第一个子样本,即“训练”子样本,用于在特定调参值下估计模型。

第二个样本,或称“验证”样本,用于调整超参数。
我们基于训练样本中估计的模型,构建验证样本中数据点的预测。接下来,我们基于验证样本的预测误差计算目标函数,并迭代地搜索能够优化验证目标的超参数（在每一步中,根据当前的超参数值,从训练数据重新估计模型）。

调优参数是从验证样本中选择的,并考虑了估计参数,但这些估计参数仅基于训练数据。验证的目的是模拟模型的样本外测试。超参数调优相当于寻找一种模型复杂度,使其能够产生可靠的样本外性能。验证样本的拟合结果当然并非真正意义上的样本外数据,因为它们用于调优,而调优结果又是估计的输入。因此,第三个子样本,即“测试”子样本,既不用于估计也不用于调优,才是真正意义上的样本外数据,因此用于评估方法的预测性能。

互联网附录 D提供了我们样本拆分方案的更多细节,互联网附录 E总结了每个模型的超参数调整方案。

1.2 简单线性模型我
们首先从分析中最简单的方法　通过普通最小二乘法 (OLS) 估计的简单线性预测回归模型　开始描述模型。尽管我们预期这种方法在高样本量下表现不佳,但我们仍然会使用简单线性预测回归模型。

6 在机器学习中，“超参数”控制着估计器正则化的程度。这种用法与贝叶斯统计学中超参数作为先验分布参数的含义相关,但又有所不同。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



维度问题,我们将其作为参考点,以强调更复杂方法的独特特征。

简单的线性模型规定,条件期望 g(·) 可以用原始预测变量和参数向量 θ 的线性函数来近似表示,

$$g(z_{i,t};\theta)=z\,\theta.\,i,t \tag{3}$$

该模型采用简单的回归设定,不允许非线性效应或预测变量之间的交互作用。

我们对简单线性模型的基准估计采用标准最小二乘法。
平方,或“l2”,目标函数:

$$L(\theta)=\frac{1}{NT}\sum_{i=1}^{N}\sum_{t=1}^{T}\left(r_{i,t+1}-g(z_{i,t};\theta)\right)^{2}。 \tag{4}$$

最小化 L(θ) 即可得到混合最小二乘估计量。基准l2目标函数的优势在于它能提供解析估计,从而避免了复杂的优化和计算。

1.2.1 扩展:鲁棒目标函数。在某些情况下,可以用加权最小二乘目标函数代替公式 (4),例如:

$$LW(\theta)=\frac{1}{NT}\sum_{i=1}^{N}\sum_{t=1}^{T}w_{i,t}\left(r_{i,t+1}-g(z_{i,t};\theta)\right)^{2}, \tag{5}$$

有可能提高预测性能。这种加权最小二乘目标函数允许计量经济学家将估计值偏向于统计或经济信息量更大的观测值。例如,我们考虑的一种变体将wi,t设置为与 t 时刻的股票数量成反比。这意味着无论当月有多少股票可用,每个月对模型的贡献都相同。这也相当于对 t 时刻所有可用股票的平方损失赋予相同的权重。我们考虑的另一种变体将wi,t设置为与 t 时刻股票 i 的市值成正比。这种价值加权损失函数降低了小盘股的权重,提高了大盘股的权重,其经济依据是:小盘股在交易股票数量上占很大比例,但其总市值却只占很小一部分。<sup>7</sup>

厚尾是金融收益和股票层面预测变量的一个众所周知的特征。最小二乘目标函数 (4)的凸性要求极高,它特别强调较大的误差,因此异常值会破坏基于OLS的模型的稳定性。

7 根据 Fama 和 French (2008) 的数据,市值最小的 20% 的股票仅占总市值的 3%。
统计动机加权方案的一个例子是使用wi,t与观测值的估计误差方差成反比,这种选择有可能提高预测效率,类似于广义最小二乘法。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



预测。统计学文献长期以来都意识到了这个问题,并发展出了一套方法。
改进的最小二乘目标函数往往会产生更稳定的结果
在存在极端观测值的情况下,预测结果优于 OLS。8在机器中
学习文学是抵消这种有害影响的常见选择。
对于重尾观测值,Huber 稳健目标函数是:
定义为

$$LH(\theta)=\frac{1}{NT}\sum_{i=1}^{N}\sum_{t=1}^{T}H\left(r_{i,t+1}-g(z_{i,t};\theta),\xi\right), \tag{6}$$

在哪里

$$H(x;\xi)=\begin{cases}x^2, & \text{如果 } |x|\leqslant\xi;\\ 2\xi|x|-\xi^2, & \text{如果 } |x|>\xi。\end{cases}$$

Huber损失函数H(·)是平方损失函数的混合形式,适用于相对较小的误差;
对于相对较大的误差,绝对损失由以下因素控制:
一个调参参数 ξ,尽管这种迁 可以根据数据进行自适应优化。9
回的方法在以下背景下引入了鲁棒的目标函数:
简单的线性模型几乎适用于所有方法。
我们进行研究。在我们的实证分析中,我们研究了稳健预测的优势。
多种机器学习方法中的损失函数。

### 1.3 惩罚线性

当存在大量预测变量时,简单的线性模型必然会失效。
当预测变量的数量 P 接近观测值的数量 T 时,线性模型会变得效率低下甚至不一致。<sup>10</sup>,
它开始过拟合。
提取的是噪声而不是信号。这对于以下情况尤其麻烦:
信噪比极低的收益预测问题。
避免过拟合的关键在于减少估计参数的数量。
最常用的机器学习参数简约性约束方法
是在目标函数中添加惩罚项,以鼓励更多
简洁的规范。这种对估计问题的“正则化”
通过机械方式降低模型的样本内性能,希望它能
提高了其样本外稳定性。当进行惩罚时,情况就是如此。
能够在保持信号拟合度的同时,降低模型对噪声的拟合度。
我们惩罚线性模型的统计模型与简单的线性模型相同。
公式 (3)中的线性模型。也就是说,它仍然只考虑基线,

8 经典分析包括 Box (1953)、Tukey (1960) 和 Huber (1964)。

9 OLS 是式 (6) 在ξ =∞时的特例。尽管大多数来自高维统计的理论分析
假设数据具有亚高斯或亚指数分布的尾部,Fan等人 (2017)提供了理论依据。
在高维设置中使用此损失函数以及确定超参数的程序。

10 我们特意将P与T 的依赖性进行比较,从而限 ,而不是用NT ,因为股票收益率具有很强的横截面相关性。
制了新的截面观测中所包含的增量信息。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



未转换的预测变量。惩罚方法与此不同,它在原始损失函数上附加了一个惩罚项:

$$L(\theta;\cdot)=L(\theta)+\phi(\theta;\cdot)。 \tag{7}$$

惩罚函数 $\phi(\theta;\cdot)$ 有多种选择。我们重点关注常用的“弹性网络”惩罚函数,其形式如下:

$$\phi(\theta;\lambda,\rho)=\lambda(1-\rho)\sum_{j=1}^{P}|\theta_j|+\lambda\rho\sum_{j=1}^{P}\theta_j^2。 \tag{8}$$

弹性网络包含两个非负超参数 λ 和 ρ,并包含两个著名的正则化方法作为特例。ρ = 0 的情况对应于 Lasso 回归,它使用绝对值(或称“l1”)参数惩罚。Lasso 回归的特殊几何结构使得一部分协变量的系数恰好为零。从这个意义上讲,Lasso 回归对模型设定施加了稀疏性,因此可以被视为一种变量选择方法。ρ = 1 的情况对应于岭回归,它使用l2参数惩罚,使所有系数估计值更接近于零,但不会强制任何系数为零。

从这个意义上讲,岭回归是一种收缩方法,有助于防止系数过大。对于 ρ 的中间值,弹性网络通过收缩和选择两种方式来促进模型的简化。

我们使用验证样本自适应地优化调参 λ 和 ρ。我们实现的惩罚回归采用加速近端梯度算法,并同时支持最小二乘法和 Huber 目标函数(更多详情请参见网络附录 B.1)。

1.4 降维:PCR 和 PLS惩罚线性模型通过收缩和变量选择

来处理高维问题,强制大多数回归变量的系数接近或正好为零。当预测变量高度相关时,这可能会导致次优预测。一个简单的例子是,所有预测变量都等于预测目标值加上一个独立同分布的噪声项。在这种情况下,通过 lasso 惩罚选择预测变量子集不如对所有预测变量取简单平均值并将其作为单变量回归中的唯一预测变量。

与预测变量选择不同,预测变量平均是降维的本质。通过对预测变量进行线性组合,可以降低噪声,更好地提取预测变量中的信号,并有助于消除原本高度相关的预测变量之间的相关性。两种经典的降维技术是主成分回归(PCR)和偏最小二乘法(PLS)。

PCR 由两步组成。第一步,主成分分析 (PCA) 将回归变量组合成一组线性组合,以最大程度地保留预测变量之间的协方差结构。第二步



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



步骤一是使用标准预测回归中的几个主要成分。也就是说,PCR 通过将低方差成分的系数置零来正则化预测问题。

主成分回归 (PCR) 的一个缺点是,它未能将最终的统计目标 预测收益 纳入降维步骤中。主成分分析 (PCA) 则基于预测变量之间的协方差将数据压缩成不同的成分。

这发生在预测步骤之前,并且没有考虑预测因子与未来收益之间的关联。

相比之下,偏最小二乘法 (PLS) 通过直接利用预测变量与预测目标之间的协变关系来进行降维。<sup>11</sup> PLS 回归的步骤如下:对于每个预测变量 j,首先通过普通最小二乘法 (OLS) 计算预测系数。该系数记为 <sub>j</sub>,表示收益对每个预测变量 j 估计其单变量收益反映了的“部分”敏感度。接下来,将所有预测变量平均化为一个聚合分量,权重与 <sub>j</sub> 成正比,其中最强的单变量预测变量权重最高,最弱的单变量预测变量权重最低。这样,PLS 就能在最终预测目标的指导下进行降维。为了生成多个预测分量,需要将目标值和所有预测变量相对于先前构建的分量进行正交化,然后在正交化的数据集上重复上述步骤。如此迭代,直到达到所需的 PLS 分量数量。

我们对 PCR 和 PLS 的实现始于方程 (1)~(3) 中线性模型的向量化版本。具体来说,我们重新组织了线性回归ri,t+1 =z

$$\text{它}\ \theta + i,t+1 \text{ as}$$

$$R = Z\theta + E, \tag{9}$$

其中 R 是 ri,t+1 的 NT ×1 向量, Z 是堆叠预测变量zi,t的 NT ×P 矩阵,E 是残差的 NT ×1 向量。PCR 和 PLS 采用相同的一般方法来降低维度。 i,t+1。

它们都将维度为 P 的预测变量集压缩成数量少得多的 K 个预测变量的线性组合。因此,两种方法的预测模型都可以写成如下形式:

$$R = (Z\Omega K)\theta K + E。 \tag{10}$$

ΩK是一个 P × K 矩阵,其列分别为w1, w2, ..., wK。每个wj是用于创建第 j 个预测分量的线性组合权重集,因此 ZΩK是原始预测变量集的降维版本。同样,预测系数θK现在是一个 K × 1 向量,而不是 P × 1 向量。

11 有关 PLS 回归的渐近理论及其在金融市场风险溢价预测中的应用,请参阅 Kelly 和 Pruitt (2013, 2015)。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



PCR递归地选择组合权重ΩK。j 线性组合求解12

$$_{西} \quad \text{Var}(Zw),\ \text{st } ww=1,\ \text{Cov}(Zw,Zwl)=0,l=1,2,\ldots,j-1。\ wj=\arg \text{最大值} \quad (11)$$

直观地说,PCR 算法旨在寻找能够最忠实地模拟完整预测变量集的 K 个 Z 的线性组合。目标函数表明,分量的选择完全不基于预测目标。相反,PCR 的重点在于找到能够保留预测变量集中最大可能共同变异的分量。众所周知的 (11) 式的解是通过对 Z 进行奇异值分解来计算ΩK 的,因此从计算角度来看,PCR 算法非常高效。

与主成分分析 (PCR) 不同,偏最小二乘法 (PLS) 的目标是找到 K 个 Z 的线性组合,使它们与预测目标具有最大的预测相关性。用于构建第 j 个 PLS 分量的权重求解

$$wj=\text{argmax}_{西} \quad \text{Cov2}(R,Zw),\ \text{st } ww=1,\ \text{Cov}(Zw,Zwl)=0,l=1,2,\ldots,j-1。 \quad (12)$$

这一目标凸显了PCR和PLS之间的主要区别。PLS愿意牺牲ZΩK对Z的近似精度,以找到具有更强收益预测能力的成分。式(12)中的问题可以使用许多类似的程序高效求解,其中最著名的是de Jong (1993)提出的SIMPLS算法。

最后,给定 ΩK 的解,在 PCR 和 PLS 中, θK均通过 R 对ZΩK 的 OLS 回归进行估计。对于这两个模型,K 都是一个超参数,可以根据验证样本自适应地确定。

1.5 广义线性模型 线性模型在实践中

应用广泛,部分原因是它们可以被视为数据生成过程的一阶近似。<sup>13</sup>当“真实”模型复杂且非线性时,将函数形式限制为线性会由于模型设定错误而引入近似误差。令g(zi,t)表示真实模型, g(zi,t;θ)表示计量经济学家设定的函数形式。令g(zi,t;θ)和ri,t+1 分别表示拟合模型及其相应的收益预测。我们可以将模型的预测误差分解为:

$$r_{i,t+1}-r_{i,t+1}=\underbrace{g(z_{i,t})-g(z_{i,t};\theta)}_{\text{近似误差}}+\underbrace{g(z_{i,t};\theta)-g(z_{i,t};\theta)}_{\text{估计误差}}+\underbrace{\varepsilon_{i,t+1}}_{\text{固有误差}}。$$

内在误差是不可减少的;它是收益中真正不可预测的成分,与新闻发布和其他随机因素有关。

12 对于两个向量a和b,我们记Cov(a,b):= (a−¯a) (b−b¯),其中a¯是 a 的所有元素的平均值。显然,我们定义Var(a):=Cov(a,a)。

13 有关线性模型作为一阶近似的局限性的讨论,请参阅 White (1980)。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



金融市场。估计误差源于抽样变异,由数据决定。虽然增加新的观测值可能有助于降低估计误差,但这可能并非计量经济学家所能控制。近似误差则由计量经济学家直接控制,并且可以通过引入更灵活的模型设定来降低,从而提高模型对真实模型的逼近能力。然而,更高的灵活性会增加过拟合的风险,并导致模型在样本外不稳定。在本节及后续小节中,我们将介绍具有不同灵活性的非参数g(·)模型,每个模型都辅以正则化方法来缓解过拟合。

我们考虑的第一种也是最直接的非参数方法是广义线性模型。它将原始预测变量的非线性变换作为新的加性项引入到原本的线性模型中。

因此,广义线性模型是与第 1.2 节和第 1.3 节中的线性方法最接近的非线性对应物。

我们研究的模型通过添加 K 项样条函数来改进简单的线性形式。
预测因子的级数展开

$$g(z;\theta,p(\cdot))=\sum_{j=1}^{P} p(zj)\,\theta j\,, \tag{13}$$

其中p(·)=(p1(·),p2(·),...,pK(·))是基函数向量,参数则为 K × N 矩阵 θ =(θ1,θ2,...,θN )。样条函数有很多种选择。我们采用二阶样条级数:1,z,(z−c1) 2,(z−c2) 2,...,(z−cK−2) 2

, 其中c1, c2,⋯cK−2为纽结。

由于高阶项以加性方式引入,因此可以使用与第 1.2 节相同的估计工具来处理广义线性模型的预测。具体而言,我们的分析使用了最小二乘目标函数,包括有无 Huber 稳健性修正的情况。由于级数展开会迅速增加模型参数的数量,我们使用惩罚来控制自由度。我们选择的惩罚函数是专门针对样条展开的,称为组套索（group lasso）。其形式如下:

$$\phi(\theta;\lambda,K)=\lambda\sum_{j=1}^{P}\sum_{k=1}^{K}\theta_{2\,j,k1/2}\,。 \tag{14}$$

顾名思义,群组套索算法要么选择与给定特征相关的全部 K 个样条项,要么一个都不选择。我们将此惩罚项嵌入到公式 (7) 的一般目标函数中。群组套索算法既支持最小二乘目标函数,也支持鲁棒 Huber 目标函数,并且它使用与弹性网络相同的加速近端梯度下降法。它有两个调参参数:λ 和 K。

14

14 有关更多详细信息,请参阅互联网附录 B.1。Freyberger 、Neuhierl 和 Weber (2020) 在收益预测方面提供了类似的模型。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



1.6 提升回归树和随机森林式 (13) 中的模型捕捉了单个预测变量对预期收益的非线性影响,但并未考虑预测变量之间的交互作用。一种添加交互作用的方法是扩展广义模型,使其包含预测变量的多变量函数。虽然用 K 个基函数扩展单变量预测变量会使参数数量乘以 K,但多维交互作用会组合地增加参数化程度。如果没有预先假设要包含哪些交互作用,广义线性模型在计算上将变得不可行。<sup>15</sup>

作为一种替代方案,回归树已成为一种流行的机器学习方法,用于处理多因素预测变量的交互作用。与线性模型不同,回归树是完全非参数的,其逻辑与传统回归截然不同。从根本上讲,回归树旨在找到行为相似的观测值组。回归树的“生长”过程分为一系列步骤。在每个步骤中,一个新的“分支”会根据某个预测变量将前一步剩余的数据分类到不同的区间中。这种顺序分支将预测变量空间分割成矩形区域,并用每个区域内结果变量的平均值来近似未知函数 g(·)。

图 1 展示了一个包含两个预测变量“size”和“b/m”的示例。左侧面板描述了决策树如何根据每个预测变量的值将观测值分配到相应的分区。首先,观测值按 size 排序。size 值高于 0.5 的观测值被分配到类别 3。然后,size 值较小的观测值按 b/m 值进一步排序。size 值较小且 b/m 值低于 0.3 的观测值被分配到类别 1,而 b/m 值高于 0.3 的观测值则被分配到类别 2。

最后,每个分区中观测值的预测值定义为该分区中结果变量值的简单平均值。其中有 K 个“叶子”(终端节点)。

更正式地说,对深度为 L 的树 T 的预测可以写成:,

$$g(z_i,t;\theta,K,L)=\sum_{k=1}^{K}\theta_{k1}\{z_i,t\in C_k(L)\}, \tag{15}$$

其中Ck(L) 是数据的 K 个划分之一。每个划分都是至多 L 个预测变量指示函数的乘积。与划分 k 相关的常数(记为θk)定义为该划分内结果的样本平均值。<sup>16</sup>图 1 中的示例具有以下预测方程: $g(z_i,t;\theta,3,2)=\theta_{11}\{size_i,t<0.5\}1\{b/m_i,t<0.3\}+\theta_{21}\{size_i,t<0.5\}1\{b/m_i,t\geq 0.3\}+\theta_{31}\{size_i,t\geq 0.5\}$。

15 当预测变量的数量远大于观测变量的数量时,参数惩罚并不能解决线性模型估计的难题。此时,必须采用启发式优化算法,例如逐步回归(依次添加/删除变量,直到满足某个停止规则)、变量筛选(保留与预测目标单变量相关性超过特定值的预测变量)等。

16 我们重点关注递归二叉树,因为它们相对简单。Breiman 等人 (1984) 讨论了更复杂的树结构。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



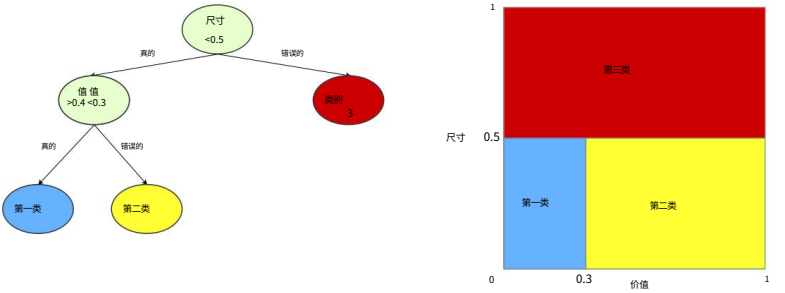



图 1 回归
树示例该图展示了回归树（左）
及其在两个特征（规模和价值)空间中的等效表示（右）。树的末端节点分别用蓝色、黄色和红色表示。根据这两个特征的值,个股样本被分为三类。

构建决策树的过程就是找到能够最好地区分各种潜在结果的区间。分支所依据的具体预测变量以及分支分裂点的具体数值,都应以最小化预测误差为目标。

然而,潜在的树状结构种类繁多,因此无法进行精确优化。
文献中已发展出一系列复杂的优化启发式算法,用于快速收敛到近似最优的决策树。我们采用 Breiman 等人 (1984) 的算法,并在网络附录 B.2 中对其进行详细描述。其基本思想是在每个分支的起始位置进行预测误差的优化。在每个新的层级,我们从预测变量集中选择一个排序变量和分割值,以最大化每个区间内平均结果之间的差异。<sup>17</sup>与分支 C 的预测误差相关的损失通常被称为“不纯度”,它描述了分割点两侧观测值的相似程度。我们为决策树的每个分支选择最常用的l<sup>2 </sup> 不纯度:

$$H(\theta,C)=\frac{1}{|C|}\sum_{z_i,t\in C}(r_{i,t+1}-\theta)^2, \tag{16}$$

其中 |C| 表示集合 C 中的观测值数量。给定 C,显然θ的最优选择为:θ = zi,t∈C ri,t+1。该过程等价于|C|找到局部最小化不纯度的分支 C。当叶子数量或树的深度达到预先指定的阈值时,分支停止,该阈值可以使用验证样本自适应地选择。

树模型的优点在于:它对预测变量的单调变换具有不变性;它能自然地在同一模型中处理分类数据和数值数据;它能够近似潜在的严重偏差。

17 由于选择分支时没有考虑未来的潜在分支,因此可能会短视地绕过一个较差的分支,而该分支最终会导致预测误差显著降低。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



非线性,并且深度为 L 的树可以捕捉 (L−1) 路交互。
它们的灵活性也是它们的局限性。决策树是最容易过拟合的预测方法之一,因此必须进行大量的正则化。在我们的分析中,我们考虑了两种“集成”决策树正则化器,它们将来自多个不同决策树的预测结果组合成一个单一的预测结果。<sup>18</sup>

第一种正则化方法是“提升”(boosting),它递归地组合多个过于简化的决策树的预测结果。<sup>19</sup>单独来看,浅层决策树是“弱学习器”,预测能力微乎其微。提升背后的理论表明,许多弱学习器作为一个集成模型,可以构成一个比单个复杂决策树更稳定的“强学习器”。

我们的提升过程(通常称为梯度提升回归树 (GBRT))的详细步骤在互联网附录 B.2 的算法 4 中描述。它首先拟合一棵浅树(例如,深度 L=1)。这棵过于简化的树必然是一个预测能力较弱且在训练样本中存在较大偏差的预测器。接下来,使用第二棵简单的树(深度 L 相同)来拟合第一棵树的预测残差。将这两棵树的预测结果相加,形成一个集成预测,但第二棵树的预测分量会按因子 ν ∈(0,1) 进行收缩,以防止模型过拟合残差。在每个新的步骤 b 中,使用 b-1 棵树的模型残差拟合一棵浅树,并将其残差预测值以收缩权重 ν 添加到总预测值中。如此迭代,直到集成中总共有 B 棵树。因此,最终输出是一个具有三个调参(L、ν、B)的浅层树的加性模型,我们在验证步骤中自适应地选择这些调参。

与提升算法类似,随机森林也是一种集成方法,它将来自多个不同决策树的预测结果结合起来。它是更通用的方法 自助聚合(或称“bagging”)(Breiman 2001)的一种变体。基本的树bagging方法会抽取B个不同的数据自助样本,为每个样本拟合一个单独的回归树,然后对它们的预测结果取平均值。单个自助样本对应的树往往很深且过拟合,导致其预测结果波动较大,效率低下。对多个预测结果取平均值可以降低这种波动,从而稳定树的预测性能。

随机森林采用一种改进的 bagging 方法,旨在降低不同 bootstrap 样本中决策树之间的相关性。例如,如果公司规模是数据中主要的收益预测因子,那么大多数 bagging 决策树在规模上的分割程度较低,导致其最终预测结果之间存在显著相关性。森林方法使用一种称为去相关性的方法来消除决策树之间的相关性。

---

18 文献中还探讨了其他一些树正则化方法,例如提前停止和后剪枝,这两种方法都是为了减少单棵大型树的过拟合。集成方法展现出更可靠的性能,并且能够扩展到非常大的数据集,因此在近期的文献中越来越受欢迎。

19 Boosting算法最初由Schapire(1990)和Freund(1995)提出,用于分类问题,旨在提升一组弱学习器的性能。Friedman等人(2000)和Friedman(2001)将Boosting算法扩展到分类以外的领域,最终发展出了梯度提升回归树。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



“dropout”方法仅考虑在每个潜在分支处随机抽取的一个预测因子子集进行分裂。这样做可以确保，在本例中，至少有几棵树的早期分支会基于公司规模以外的特征进行分裂。

这降低了预测结果之间的平均相关性，从而进一步提高了相对于标准 bagging 的方差缩减效果。树的深度 L、每次分裂中的预测变量数量以及 bootstrap 样本数量 B 是通过验证集优化的调优参数。互联网附录中的算法 3详细描述了我们随机森林的实现细节。

本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

1.7 神经网络我们分析的最后

一个非线性方法是人工神经网络。

神经网络可以说是机器学习中最强大的建模工具，其理论基础是作为任何平滑预测关联的“通用逼近器”（Hornik、Stinchcombe 和 White 1989；Cybenko 1989）。它们是目前解决复杂机器学习问题的首选方法，例如计算机视觉、自然语言处理和自动游戏（如国际象棋和围棋）。神经网络的灵活性源于其能够交织多个层级的非线性预测器交互，因此也被称为“深度学习”。与此同时，神经网络的复杂性也使其成为透明度最低、可解释性最差、参数化程度最高的机器学习工具之一。

我们的分析重点是传统的“前馈”网络。这类网络由一个包含原始预测器的“输入层”、一个或多个相互作用并非线性转换预测器的“隐藏层”以及一个将隐藏层聚合为最终结果预测的“输出层”组成。类似于生物大脑中的轴突，网络的每一层代表一组“神经元”，每一层都通过“突触”连接，突触在不同层的神经元之间传递信号。图2展示了两个示例。

输入层的单元数等于预测变量的维度，在本例中我们将其设置为四（记为z1,...,z4）。左图展示了最简单的网络，它没有隐藏层。每个预测变量的信号都根据一个五维参数向量 θ 进行放大或衰减，该向量包含一个截距和一个权重参数（每个预测变量对应一个权重参数）。输出层将加权信号聚合为预测值 θ0 + zkθk；也就是说，最简单的神经网络是一个线性回归模型。

4 k=1

该模型通过在输入和输出之间添加隐藏层，实现了更灵活的预测关联。图 2 的右图展示了一个包含五个神经元的单隐藏层示例。每个神经元都像左侧的简单网络一样，从所有输入单元线性提取信息。然后，每个神经元在将其输出发送到下一层之前，对其聚合信号应用非线性“激活函数”f。例如，隐藏层中的第二个神经元将输入转换为输出，如x(1) = f θ(0) 2,0+ θ(0) 2,j 。最后，每个神经元的结果线性地表示为zj j=1 。

4

2

Machine Translated by Google



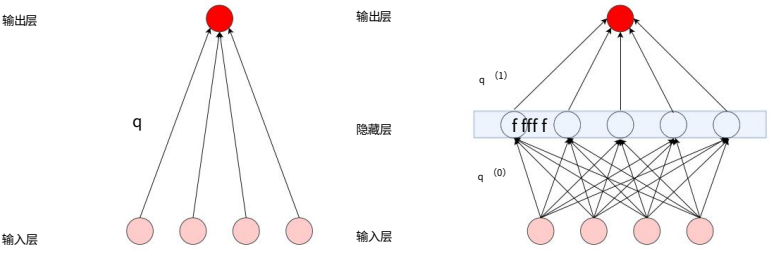



图 2 神经网
络该图展示了两个简单
的神经网络,一个不带有隐藏层（右）,一个不带隐藏层（左）。粉色圆圈表示输入层,深红色圆圈表示输出层。每个箭头都对应一个权重参数。在带有隐藏层的网络中,非线性激活函数f在将输入传递到输出之前对其进行变换。

汇总成最终产量预测：

$$g(z;\theta)=\theta_0^{(1)}+\sum_{j=1}^{5}x_j^{(1)}\theta_j^{(1)}。$$

因此,在这个例子中,总共有 31 = (4+1)×5+6 个参数（五个参数用于到达每个神经元,六个权重用于将神经元聚合为一个单一的输出）。

构建神经网络时需要做出许多选择,包括隐藏层的数量、每层神经元的数量以及连接哪些单元。尽管前述的“通用逼近”结果表明单个隐藏层就足够了,但最近的文献表明,更深的网络通常可以用更少的参数达到相同的精度。<sup>20</sup>

另一方面,在小数据集上,层数和节点数较少的简单网络通常表现最佳。训练深度神经网络极具挑战性,因为它通常涉及大量参数,目标函数高度非凸,而且递归计算导数（称为“反向传播”）容易出现梯度爆炸或梯度消失的问题。

通过交叉验证选择合适的网络架构通常是一项艰巨的任务。通过搜索无数种架构来找到最优网络既不现实也没必要。因此,我们预先设定多种网络架构,并对每种架构进行性能评估。我们希望能够得到机器学习方法性能的合理下限。

20 Eldan 和 Shamir (2016) 正式证明,在标准的前馈神经网络中,即使只增加一层深度,其价值也比增加宽度高得多。自 Hinton、Osindero 和 Teh (2006) 的开创性工作以来,机器学习界一直在尝试和采用更深（也更宽）的网络,用于图像识别的网络层数甚至高达 152 层（例如,参见 He 等人,2016）。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



我们考虑最多包含五个隐藏层的架构。我们最浅层的神经网络只有一个隐藏层,包含32个神经元,我们将其记为NN1。接下来,NN2有两个隐藏层,分别包含32个和16个神经元;NN3有三个隐藏层,分别包含32个、16个和8个神经元;NN4有四个隐藏层,分别包含32个、16个、8个和4个神经元;NN5有五个隐藏层,分别包含32个、16个、8个、4个和2个神经元。我们根据几何金字塔规则（参见Masters 1993)选择每层的神经元数量。所有架构都是全连接的,因此每个单元都接收来自其下一层所有单元的输入。通过比较 NN1 至 NN5 的性能,我们可以推断网络深度在收益率预测问题中的权衡关系。<sup>21</sup>非线性激活函数有很多潜在的选择（例如 sigmoid、双曲函数、softmax 函数）。我们在所有节点上使用相同的激活函数,并选择了近期文献中常用的一种函数形式,即修正线性单元 (ReLU),其定义为<sup> 22</sup>

$$\text{ReLU}(x)=\begin{cases}0 & \text{当 } x<0 \text{ 时}\\ x, & \text{否则为 } x,\end{cases}$$

这样可以减少活跃神经元的数量,并加快导数评估速度。

我们的神经网络模型具有以下通用公式。令K(l)表示每一层 l = 1,...,L 中的神经元数量。定义第 l 层中神经元 k 的输出为x(l)k 。接下来,定义该层的输出向量（包含一个常数， x(l) )为x(l) = (1,x(l) ,...,x(l)) 。类似地,使用原始预测变量义输入层， x(0) = (1,z1,...,zN )。

0 1 K(l) ）。要初始化网络，

神经网络中第 l>0 层每个神经元的递归输出公式为

$$x_k^{(l)} = \text{ReLU}\left(x^{(l-1)}\theta_k^{(l-1)}\right), \tag{17}$$

最终输出

$$g(z;\theta)=x^{(L-1)}\theta^{(L-1)}。 \tag{18}$$

每个隐藏层 l 的权重参数数量为K(l) (1+K(l−1)),加上输出层的另外1+K(L−1)个权重。

我们通过最小化预测误差的惩罚性L2目标函数来估计神经网络权重参数。与需要“贪婪”优化的基于树的算法不同,原则上,训练神经网络允许在每一步中联合更新所有模型参数。

21 由于我们的样本量有限（与典型的神经网络应用相比）,我们将架构的选择限制在五个较小的范围内。

22 例如,参见 Jarrett 等人 (2009)、Nair 和 Hinton (2010) 以及 Glorot、Bordes 和 Bengio (2011)。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



优化 这是神经网络相对于决策树的一个显著优势。
然而,神经网络的高度非线性和非凸性,以及其丰富的参数化特性,使得穷举优化计算量极大（往往达到无法实现的程度）。一种常见的解决方案是使用随机梯度下降（SGD)来训练神经网络。

与每次迭代都使用整个训练样本来评估梯度的标准下降法不同,随机梯度下降法（SGD)仅使用一小部分随机数据子集来评估梯度。这种近似方法牺牲了精度,但极大地加快了优化过程。

出于与上述相同的原因（严重的非线性和繁重的参数化）,神经网络的正则化需要比前面讨论的方法更加谨慎。除了对权重参数进行l1惩罚之外,我们的估计中还同时采用了其他四种正则化技术:学习率收缩、提前停止、批量归一化和集成学习。

在随机梯度下降法（SGD)中,一个关键的调参是学习率,它控制着下降的步长。当梯度趋近于零时,必须将学习率逐渐减小至零,否则梯度计算中的噪声会开始主导其方向信号。我们采用Kingma和Ba（2014)提出的“学习率收缩”算法来自适应地控制学习率（详见互联网附录B.3中的算法5）。<sup>23</sup>

接下来,“提前停止”是一种通用的机器学习正则化工具。它从一个初始参数猜测开始,该猜测采用简约的参数化方法（例如,将所有θ值设置为接近于零）。在优化算法的每一步中,参数猜测值会逐步更新,以减少训练样本中的预测误差。每次更新猜测值时,也会对验证样本进行预测,当验证样本的误差开始增加时,优化过程终止。这通常发生在训练样本的预测误差最小化之前,因此得名“提前停止”（参见互联网附录B.3中的算法6）。通过提前结束参数搜索,参数值会逐渐向初始猜测值收缩。由于它以更低的计算成本实现了正则化,因此是θ参数l2惩罚的常用替代方案。<sup>24</sup>提前停止可以单独使用,也可以与l1正则化结合使用,正如我们在本文中所做的那样。

“批量归一化”（Ioffe 和 Szegedy,2015)是一种简单的技术,用于控制网络中不同区域预测变量的变异性。

---

23 与之相关的是,在每次 SGD 迭代中进行随机子集划分会给优化过程增加噪声,而噪声本身就起到了一种正则化的作用。参见 Wilson 和 Martinez (2003)。

24 由于仅进行部分优化,提前停止算法的计算成本相对较低;而L2正则化（或更一般的弹性网络)搜索调整参数时,会针对每个调整参数猜测值对模型进行完全优化。通常,弹性网络的L1 惩罚项会促使神经元连接到有限数量的其他神经元,而其L2 惩罚项则会将权重参数向零收缩（神经网络文献中称之为“权重衰减”）。在某些情况下,提前停止算法和权重衰减算法被证明是等价的。例如,参见 Bishop (1995) 和 Goodfellow、Bengio 和 Courville (2016)。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



该方法适用于不同的数据集。其动机源于内部协变量偏移现象,即隐藏层的输入与验证样本中的对应输入服从不同的分布。在拟合包含众多参数和复杂结构的深度神经网络时,经常会遇到这个问题。对于每个训练步骤（“批次”）中的每个隐藏单元,该算法会进行横截面去均值和方差标准化,以恢复该单元的表征能力。

最后,我们采用集成方法来训练神经网络（另见 Hansen 和 Salamon 1990;Dietterich 2000）。具体而言,我们使用多个随机种子来初始化神经网络估计,并通过对所有网络的预测结果取平均值来构建预测结果。这降低了预测方差,因为优化的随机性可能导致不同的种子产生不同的预测结果。<sup>25</sup>

1.8 性能评估为了评估个股超额收益预测

的预测性能,我们计算样本外$R^2$值。

$$R2_{oos} = 1 - \frac{\sum_{(i,t)\in T3} (r_{i,t+1} - r_{i,t+1})^2}{\sum_{(i,t)\in T3} r_{i,t+1}^2}, \quad (19)$$

其中， T3表示仅对测试子样本进行拟合评估,该子样本的数据不会用于模型估计或调优。R2将各公司和不同时间段的预测误差汇总,从而对每个模型进行总体面板层面的评估。 oos

我们$R^2$指标的一个微妙但重要的方面是,其分母是未进行降级处理的超额收益平方和。在许多样本外预测应用中,预测值会与历史平均收益进行比较。虽然这种方法对于综合指数或多空投资组合等情况来说是合理的,但在分析个股收益时却存在缺陷。用历史平均值来预测未来的股票超额收益,其表现通常远逊于直接预测为零。

也就是说,历史平均股票收益率波动较大,人为地降低了“良好”预测性能的标准。我们通过将$R^2$ 值与零预测值进行比较来避免这一陷阱。为了说明这一选择的重要性,当我们以历史平均股票收益率作为模型预测的基准时,所有方法的样本外月度$R^2$ 值都提高了约三个百分点。

为了对不同方法进行两两比较,我们使用 Diebold 和 Mariano (1995) 检验来比较两个模型在样本外预测准确率上的差异。<sup>26</sup>虽然收益率的时间序列依赖性足够弱,但它

25 使用不同种子进行估计可以独立并行运行,从而限制增量计算时间。

26 正如 Diebold (2015) 所强调的那样,Diebold-Mariano 检验的无模型性质意味着它应该被解释为预测的比较,而不是“完全阐述的计量经济模型”的比较。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



由于横截面数据可能存在强相关性,Diebold-Mariano检验所依据的弱误差相关性条件不太可能适用于我们的股票层面分析。我们对Diebold-Mariano检验进行了调整,使其适用于我们的场景,方法是比较每个模型预测误差的横截面平均值,而不是比较单个收益率之间的误差。更准确地说,为了检验方法（1)与方法（2)的预测性能,我们定义检验统计量DM12 =d¯ 12/σd¯ ,其中

$$d_{12,t+1} = \frac{1}{n_{3,t+1}} \sum_{i=1}^{n_{3,t+1}} e_{(1)i,t+12} - e_{(2)i,t+12}, \tag{20}$$

$e_{i,t+1}^{(1)}$ 和 $e_{i,t+1}^{(2)}$ 用 表示使用每种方法对股票 i 在时间 t 的收益率的预测误差， $n_{3,t+1}$表示测试样本（t+1年)中的股票数量。d¯ 和σd¯分别表示$d_{12,t}$在测试样本上的均值和 Newey-West 标准误差。这种改进的 Diebold-Mariano 检验统计量基于自相关性很小的单一时间序列误差差$d_{12,t+1}$ ,更有可能满足渐近正态性所需的温和正则性条件,从而为我们的模型比较检验提供合适的 p 值。

1.9 变量重要性和边际关系我们解释机器学习模型的目标很简单。我们旨在识别对预期收益横截面有重要影响的协变量,同时控制系统中的许多其他预测因子。

我们根据变量重要性的概念对协变量进行排序,从而发现有影响力的协变量,我们将第 j 个输入变量的重要性表示为 VIj。

我们考虑两种不同的重要性概念。第一种是将所有预测变量 j 的值设为零,同时保持其余模型估计值不变时,面板预测$R^2$ 的降低量（例如,Kelly、Pruitt 和 Su (2019) 在降维的背景下使用了该概念）。第二种概念由 Dimopoulos、Bourret 和 Lek (1995) 在神经网络文献中提出,是模型对每个输入变量 j 的偏导数平方和 (SSD),它概括了模型拟合对该变量变化的敏感性。<sup>27</sup>

27 具体而言,SSD 将第j个变量的重要性定义为

$$SSDj = \sum_{i,t\in T1} \left( \frac{\partial g(z;\theta)}{\partial z_j} \Big|_{z=z_{i,t}} \right)^2,$$

其中,为方便起见,导数分母中的zj表示输入变量向量的第j 个元素。我们在训练集T1 内测量 SSD。需要注意的是,由于基于树的模型中存在不可微性,Dimopoulos、Bourret 和 Lek (1995) 的方法并不适用。因此,在进行第二次变量重要性分析时,我们使用平均不纯度下降值（例如,参见 Friedman 2001)来测量随机森林和提升树的变量重要性。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



作为分析的一部分,我们还绘制了预期收益与每个特征之间的边际关系。尽管存在明显的局限性,但这种图表是可视化机器学习模型中协变量的一阶影响的有效工具。

## 2. 美国股票的实证研究

### 2.1 数据和总体模型我们从 CRSP 获取了纽约

证券交易所 (NYSE)、美国证券交易所 (AMEX) 和纳斯达克 (NASDAQ) 所有上市公司的月度个股总收益率。我们的样本始于 1957 年 3 月（标普 500 指数的起始日期），止于 2016 年 12 月,共计 60 年。样本中的股票数量接近 30,000 只,平均每月股票数量超过 6,200 只。28我们还获取了国库券利率作为无风险利率的代理变量,并以此计算个股超额收益。

此外,我们基于股票收益横截面文献构建了一个包含大量股票层面预测特征的数据集。这些特征包括94个<sup>29</sup>（其中61个按年更新,13个按季度更新,20个按月更新）。此外,我们还纳入了74个行业虚拟变量,这些变量对应于标准行业分类（SIC)代码的前两位数字。互联网附录中的表A.6提供了这些特征的详细信息<sup>30</sup>。

我们还根据 Welch 和 Goyal (2008) 中详述的变量定义构建了八个宏观经济预测因子,包括股息价格比率 (dp)、市盈率 (ep)、账面市值比率 (bm)、净权益扩张 (ntis)、国库券利率 (tbl)、期限利差 (tms)、违约利差 (dfy) 和股票方差 (svar)。<sup>31</sup>

我们考虑的所有机器学习方法都是为了近似方程 (2) 中定义的总体经验模型 $E_t(r_{i,t+1}) = g(z_{i,t})$ 。

---

28 我们纳入了股价低于 5 美元、股票代码为 10 或 11 以上的股票以及金融公司。我们选择尽可能大的资产池至少有三个重要原因。首先,这些常用的筛选条件会剔除标普 500 指数成分股中的某些股票,而我们认为从资产定价分析中排除这些重要股票显然是不妥的。此外,由于我们将个股收益预测汇总以预测指数,因此我们不能忽略这些股票。其次,我们的结果不易受到文献（例如 Lo 和 MacKinlay,1990)所警告的样本选择偏差或数据窥探偏差的影响。第三,使用更大的样本有助于提高观测值与参数值的比率,从而避免过拟合。即便如此,如果我们剔除这些公司,我们的结果在性质上仍然相同,在数量上也保持不变。

29 我们按时期对所有股票特征进行横截面排名,并按照 Kelly、Pruitt 和 Su (2019) 以及 Freyberger、Neuhierl 和 Weber (2020) 的方法将这些排名映射到 [-1,1] 区间。

30 这94个预测特征基于Green等人（2017)的研究,我们采用了Jeremiah Green网站上提供的SAS代码,并将样本期扩展至1957年。我们的数据构建方式与之前的文献有所不同,我们更严格地遵循了原始论文中的变量定义。例如,我们按照Fama和French（2015)的方法构建了账面权益比和营业利润率。这些特征大多存在一定的延迟。为了避免前瞻性偏差,我们假设月度特征最多延迟1个月,季度特征至少延迟4个月,年度特征至少延迟6个月。因此,为了预测t+1个月的收益率,我们使用t月末的最新月度特征、 t-4月末的最新季度数据以及t- 6月末的最新年度数据。另一个问题是特征缺失,我们用每只股票在每个月的横截面中位数来填补这些缺失值。

31 每月数据可从 Amit Goyal 的网站上获取。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



在整个分析过程中,我们定义了股票层面协变量的基准集。
zi,t作为

$$z_{i,t} = x_t \otimes c_{i,t}, \tag{21}$$

其中， $c_{i,t}$是一个$P_c \times 1$ 的矩阵,表示每只股票 i 的特征； $x_t$是一个$P_x \times 1$ 的向量,表示宏观经济预测因子（因此所有股票都包含这些因子,包括一个常数）。因此， $z_{i,t}$是一个 $P \times 1$ 的向量,表示用于预测个股收益的特征（其中 $P = P_c P_x$ ）,并且包含了股票层面特征与宏观经济状态变量之间的交互作用。协变量的总数为 $94 \times (8+1)+74 = 920$。

由（2)和（21)规定的总体模型嵌套了文献中提出的许多模型（Rosenberg 1974;Harvey 和 Ferson 1999 等）。
该模型结构的激励性例子是资产定价条件欧拉方程的标准贝塔定价表示，

$$E_t(r_{i,t+1}) = \beta_{i,t} \lambda_t 。 \tag{22}$$

我们特征集的结构（21)允许纯粹的股票层面信息通过$c_{i,t}$进入预期收益,类似于风险敞口函数$\beta_{i,t}$ ,也允许总体经济状况进入,类似于动态风险溢价$\lambda_t$ 。

特别地,如果对于某些常数参数矩阵$\theta_1$ ($K \times P_c$)和$\theta_2$ ($K \times P_x$ ),有$\beta_{i,t} = \theta_1 c_{i,t}$ ,且$\lambda_t = \theta_2 x_t$ ,则式(22)中的beta定价模型变为

$$g(z_{i,t}) = E_t(r_{i,t+1}) = \beta_{i,t} \lambda_t = c_{它} \theta_1 \theta_2 x_t = x_t \otimes c_{i,t} \, vec(\theta_1 \theta_2) =: z_{它} \theta, \tag{23}$$

其中 $\theta = vec(\theta_1 \theta_2)$。总体模型比此示例更具通用性,因为 $g(\cdot)$ 不限于线性函数。例如,考虑非线性 $g(\cdot)$ 公式，例如通过广义线性模型或神经网络,本质上扩展了特征集,使其包含基线$z_{i,t}$预测器集的各种函数变换。

我们将60年的数据分为三部分:18年的训练样本（1957-1974年）、12年的验证样本（1975-1986年)以及剩余的30年（1987-2016年)用于样本外测试。由于机器学习算法计算量巨大,我们避免每月递归地重新拟合模型。

相反,我们每年重新拟合一次模型,因为我们的大部分信号每年更新一次。每次重新拟合时,我们将训练样本增加一年。验证样本的大小保持不变,但向前滚动,使其包含最近 12 个月的数据。<sup>32</sup>

2.2 个股横截面分析表 1 展示了机器学习技术在样本外预测
$R^2$ 方面的比较。我们总共比较了 13 个模型,其中包括

32 我们不使用交叉验证来保持数据的时间顺序。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

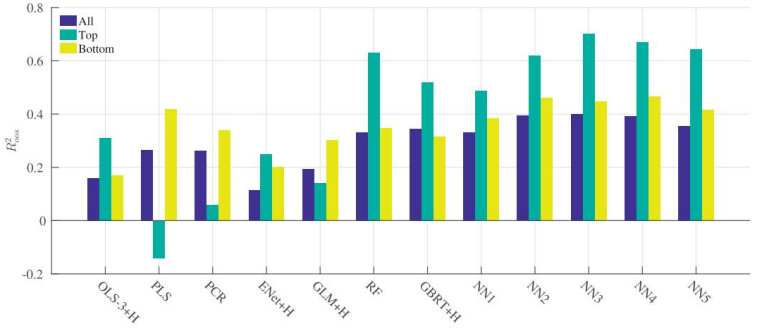
Machine Translated by Google



表1

月度样本外股票水平预测表现（R2 oos 百分比）

| | OLS +H | OLS-3 +H | PLS | PCR | ENet +H | GLM +H | RF | GBRT +H | NN1 | NN2 | NN3 | NN4 | NN5 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| All | −3.46 | 0.16 | 0.27 | 0.26 | 0.11 | 0.19 | 0.33 | 0.34 | 0.33 | 0.39 | 0.40 | 0.39 | 0.36 |
| Top 1,000 | −11.28 | 0.31 | −0.14 | 0.06 | 0.25 | 0.14 | 0.63 | 0.52 | 0.49 | 0.62 | 0.70 | 0.67 | 0.64 |
| Bottom 1,000 | −1.30 | 0.17 | 0.42 | 0.34 | 0.20 | 0.30 | 0.35 | 0.32 | 0.38 | 0.46 | 0.45 | 0.47 | 0.42 |




本表报告了使用所有变量的普通最小二乘法（OLS）、仅使用市值、账面市值比和动量的普通最小二乘法（OLS-3）、偏最小二乘法（PLS）、PCR、弹性网络（ENet）、广义线性模型（GLM）、随机森林（RF）、梯度提升回归树（GBRT)以及1至5层神经网络（NN1–NN5)计算得到的整个股票面板的月度$R^2$值。“+H”表示使用Huber损失函数而非l2损失函数。我们还报告了仅包含市值排名前1000或后1000的股票的$R^2$子样本。下方面板提供了$R^2$值的直观比较。

oos 之内

oos 表格中的统计数据（由于 OLS 的负值较大,因此省略了 OLS）。

我们采用了以下几种回归模型:包含所有协变量的普通最小二乘法 (OLS)、仅预选规模、账面市值比和动量作为协变量的 OLS-3、偏最小二乘法 (PLS)、聚合回归 (PCR)、弹性网络 (ENet)、带分组套索的广义线性模型 (GLM)、随机森林 (RF)、梯度提升回归树 (GBRT) 以及一至五层的神经网络架构 (NN1,...,NN5)。对于 OLS、ENet、GLM 和 GBRT,我们提出了使用 Huber 损失的稳健版本,其性能优于未使用 Huber 损失的版本。

表 1 的第一行报告显示,使用全部 920 个特征的$_{oos}$ 对于整个合并样本,OLS值为-3.46%,表明其$R^2$模型得到的$R^2$值明显低于对所有股票所有月份均应用零预测值的$_{oos}$ 为
简单预测。这可能并不令人意外,因为缺乏正则化使得 OLS 模型极易出现样本内过拟合。然而,通过限制 OLS 模型的参数化程度,例如强制模型仅包含三个协变量（规模、价值和动量）,或者使用弹性网络对模型进行惩罚,可以显著改善完整的 OLS 模型（$R^2$分别为 0.16% 和 0.11%）。图 3 总结了每个模型在每次重新估计日期的复杂度。左上角面板显示了弹性网络赋予非零载荷的特征数量。在测试样本的前 10 年中,模型通常选择少于 5 个特征。在 2000 年之后,所选特征的数量增加并稳定在 20 到 40 个之间。

oos

通过降维对线性模型进行正则化可以进一步提高预测精度。通过构建预测变量的几个线性组合,PLS 和



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



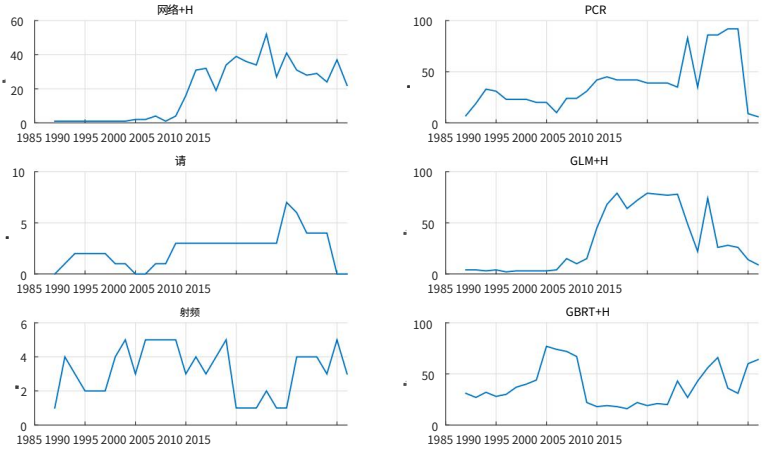



图 3 时变
模型复杂度该图展示了弹性网络
(ENet)、PCR、PLS、带分组套索的广义线性模型 (GLM)、随机森林 (RF) 和梯度提升回归树 (GBRT) 在我们 30 年递归样本外分析的每个训练样本中的模型复杂度。对于 ENet 和 GLM,我们报告了被选中且具有非零系数的特征数量;对于 PCR 和 PLS,我们报告了被选中的成分数量;对于 RF,我们报告了平均树深度;对于 GBRT,我们报告了进入树的不同特征的数量。

特别是 PCR,分别将样本外R2提高到 0.27% 和 0.26%。
图 3 显示,PCR 通常在其预测中使用 20 到 40 个成分。
另一方面,PLS方法在早期样本的大部分区域未能找到单一可靠的成分,但最终确定了三到六个成分。通过弹性网络进行变量选择后,降维效果优于其他方法,这表明特征存在部分冗余,且本质上是噪声信号。将它们组合成低维成分可以平均噪声,从而更好地揭示其相关信号。

带有分组 Lasso 惩罚的广义线性模型未能提升纯线性方法的性能（$R^2$为 0.19%）。该方法虽然使用了单个特征的样条函数,但并未考虑特征间的交互作用,这表明单变量扩展在线性模型的基础上几乎没有提供任何增量信息。尽管它倾向于选择比弹性网络更多的特征,但这些额外的特征并未转化为性能的提升。

提升树和随机森林与PCR相比具有竞争力,拟合准确率分别为0.34%和0.33%。随机森林通常估计较浅的树,平均只有一到五层。为了量化GBRT的复杂度,我们报告了每次重估计时提升树集成中使用的特征数量。在样本初期,GBRT使用大约30个特征来划分结果,之后特征数量增加到50个。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



神经网络是性能最佳的非线性方法,也是整体预测效果最好的模型。NN1的$R^2$为 0.33%,NN3 的 $R^2$ 最高,达到 0.40%。 oos
这些结果表明,纳入复杂的预测变量交互作用具有重要价值,这些交互作用嵌入在树模型和神经网络模型中,但其他技术却忽略了它们。结果还显示,在月度收益率的背景下,“深度”学习的优势有限,因为四层和五层模型未能超越 NN3.33。表 1 的第二行和第三行分别列出了大型股票(每月市值排名前 1000 的股票)和小型股票(每月市值排名后 1000 的股票)的预测能力。这是基于完整的估计模型(使用所有股票)得出的,但重点关注两个子样本之间的拟

合情况。OLS 表现不佳、正则化线性模型有所改进、非线性模型占主导地位的基准模式也适用于子样本。树方法和神经网络在大型股票中表现尤为出色, $R^2$ 值介于 0.52% 至 0.70% 之间。这种二分法表明,机器学习并非仅仅捕捉到由流动性不足导致的小规模效率低下。<sup>34</sup>表2以年度为时间跨度进行分析。不同方法之间的比较表现与表1所示的月度结果类似,但预测年度收益的年度R<sup>2 </sup>同样表明,机器学习模型能够识别出持续存在于商业周期频率中的风险溢价,而不仅仅是捕捉到短暂的效率低下。

oos

oos 几乎大了一个数量级。他们的成功

表 1 对模型的预测性能进行了定量比较,而表 3 则评估了模型间在月度频率上的统计显著性差异。它报告了列模型与行模型两两比较的 Diebold-Mariano 检验统计量。在模型间无差异的零假设下,Diebold-Mariano 统计量服从正态分布 N(0,1),因此检验统计量的大小与 p 值之间的关系与回归 t 统计量相同。我们的符号约定是:正的统计量表示列模型优于行模型。粗体数字表示每个检验在 5% 的显著性水平上具有统计学意义。

表3得出的第一个结论是,约束线性模型(包括将OLS限制为仅使用三个预测变量、通过PLS或PCA降维以及通过弹性网络进行惩罚)相比于非约束OLS模型,均能带来统计学意义上的显著改进。其次,我们发现惩罚线性方法和降维方法的性能差异很小。第三,我们发现基于树的方法普遍能够提升模型性能。

33 因为我们将五种神经网络架构固定下来,并简单地对它们进行比较,所以我们没有在图 3 中描述它们的估计复杂度。

34 顺便一提,值得注意的是,如果以历史平均值作为基准,样本外$R^2$ 值大约会膨胀 3%。对于 OLS-3 模型,相对于历史平均预测值的$R^2$值每月高达 3.74%!显然,历史平均值预测值波动性极大,甚至很容易被零超额收益的固定预测值所超越。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

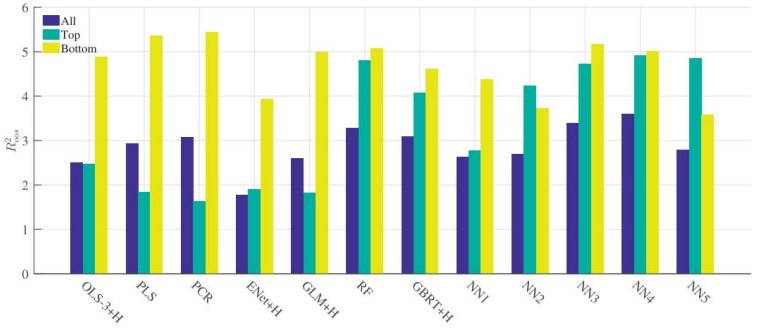
Machine Translated by Google



表2

年度样本外股票水平预测表现（R2 oos 百分比）

| | OLS +H | OLS-3 +H | PLS | PCR | ENet +H | GLM +H | RF | GBRT +H | NN1 | NN2 | NN3 | NN4 | NN5 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| All | −34.86 | 2.50 | 2.93 | 3.08 | 1.78 | 2.60 | 3.28 | 3.09 | 2.64 | 2.70 | 3.40 | 3.60 | 2.79 |
| Top | −54.86 | 2.48 | 1.84 | 1.64 | 1.90 | 1.82 | 4.80 | 4.07 | 2.77 | 4.24 | 4.73 | 4.91 | 4.86 |
| Bottom | −19.22 | 4.88 | 5.36 | 5.44 | 3.94 | 5.00 | 5.08 | 4.61 | 4.37 | 3.72 | 5.17 | 5.01 | 3.58 |




年度收益率预测R2 oos （参见表 1 的图例）。

表3

使用 Diebold-Mariano 检验对月度样本外预测进行比较

| | OLS-3 +H | PLS | PCR | ENet +H | GLM +H | RF | GBRT +H | NN1 | NN2 | NN3 | NN4 | NN5 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| OLS+H | 3.26 | 3.29 | 3.35 | 3.29 | 3.28 | 3.29 | 3.26 | 3.34 | 3.40 | 3.38 | 3.37 | 3.38 |
| OLS-3+H | | | 1.42 | 1.87 | −0.27 | | 0.62 | 1.64 | 1.28 | | 1.25 | 2.13 | 2.13 | | 2.36 | 2.11 |
| 请 | | | | −0.19 | −1.18 | −1.47 | 0.87 | | | 0.67 | | 0.63 | 1.32 | 1.37 | | 1.66 | 1.08 |
| PCR | | | | | −1.10 | −1.37 | 0.85 | | | 0.75 | 0.58 | 1.17 | 1.19 | 1.34 | 1.00 | | |
| 网络+H | | | | | | | 0.64 | 1.90 | 1.40 | 1.73 | 1.97 | 2.07 | 1.98 | 1.85 | | | |
| GLM+H | | | | | | | | 1.76 | 1.22 | 1.29 | 2.28 | 2.17 | 2.68 | 2.37 | | | |
| 射频 | | | | | | | | | | 0.07 | −0.03 | 0.31 | 0.37 | 0.34 | 0.00 | | |
| GBRT+H | | | | | | | | | | | −0.06 | 0.16 | 0.21 | 0.17 | −0.04 | | |
| NN1 | | | | | | | | | | | | 0.56 | 0.59 | 0.45 | 0.04 | | |
| NN2 | | | | | | | | | | | | | 0.32 | −0.03 | −0.88 | | |
| NN3 | | | | | | | | | | | | | | −0.32 | −0.92 | | |
| NN4 | | | | | | | | | | | | | | | −1.04 | | |

该表报告了成对的迪博尔德-马里亚诺检验统计量，用于比较样本外股票水平预测。
十三种模型的性能比较。正数表示列模型优于行模型。
粗体字表示单个测试中差异显著（显著性水平为 5% 或更高），星号表示
通过我们保守的 Bonferroni 调整，12 项比较的显著性水平为 5%。

与线性模型相比，改进效果充其量也只是略微显著。
神经网络是唯一能够产生大量显著结果的模型。
与线性模型和广义线性模型相比，统计性能有所提升。它们也
比树模型有所改进，但差异在统计学上并不显著。

表3进行了多项比较。我们重点阐述了推断是如何变化的。
采用保守的 Bonferroni 多重比较校正方法，将……



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



显著性水平取决于比较次数。<sup>35</sup>对于 12 次模型比较,显著性水平为 5% 的情况,我们设定的调整后单侧临界值为 2.64。表中,超过此保守阈值的检验结果均标有星号。与 Bonferroni 校正的主要区别在于,神经网络相对于惩罚线性模型而言,其显著性仅略微降低。

### 2.3 哪些协变量比较重要?

现在,我们使用第 1.9 节中描述的重要性度量方法,来研究各个协变量对每个模型性能的相对重要性。首先,对于每种方法,我们计算在每个训练样本中将给定预测变量的所有值设为零后$R^2$的降低值,并将这些降低值平均,得到每个预测变量的单一重要性度量。图 4 显示了每种方法中前 20 个股票层面特征的重要性度量结果。

模型中的变量重要性被标准化为总和为 1,从而可以解释该特定模型的相对重要性。

图 5 显示了所有模型特征的总体排名。我们对每种方法中每个特征的重要性进行排名,然后将它们的排名相加。
特征按总排名顺序排列,总排名最高的特征位于顶部,排名最低的特征位于底部。每列中的颜色渐变显示了模型特定的特征排名,从最不重要到最重要(从最浅到最深)。<sup>36</sup>

图 4 和图 5 表明,各模型在最具影响力的个股层面预测因子方面总体上高度一致,这些因子可分为四类。第一类基于近期价格趋势,包括图 5 中排名前七的变量中的五个:短期反转(mom1m)、个股动量(mom12m)、动量变化(chmom)、行业动量(indmom)、近期最大收益(maxret)和长期反转(mom36m)。第二类是流动性变量,包括换手率和换手率波动率(turn、SD_turn)、对数市值(mvel1)、美元成交量(dolvol)、Amihud 流动性不足指数(ill)、零交易日数(zerotrade)和买卖价差(baspread)。第三类具有影响力的指标是风险指标,包括总收益波动率和特质收益波动率(retvol、idiovol)、市场贝塔系数(beta)和贝塔系数平方(betasq)。

最后一组包括估值比率和基本面信号,例如市盈率(ep)、市销率(sp)、资产增长率(agr)和股票数量。

---

35 当研究者进行大量假设检验,却仅基于显著性结果得出结论时,多重比较便成为一个值得关注的问题。这样做会因选择性偏差而扭曲检验的有效性。因此,我们报告每次比较的t统计量,但同时报告调整后的推断值,以求更加谨慎。

我们还注意到,多重比较中的错误发现应该是随机分布的。然而,我们分析中具有统计学意义的t统计量并非随机分布,而是遵循一种模式,即非线性模型优于线性模型。

36 图 5 基于超过 30 个递归训练样本的平均排名。网络附录中的图 A.1 分别展示了每个递归样本的排名。重要特征(协变量的前三分之一)的排名随时间推移表现出显著的稳定性。所有模型均如此,但出于篇幅考虑,我们仅展示了一个代表性模型(NN3)的结果。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



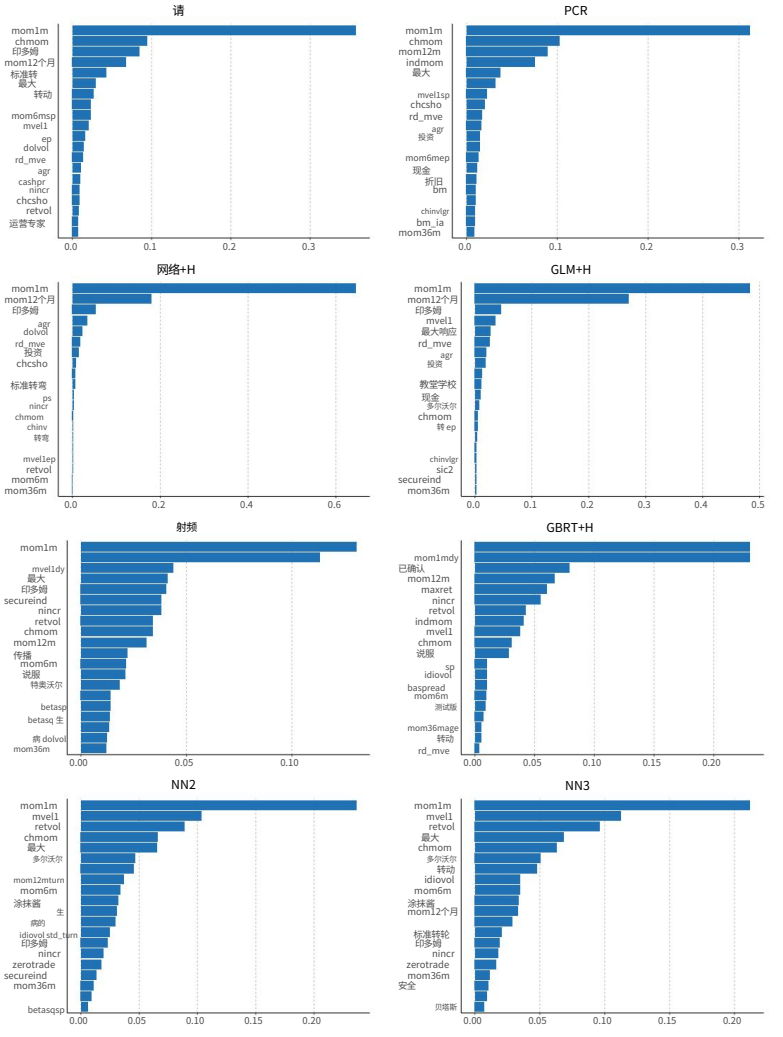



图 4
模型中的变量重要性
每个模型中最具影响力的前 20 个变量的变量重要性。变量重要性是平均值。
在所有训练样本中,每个模型内的变量重要性均被归一化,使其总和为 1。

近期收益增长（nincr）。图 4 显示了特征重要性
惩罚线性模型和降维模型的量级为
高度偏向动量和反转。树和神经网络
更具民主性,从更广泛的数据集中提取预测信息
特征。

我们发现,我们第二个衡量变量重要性的指标,即 SSD,
Dimopoulos、Bourret 和 Lek (1995) 的研究结果与此非常相似。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google






图 5

特征重要性

根据整体模型对 94 个股票层面特征和行业虚拟变量 (sic2) 进行排名
贡献度。特征根据其在所有模型中的排名总和进行排序，最具影响力的特征排名靠前。
特征列于顶部，影响最小的特征列于底部。各列对应不同的模型。
每列中的颜色渐变表示影响力从最大（深蓝色）到最小（白色）不等。
变量。

更简单的$R^2$度量。在每个模型中，我们计算皮尔逊相关系数。
SSD相对重要性与$R^2$值之间存在相关性。
范围从低端的 84.0% (NN1) 到高端的 97.7% (随机)。
森林）。也就是说，这两种方法对哪一种森林都给出了高度一致的总结？
变量对预测准确性影响最大。图 A.2（互联网）
附录展示了完整的 SSD 结果集。



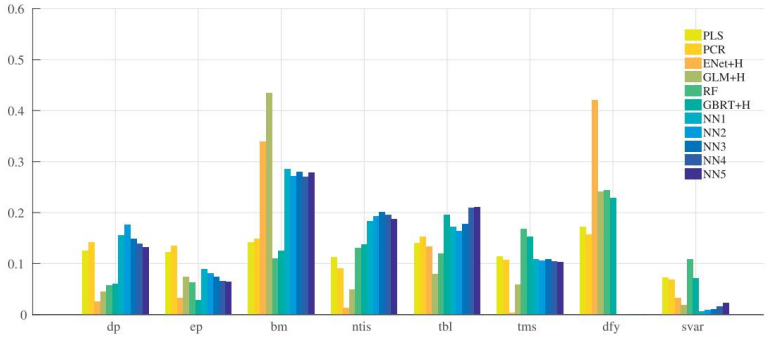
本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



表4
宏观经济预测变量的重要性

| | PLS | PCR | ENet+H | GLM+H | RF | GBRT+H | NN1 | NN2 | NN3 | NN4 | NN5 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| dp | 12.52 | 14.12 | 2.49 | 4.54 | 5.80 | 6.05 | 15.57 | 17.58 | 14.84 | 13.95 | 13.15 |
| ep | 12.25 | 13.52 | 3.27 | 7.37 | 6.27 | 2.85 | 8.86 | 8.09 | 7.34 | 6.54 | 6.47 |
| bm | 14.21 | 14.83 | 33.95 | 43.46 | 10.94 | 12.49 | 28.57 | 27.18 | 27.92 | 26.95 | 27.90 |
| ntis | 11.25 | 9.10 | 1.30 | 4.89 | 13.02 | 13.79 | 18.37 | 19.26 | 20.15 | 19.59 | 18.68 |
| tbl | 14.02 | 15.29 | 13.29 | 7.90 | 11.98 | 19.49 | 17.18 | 16.40 | 17.76 | 20.99 | 21.06 |
| tms | 11.35 | 10.66 | 0.31 | 5.87 | 16.81 | 15.27 | 10.79 | 10.59 | 10.91 | 10.38 | 10.33 |
| dfy | 17.17 | 15.68 | 42.13 | 24.10 | 24.37 | 22.93 | 0.09 | 0.06 | 0.06 | 0.04 | 0.12 |
| svar | 7.22 | 6.80 | 3.26 | 1.87 | 10.82 | 7.13 | 0.57 | 0.85 | 1.02 | 1.57 | 2.29 |




每个模型中八个宏观经济变量的重要性。变量重要性是所有训练样本的平均值。每个模型内的变量重要性均已归一化，使其总和为 1。下图提供了宏观经济变量重要性的补充可视化比较。

为了验证结果的稳健性，我们使用包含五个安慰剂“特征”的扩展特征集重新运行了分析。这些特征根据互联网附录A中的数据生成过程 (A.1) 进行模拟。这些参数经过校准，使其行为与我们的特征数据集相似，但根据构建方式与未来收益无关。互联网附录 F 中的图 A.3 展示了变量重要性图（基于$R^2$），其中突出显示了五个噪声特征。该表证实，我们在主要分析中识别出的最具影响力的特征不受无关特征的影响。噪声变量与罪恶股票、股息发放/取消、现金流波动性和其他会计变量一起，出现在信息量最小的特征之列。

表 4 显示了每个宏观经济预测变量的基于 R2 的重要性度量（同样，在给定的模型中，所有变量之和为 1 已归一化）。
所有模型都一致认为，总账面市值比是一个关键的预测因子，而市场波动性在任何模型中都几乎不起作用。PLS 和 PCR 对所有其他预测因子赋予相似的权重，这可能是因为这些变量高度相关。线性模型和广义线性模型强烈偏爱债券市场变量，包括违约利差和国债利率。非线性方法（决策树和神经网络）则格外重视线性方法忽略的那些预测因子，例如期限利差和发行活动。

许多会计特征无法以月度频率获取，这或许可以解释它们在图 5 中的重要性较低。为了探究这一点，



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



网络附录中的图 A.6展示了基于年度收益预测的变量排名。价格趋势变量的重要性相对于流动性和风险指标有所下降,但仍然具有相当大的影响力。在月度预测周期内排名后半段的特征,在年度预测周期内仍然基本不重要。唯一的例外是行业（sic2）,它在年度频率下表现出显著的预测能力。

2.3.1 特征与预期收益之间的边际关联性..
图 6 展示了模型隐含的各项特征对预期超额收益的边际影响。我们的数据转换将特征值标准化到 (-1,1) 区间,并将所有其他变量固定为其中位数零。图中我们选取了四个示例性特征,包括规模 (mvel1)、动量 (mom12m)、股票波动率 (retvol) 和应计项目 (acc)。

首先,图 6 显示机器学习方法识别出的模式与一些众所周知的经验现象相似。例如,预期股票收益率随公司规模的增加而降低,随过去一年收益率的增加而增加,随股票波动性的增加而降低。有趣的是,所有方法都一致认为应计项目与未来收益率之间几乎不存在任何关系。其次,（惩罚的）线性模型发现收益率与公司规模或波动性之间均无预测关联,而决策树和神经网络则发现预期收益率对这两个变量都非常敏感。例如,根据 NN3 的预测,一家公司如果从公司规模的中位数下降到规模分布的第 20 个百分位数,其年化预期收益率将增加约
2.4%（0.002×12×100）;而一家公司的波动性如果从中位数上升到第 80 个百分位数,其预期收益率每年将下降约 3.0%。这些方法检测到了非线性预测关联。线性模型无法捕捉非线性,这可能导致它们倾向于零关联,这可以部分解释线性方法和非线性方法性能上的差异。

2.3.2 交互效应。决策树和神经网络的良好表现表明,允许预测变量之间存在潜在的复杂交互作用是有益的。机器学习模型通常被称为“黑箱”,但从某种意义上说,这种说法并不准确,因为这些模型是可以很容易地进行检查的。然而,它们确实很复杂,这既是它们强大功能的原因,也是它们难以理解的原因。任何对交互效应的探索都会受到交互预测变量的身份和函数形式的巨大可能性的困扰。在本节中,我们将展示一些交互结果,以帮助说明一种黑箱方法 NN3模型的内部运作机制。

首先,我们考察 NN3 中的一组成对交互效应。图 7 展示了在保持所有其他变量固定为中位数零的情况下,当我们同时改变一对特征在其支持区间 [-1,1] 内的值时,预期收益如何变化。我们展示了以下交互作用:



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



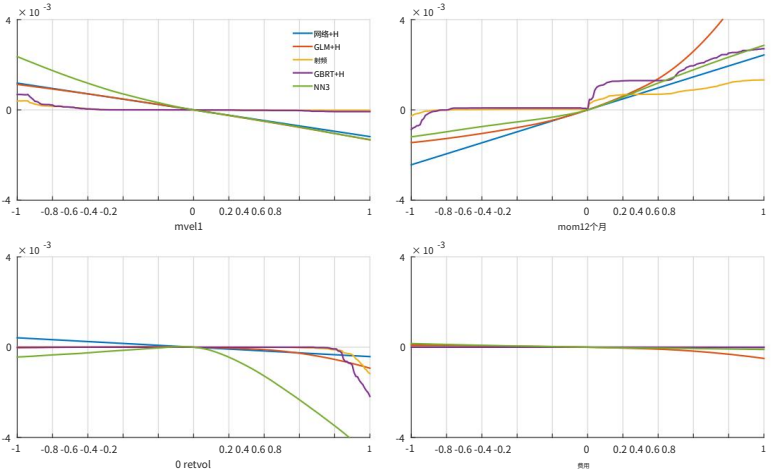



图 6
预期收益与特征之间的边际关联
图表应显示预期月度百分比收益率（纵轴)对个人的敏感性
特征（将所有其他协变量固定为其中位数）。

股票规模（mvel1)与其他四个预测因子:短期反转（mom1m），
动量（mom12m）、总波动率和特质波动率（retvol 和 retvol）。
分别为idiovol）。

左上图显示,短期逆转效应最为显著。
在小盘股中,这种关系基本呈线性（蓝线）。在大盘股中……
（绿线）,反转呈凹形,主要发生在上个月
收益为正。右上角的图显示了动量效应,即
在NN3模型中,大型股票的表现最为显著。37同样,在
在左下角,我们看到低波动性异常也最为显著。
大型股票。对于小型股票,波动率效应呈驼峰状。最后，
右下角显示,NN3 估计大小之间不存在交互作用。
以及应计项目　规模线只是单变量应计项目的垂直平移。
曲线。

图 8 展示了库存水平特征与
宏观经济指标变量。例如,它显示了规模效应。
当总体估值较低（bm较高)时,这种现象更为明显；
股权发行量（ntis)较低,而低波动性异常现象尤为突出。
在高估值和高发行环境下表现强劲。图 A.4
互联网附录列出了股票最重要的100次互动。
每个机器学习的特征都具有宏观经济指标
模型。最具影响力的特征来自于与股票近期走势的交互作用。

37 我们的模型得出的结论可能与文献中的结果有所不同,因为我们对数百个模型进行了联合建模。
预测变量,可以得出关于边际效应、交互效应等的新结论。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



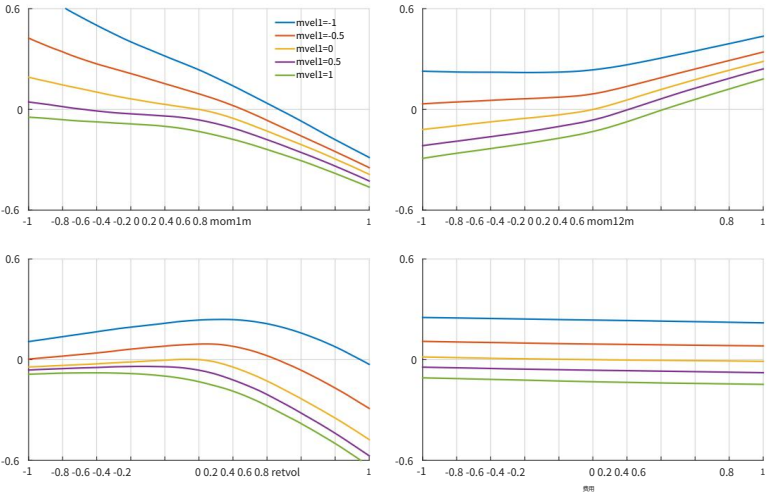



图 7
预期收益和特征交互作用（NN3）
各面板应显示预期月度百分比收益率（纵轴)对交互作用的敏感性
在模型 NN3 中,mvel1 与 mom1m、mom12m、retvol 和 acc 存在效应（所有其他协变量均固定）。
（它们的中位数）。

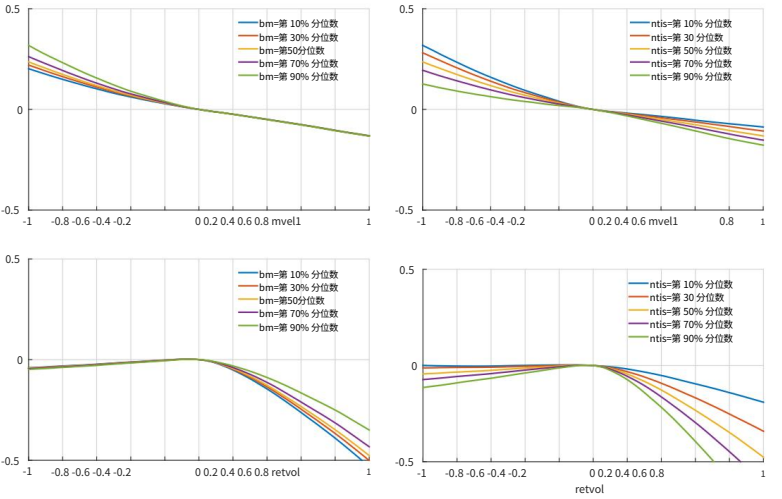



图 8
预期收益与特征/宏观经济变量的交互作用（NN3）
图表显示了预期月度百分比收益率（纵轴)对交互效应的敏感性
mvel1 和 retvol 与 bm 和 ntis 在模型 NN3 中（将所有其他协变量固定为其中值）。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



价格趋势（例如,动量、短期反转或行业动量)与总体资产价格水平（例如,整体股票市场的估值比率或国库券利率)密切相关。此外,主要的宏观经济互动随时间推移保持稳定,如图A.5（见网络附录)所示。

2.4 投资组合预测到目前为止,我

们已经分析了个股收益的可预测性。接下来,我们将比较机器学习方法对整体投资组合收益的预测性能。在投资组合层面分析预测结果具有诸多优势。

首先,由于我们所有的模型都针对个股层面的预测进行了优化,因此投资组合预测可以间接地评估模型及其稳健性。其次,总体投资组合往往具有更广泛的经济意义,因为它们代表了投资者最常持有的风险资产储蓄工具（通过共同基金、ETF 和对冲基金）。我们研究市值加权投资组合,以评估模型的预测性能在经济中最有价值（也是经济意义最重大)的资产中表现如何。第三,投资组合收益的分布对个股收益之间的相关性非常敏感,这意味着一个好的个股层面预测模型并不能保证产生准确的投资组合层面预测。自下而上的投资组合预测使我们能够评估模型将其在最精细的资产层面上的预测结果推广到更广泛的投资环境中的能力。最后,投资组合结果更进一步地体现了“样本外”分析,因为优化程序并不直接考虑投资组合的预测性能。

到目前为止,我们对预测表现的评估完全是统计性的,依赖于预测$R^2$的比较。在投资组合层面分析可预测性的最终优势在于,我们可以通过每种方法对风险调整后投资组合收益表现的贡献来评估其经济贡献。

2.4.1 预设投资组合。我们通过将个股收益预测汇总成投资组合来构建自下而上的预测。给定股票 i 在投资组合 p 中的权重（记为wp<sub>i,t</sub>)以及基于模型的股票 i 的样本外预测（记为 ri<sub>i,t+1</sub>),我们构建投资组合收益预测如下：

$$r^{p}_{t+1} = \sum_{i=1}^{n} wp_{i,t} \times ri,t+1。$$

这种自下而上的方法适用于任何权重事先已知的目标投资组合。

我们对实证金融文献中最著名的30个投资组合进行了自下而上的预测,其中包括标普500指数、Fama-French规模、价值、盈利能力、投资和动量因子投资组合（SMB、



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



（分别为 HML、RMW、CMA 和 UMD），以及这些 Fama-French 投资组合的子成分，包括六个规模与价值投资组合、六个规模与投资组合、六个规模与盈利能力组合以及六个规模与动量组合。子成分投资组合均为多头投资组合，因此与市场指数有相当大的重叠，而 SMB、HML、RMW、CMA 和 UMD 是零净投资的多空投资组合，在很大程度上剔除了市场敞口。所有投资组合均使用 CRSP 市场股票价值权重自行构建。我们的投资组合构建方式与实际的标普 500 指数和基于特征的 Fama-French 投资组合（Fama 和 French，1993，2015）略有不同，但其优势在于我们可以精确追踪每个投资组合的事前权重。<sup>38</sup>表 5 报告了我们 30 年测试样本的月度样本外$R^2$值。正则化线性方法在预测标普500指数方面未能超越简单的常数预测。相比之下，所有非线性模型都具有显著的正预测性能。广义线性模型的1个月样本外$R^2$为0.71%，而三层神经网络的$R^2$则高达1.80%。作为对比基准，Welch和Goyal（2008）调查中几乎所有宏观经济收益预测变量的样本外预测$R^2$均未达到正值。Kelly和Pruitt（2013）发现，偏最小二乘法

（PLS）对综合市场指数的月度样本外预测$R^2$约为1%，但他们的预测直接针对市场收益，而非自下而上的预测。而研究最深入的投资组合预测指标，如总价格股息率，通常每月产生的样本内预测R2约为 1%（例如，Cochrane 2007），小于我们在样本外发现的 R2。

不同模型对标普500指数预测表现的模式同样适用于仅做多特征排序投资组合（第2-25行）和多空因子投资组合（SMB、HML、RMW、CMA和UMD）。非线性方法表现尤为出色。

NN3–NN5对所有分析的投资组合均产生正的$R^2_{oos}$值，其中 NN3 表现最佳。NN1 和 NN2 也产生正的$R^2_{oos}$值（总体而言，这是最难预测的策略）。广义线性模型$R^2_{oos}$除了马里兰大学（UMD）以外，其他所有大学都是如此。

在30个投资组合中，有22个投资组合的结果为正。另一方面，线性方法总体上对于自下而上的投资组合收益预测并不可靠，尽管它们在“大型”投资组合上的表现往往优于“小型”投资组合。

对于某些多空因子投资组合（例如SMB），约束线性方法（例如PLS）表现相对较好（与Kelly和Pruitt 2013年的研究结果一致）。简而言之，机器学习方法，尤其是非线性方法，能够产生异常强大的样本外投资组合预测结果。

接下来，我们评估投资组合可预测性的经济意义。
Campbell 和 Thompson (2008) 的研究表明， R2的微小改进可以映射

[38] 我们复制的标普500指数收益与实际指数的相关性超过0.99。对于其他投资组合（SMB、HML、RMW、CMA、UMD），我们的复制结果与肯尼斯·弗伦奇网站上的版本之间的收益相关性分别为0.99、0.97、0.95、0.99和0.96。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



表5

月度投资组合层面样本外预测$R^2$

| | OLS-3 +H | PLS | PCR | ENet +H | GLM +H | RF | GBRT +H | NN1 | NN2 | NN3 | NN4 | NN5 +H |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| A. 共同因子投资组合 | | | | | | | | | | | | |
| 标普500指数 | −0.22 | −0.86 | −1.55 | 0.75 | 0.71 | 1.37 | 1.40 | 1.08 | 1.13 | 1.80 | 1.63 | 1.17 |
| 中小企业 | 0.81 | 2.09 | 0.39 | 1.72 | 2.36 | 0.57 | 0.35 | | | | 1.40 | 1.16 |
| HML | 0.66 | 0.50 | 1.21 | 0.46 | 0.84 | 0.98 | 0.21 | | | | 1.22 | 1.31 |
| RMW | −2.35 | 1.19 | 0.41 | −1.07 | −0.06 | −0.54 | −0.92 | 0.68 | 0.47 | 0.84 | 0.53 | 0.54 |
| CMA | 0.80 | −0.44 | 0.03 | −1.07 | 1.24 | −0.11 | −1.04 | 1.88 | 1.60 | 1.06 | 1.84 | 1.31 |
| 马里兰大学 | −0.90 | −1.09 | −0.47 | 0.47 | −0.37 | 1.37 | −0.25 | −0.56 | −0.26 | 0.19 | 0.27 | 0.35 |
| B. 因子组合的子组成部分 | | | | | | | | | | | | |
| 大价值,大增 | 0.10 | 0.00 | −0.33 | 0.25 | 0.59 | 1.31 | 1.06 | −0.33 | −1.26 | | 0.85 | 0.87 |
| 长,大中性;小价 | −1.62 | 0.70 | 0.51 | 1.32 | 1.19 | −0.17 | −1.09 | −1.51 | 0.80 | | 1.00 | 1.10 |
| 值,小增长,小中 | 0.36 | 1.31 | 1.28 | | | | | | | | 1.43 | 1.24 |
| 性 | 0.30 | 1.66 | 1.05 | 0.64 | 0.85 | 1.24 | 0.52 | 1.59 | 1.37 | 1.54 | 1.40 | 1.30 |
| | −0.16 | 0.14 | −0.18 | −0.33 | −0.12 | 0.71 | 1.24 | 0.05 | 0.42 | 0.48 | 0.41 | 0.50 |
| | −0.27 | 0.60 | 0.19 | 0.21 | 0.28 | 0.88 | 0.36 | 0.58 | 0.62 | 0.70 | 0.58 | 0.68 |
| 大保守派 | −0.57 | −0.10 | −1.06 | 1.02 | 0.46 | 1.11 | 1.15 | 1.13 | 1.59 | 1.37 | 1.07 | 0.55 |
| 大侵略性 | 0.20 | −0.80 | −1.15 | 0.30 | 0.67 | 1.75 | 2.00 | 1.33 | 1.51 | 1.78 | 1.55 | 1.42 |
| 大中性 | 0.77 | 0.85 | 0.85 | 1.51 | 1.49 | 0.29 | −1.75 | −1.96 | 0.83 | 0.48 | 1.13 | |
| 小保守型 | −0.05 | 1.17 | 0.71 | −0.02 | 0.34 | 0.96 | 0.56 | 0.82 | 0.87 | 0.96 | 0.90 | 0.83 |
| 小而激进 | −0.10 | 0.51 | 0.01 | −0.09 | 0.14 | 1.00 | 1.46 | 0.34 | 0.64 | 0.75 | 0.62 | 0.71 |
| 小中性 | −0.30 | 0.45 | 0.12 | 0.42 | 0.35 | 0.76 | −0.01 | 0.70 | 0.69 | 0.83 | 0.66 | 0.72 |
| 强壮大 | −1.02 | −1.08 | −2.06 | 0.55 | 0.35 | 1.10 | 0.33 | −0.12 | 1.42 | | 0.74 | 0.79 |
| 大弱 | 1.07 | 0.89 | 1.10 | 1.33 | 1.77 | 0.86 | −1.22 | −1.26 | 0.41 | 0.13 | 1.79 | 1.79 |
| 大中立 | 1.10 | 0.91 | −0.71 | 0.35 | −0.38 | −0.04 | −0.42 | 0.70 | 0.19 | | 0.84 | 0.94 |
| 小巧结实 | | | | | | | | | | | 0.24 | 0.50 |
| 小弱 | 0.05 | 1.06 | 0.59 | −0.13 | 0.44 | 1.05 | 1.42 | 0.71 | 0.92 | 0.99 | 0.90 | 0.89 |
| 小中性 | −0.51 | 0.07 | −0.47 | −0.33 | −0.32 | 0.60 | −0.08 | 0.10 | 0.25 | 0.38 | 0.32 | 0.41 |
| 赞! | 0.20 | −0.25 | −1.24 | 0.66 | 1.17 | 1.18 | 0.90 | 0.80 | 0.76 | 1.13 | 1.12 | 0.93 |
| 大跌 | −1.54 | −1.63 | −1.55 | 0.44 | −0.33 | 1.14 | 0.71 | | | | 0.36 | 0.70 |
| 大中型 | −0.04 | −1.51 | −1.94 | 0.81 | −0.08 | 1.57 | 1.80 | 1.29 | 1.32 | 1.71 | 1.55 | 1.23 |
| 小规模 | 0.07 | 0.78 | 0.56 | −0.07 | 0.25 | 0.62 | −0.03 | 0.06 | 0.07 | 0.21 | 0.19 | 0.25 |
| 小下 | −0.21 | 0.15 | −0.20 | 0.15 | −0.01 | 1.51 | | | | 1.38 | 0.74 | 0.82 |
| 小中型 | 0.07 | 0.82 | 0.20 | 0.59 | 0.37 | 1.22 | 1.06 | | | | 1.09 | 1.09 |

在此表中,我们报告了使用 OLS 对 30 个投资组合进行样本外预测的$R^2$ 值,这些投资组合的规模、账面市值比、动量、OLS-3、PLS、PCR、弹性网络（ENet）、带分组套索的广义线性模型（GLM）、随机森林（RF）、梯度提升回归树（GBRT)和五种神经网络架构（NN1,...,NN5)。“+H”表示使用Huber损失函数而非l2损失函数。面板A中的六个投资组合均为标普500指数。以及Fama-French SMB、HML、CMA、RMW和UMD因子。B组中的24个投资组合是用于构建Fama-French价值、投资、盈利能力模型的3×2大小的双重排序投资组合以及动量因素。

对于均值-方差投资者而言,这会带来巨大的效用收益。他们证明,夏普比率积极投资者利用预测信息所获得的比率（SR ）（总结为预测$R^2$)优于夏普比率 (SR)根据买入并持有型投资者的说法

$$SR = \frac{SR2+R2}{1-R2}。$$

我们使用此公式来转换预测$R^2$ oos 表5（以及）将各投资组合的全样本夏普比率转化为年化收益率的提高



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



夏普比率（ SR　－SR)是指投资者利用机器学习预测进行投资组合择时时的比率。互联网附录中的表A.7列出了结果。
例如,标普500指数的买入并持有夏普比率在我们30年的样本外数据中为0.51,而通过利用NN3模型预测的市场择时策略,可以将该比率提高到0.71。对于基于特征的投资组合,非线性机器学习方法可以将夏普比率提高几个百分点到超过24个百分点。

Campbell 和 Thompson (2008) 也提出使用择时交易策略来评估投资组合可预测性的经济意义。我们完全遵循他们的样本外交易策略,每月根据预期收益的上升/下降调整仓位,同时对仅做多投资组合设定 50% 的最大杠杆限制,并禁止卖空（对于多空因子投资组合,我们不施加这些限制）。表 6 报告了基于机器学习预测的择时策略的年化夏普比率收益（相对于买入并持有策略）。与我们的其他结果一致,最强且最稳定的交易策略是基于非线性模型的策略,其中神经网络总体表现最佳。以 NN3 为例,对标普 500 指数进行择时操作的夏普比率为 0.77,比买入并持有策略高出 26 个百分点。多空因子投资组合比标普 500 指数和其他 24 个纯多头投资组合更难把握时机,而且所有方法都无法超越静态 UMD 策略。

作为稳健性检验,我们还分析了自下而上对年度而非月度收益率的预测。不同方法在年度和月度数据中的预测性能对比模式相同。互联网附录中的表 A.8 展示了非线性方法,尤其是神经网络的优越性。NN3 在市场组合预测中继续占据主导地位,实现了年度$R^2$值。

$_{oos}$ 15.7%。

2.4.2 机器学习投资组合。接下来,我们不评估预先设定的投资组合的预测表现,而是设计一组新的投资组合,直接利用机器学习的预测结果。每个月末,我们计算每种方法对未来一个月股票收益的样本外预测值。然后,我们根据每个模型的预测结果将股票分为十等分。我们每月使用市值权重重新构建投资组合。最后,我们构建一个净投资为零的投资组合,该组合买入预期收益最高的股票（第10等分）,卖出预期收益最低的股票（第1等分）。

表7列出了结果。样本外投资组合表现与之前报告的机器学习预测准确率结果非常吻合。

实际收益率通常随着机器学习预测结果的增加而单调递增（个别例外情况,例如 NN1 的第 8 个十分位数）。神经网络模型再次优于线性模型和基于树的方法。尤其值得一提的是,除了最极端的十分位数之外,使用神经网络预测的收益率与平均实际收益率之间的定量匹配度非常高。最佳的 10:1 策略来自 NN4。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



表6

市场择时夏普比率上涨

| | OLS-3 | PLS | PCR | ENet | GLM +H | RF +H | GBRT +H | NN1 | NN2 | NN3 | NN4 | NN5 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| A. 共同因子投资组合 | | | | | | | | | | | | |
| 标准普尔500指数 | 0.07 | 0.05 | −0.06 | 0.12 | 0.19 | 0.18 | 0.19 | 0.22 | 0.20 | 0.26 | 0.22 | 0.19 |
| 中小企业 | 0.06 | 0.17 | 0.09 | 0.24 | 0.26 | 0.00 | −0.07 | 0.21 | 0.18 | 0.15 | 0.09 | 0.11 |
| HML | 0.00 | 0.01 | 0.04 | −0.03 | −0.02 | 0.04 | 0.02 | 0.04 | 0.06 | 0.04 | 0.02 | 0.01 |
| RMW | 0.00 | −0.01 | −0.06 | −0.19 | −0.13 | −0.11 | −0.01 | −0.03 | −0.09 | 0.01 | 0.01 | −0.07 |
| CMA | 0.02 | 0.02 | 0 | −0.09 | −0.05 | 0.08 | −0.01 | 0.00 | 0.01 | 0.05 | 0.04 | 0.06 |
| 马里兰大学 | 0.01 | −0.06 | −0.02 | −0.02 | −0.07 | −0.04 | −0.07 | −0.04 | −0.08 | −0.04 | −0.10 | −0.01 |
| B. 因子组合的子组成部分 | | | | | | | | | | | | |
| 大价值,大增 | −0.01 | 0.06 | −0.03 | 0.09 | 0.06 | 0.09 | 0.08 | 0.11 | 0.11 | 0.13 | 0.10 | 0.11 |
| 长,大中性;小价 | 0.08 | −0.01 | −0.08 | 0.10 | 0.17 | 0.20 | 0.21 | 0.22 | 0.20 | 0.26 | 0.22 | 0.21 |
| 值,小增长,小中 | 0.06 | 0.03 | −0.06 | 0.11 | 0.16 | 0.13 | 0.17 | 0.23 | 0.21 | 0.23 | 0.23 | 0.21 |
| 性 | −0.04 | 0.15 | 0.09 | 0.01 | 0.08 | 0.07 | 0.08 | 0.11 | 0.11 | 0.10 | 0.11 | 0.13 |
| | 0.00 | 0.03 | −0.06 | −0.03 | −0.05 | 0.04 | 0.05 | 0.02 | 0.03 | 0.03 | 0.02 | 0.02 |
| | 0.02 | 0.09 | 0.05 | 0.03 | 0.04 | 0.11 | 0.11 | 0.09 | 0.08 | 0.10 | 0.09 | 0.11 |
| 大保守派 | 0.08 | 0.02 | −0.04 | 0.08 | 0.15 | 0.09 | 0.13 | 0.17 | 0.14 | 0.19 | 0.16 | 0.14 |
| 大侵略性 | 0.08 | −0.01 | −0.11 | 0.01 | 0.13 | 0.22 | 0.18 | 0.21 | 0.19 | 0.23 | 0.20 | 0.20 |
| 大中性 | 0.04 | −0.01 | −0.08 | 0.09 | 0.11 | 0.09 | 0.11 | 0.13 | 0.12 | 0.18 | 0.18 | 0.16 |
| 小保守派 | 0.04 | 0.17 | 0.12 | 0.02 | 0.05 | 0.17 | 0.15 | 0.11 | 0.11 | 0.14 | 0.13 | 0.15 |
| 小侵略性 | 0.01 | 0.05 | −0.06 | −0.05 | −0.03 | 0.08 | 0.06 | 0.02 | 0.05 | 0.06 | 0.04 | 0.05 |
| 小中性 | 0.01 | 0.06 | 0.03 | 0.01 | 0.04 | 0.08 | 0.09 | 0.07 | 0.06 | 0.08 | 0.07 | 0.09 |
| 强壮大 | 0.10 | 0.07 | −0.07 | 0.11 | 0.18 | 0.17 | 0.18 | 0.18 | 0.16 | 0.22 | 0.19 | 0.16 |
| 大弱 | 0.05 | 0.12 | 0.05 | 0.09 | 0.12 | 0.21 | 0.17 | 0.22 | 0.20 | 0.21 | 0.18 | 0.19 |
| 大中立 | 0.09 | 0.00 | −0.04 | 0.09 | 0.20 | 0.19 | 0.17 | 0.22 | 0.21 | 0.24 | 0.21 | 0.20 |
| 小巧结实 | 0.09 | 0.04 | −0.03 | 0.00 | 0.00 | 0.10 | 0.07 | 0.04 | 0.05 | 0.08 | 0.08 | 0.08 |
| 小弱 | −0.03 | 0.09 | 0.00 | −0.03 | −0.02 | 0.07 | 0.07 | 0.06 | 0.06 | 0.06 | 0.05 | 0.06 |
| 小中性 | 0.04 | 0.04 | −0.03 | 0.00 | 0.01 | 0.11 | 0.09 | 0.04 | 0.04 | 0.07 | 0.07 | 0.08 |
| 赞! | 0.10 | 0.05 | −0.06 | 0.10 | 0.21 | 0.16 | 0.14 | 0.17 | 0.14 | 0.17 | 0.18 | 0.17 |
| 大跌 | −0.02 | 0.09 | −0.08 | −0.02 | 0.02 | 0.08 | 0.10 | 0.10 | 0.07 | 0.12 | 0.11 | 0.09 |
| 大中型 | −0.01 | 0.04 | −0.06 | 0.14 | 0.09 | 0.17 | 0.20 | 0.22 | 0.21 | 0.25 | 0.22 | 0.19 |
| 小规模 | 0.08 | 0.13 | 0.10 | 0.05 | 0.07 | 0.16 | 0.12 | 0.07 | 0.06 | 0.08 | 0.07 | 0.10 |
| 小下 | −0.14 | 0.04 | −0.05 | −0.09 | −0.05 | 0.06 | 0.04 | 0.01 | 0.01 | 0.02 | 0.01 | 0.01 |
| 小中型 | 0.05 | 0.11 | 0.07 | 0.08 | 0.09 | 0.13 | 0.15 | 0.13 | 0.12 | 0.14 | 0.13 | 0.15 |

该表记录了年化夏普比率（SR −SR)的改善情况。我们通过加权计算SR 。
基于市场择时策略的投资组合（参见 Campbell 和 Thompson 2008）。

平均每月收益率为 2.3%（年化收益率为 27.1%）。
月度波动率为 5.8%（年化波动率为 20.1%）,年化波动率为
样本外夏普比率为 1.35。

虽然市值加权投资组合对交易成本的敏感度较低,但在我们的分析中研究等权重投资组合或许更为自然,因为
我们的统计目标函数旨在最小化等权重预测误差。
互联网附录中的表 A.9报告了机器学习的性能
采用等权重构建的投资组合。这方面的定性结论
表格中的数据与表7中的数据相同,但夏普比率却大相径庭。
更高。例如,基于NN4的多空十分位价差投资组合。
该模型采用等权重法计算,年化夏普比率为 2.45。
确定等权重结果在多大程度上受微型股驱动
股票方面,互联网附录中的表 A.10 报告了等权重投资组合

本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



表7

机器学习投资组合的表现

| | OLS-3+H | | | 请 | | | PCR | | |
|---|---|---|---|---|---|---|---|---|---|
| | 预测平均 SD SR | 预测平均 SD SR | | 预测平均 SD SR | | | | | |
| 低(L) −0.17 2 0.17 | | 0.40 | 5.90 | 0.24 −0.83 0.29 | 5.31 | 0.19 −0.68 | | 0.03 5.98 0.02 | |
| | | 0.58 | 4.65 | 0.43 −0.21 | | 0.55 4.96 0.38 −0.11 | | 0.42 5.25 0.28 | |
| 3 | 0.35 | 0.60 | 4.43 | 0.47 | 0.12 | 0.64 4.63 0.48 | 0.19 | 0.53 4.94 0.37 | |
| 4 | 0.49 | 0.71 | 4.32 | 0.57 | 0.38 | 0.78 4.30 0.63 | 0.42 | 0.68 4.64 0.51 | |
| 5 | 0.62 | 0.79 | 4.57 | 0.60 | 0.61 | 0.77 4.53 0.59 | 0.62 | 0.81 4.66 0.60 | |
| 6 | 0.75 | 0.92 | 5.03 | 0.63 | 0.84 | 0.88 4.78 0.64 0.92 | 0.81 | 0.81 4.58 0.61 | |
| 7 | 0.88 | 0.85 | 5.18 | 0.57 | 1.06 | 4.89 0.65 0.92 5.14 | 1.01 | 0.87 4.72 0.64 | |
| 8 | 1.02 | 0.86 | 5.29 | 0.56 | 1.32 | 0.62 1.15 5.24 0.76 | 1.23 | 1.01 4.77 0.73 | |
| 9 | 1.21 | 1.18 | 5.47 | 0.75 | 1.66 | 1.30 5.85 0.77 | 1.52 | 1.20 4.88 0.86 | |
| 高(H) | 1.51 | 1.34 | 5.88 | 0.79 | 2.25 | | 2.02 | 1.25 5.60 0.77 | |
| HL | 1.67 | 0.94 | 5.33 | 0.61 | 3.09 | 1.02 4.88 0.72 | 2.70 | 1.22 4.82 0.88 | |
| | 网络+H | | | GLM+H | | | 射频 | | |
| | 预测平均 SD SR | 预测平均 SD SR | | 预测平均 SD SR | | | | | |
| 低(L) −0.04 2 0.27 3 | | 0.24 | 5.44 | 0.15 −0.47 0.08 | 5.65 | 0.05 0.40 0.01 0.49 | 0.29 −0.09 6.00 −0.05 | | |
| 0.44 4 0.59 5 0.73 6 0.87 | | 0.56 | 4.84 | 4.80 0.35 0.40 | 0.29 | 0.65 4.52 0.50 0.61 | 0.44 0.38 5.02 0.27 | | |
| 7 1.01 8 1.16 9 1.36高(H) | | 0.53 | 4.50 | 0.50 0.72 4.59 | 0.55 | 0.57 0.68 0.70 4.55 | 0.53 0.64 4.70 0.48 | | |
| 1.66 | | 0.72 | 4.11 | 0.53 0.64 0.84 | 0.84 | 4.53 0.65 0.64 1.00 | 0.60 0.60 4.56 0.46 | | |
| | | 0.72 | 4.42 | 0.86 4.82 0.62 | 0.59 | 1.18 0.87 5.18 0.58 | 0.67 0.57 4.51 0.44 | | |
| | | 0.85 | 4.60 | 0.50 1.40 1.04 | 5.44 | 0.66 0.43 1.81 1.14 | 0.73 0.64 4.54 0.49 | | |
| | | 0.87 | 4.75 | 6.33 0.62 | | | 0.80 0.67 4.65 0.50 | | |
| | | 0.88 | 5.20 | | | | 0.87 1.00 4.91 0.71 | | |
| | | 0.80 | 5.61 | | | | 0.96 1.23 5.59 0.76 | | |
| | | 0.84 | 6.76 | | | | 1.12 1.53 7.27 0.73 | | |
| HL | 1.70 | 0.60 | 5.37 | 0.39 | 2.27 | 1.06 4.79 0.76 | 0.83 | 1.62 5.75 0.98 | |
| | GBRT+H | | | NN1 | | | NN2 | | |
| | 预测平均 SD SR | 预测平均 SD SR | | 预测平均 SD SR | | | | | |
| 低(L) −0.45 2 −0.16 | | 0.18 | 5.60 | 0.11 −0.38 −0.29 | 7.02 | −0.14 −0.23 −0.54 7.83 −0.24 | | | |
| 0.02 0.17 0.34 | | 0.49 | 4.93 | 0.35 0.41 0.35 | 0.24 | 0.36 6.08 0.20 | 0.21 | | |
| | | 0.59 | 4.75 | 0.43 0.51 0.47 | 0.35 | 0.65 5.07 0.44 | 0.44 | | |
| 3 4 | | 0.63 | 4.68 | 0.46 0.70 0.56 | 0.53 | 0.73 4.53 0.56 | 0.59 | | |
| 5 | | 0.57 | 4.70 | 0.42 0.77 0.37 | 0.61 | 0.81 4.38 0.64 | 0.72 | | |
| 6 | 0.46 | 0.77 | 4.48 | 0.59 | 0.95 | 0.78 4.39 0.62 0.81 | 0.84 | 0.84 4.51 0.65 | |
| 7 | 0.59 | 0.52 | 4.73 | 0.38 | 1.11 | 4.40 0.64 | 0.97 | 0.95 4.61 0.71 | |
| 8 | 0.72 | 0.72 | 4.92 | 0.51 | 1.31 | 0.75 4.86 0.54 | 1.13 | 0.93 5.09 0.63 | |
| 9 | 0.88 | 0.99 | 5.19 | 0.66 | 1.58 | 0.96 5.22 0.64 | 1.37 | 1.04 5.69 0.63 | |
| 高(H) | 1.11 | 1.17 | 5.88 | 0.69 | 2.19 | 1.52 6.79 0.77 | 1.99 | 1.38 6.98 0.69 | |
| HL | 1.56 | 0.99 | 4.22 | 0.81 | 2.57 | 1.81 5.34 1.17 | 2.22 | 1.92 5.75 1.16 | |
| | NN3 | | | NN4 | | | NN5 | | |
| | 预测平均 SD SR | 预测平均 SD SR | | 预测平均 SD SR | | | | | |
| 低(L) −0.03 −0.43 2 0.34 0.30 3 0.51 | | | | 7.73 −0.19 −0.12 | −0.52 | 7.69 −0.23 −0.23 −0.51 7.69 −0.23 | | | |
| 0.57 4 0.63 0.66 5 0.71 0.69 6 0.79 | | | | 6.38 0.31 0.16 | 0.17 | 0.30 0.33 6.16 0.19 0.42 | 0.23 | | |
| 0.76 7 0.88 0.99 8 1.00 1.09 9 1.21 | | | | 5.27 0.54 0.37 | 0.37 | 0.50 5.18 0.28 0.60 4.51 | 0.45 | | |
| 1.25高(H) 1.83 1.69 | | | | 4.69 0.67 0.47 | 0.52 | 0.62 0.46 0.69 4.26 0.56 | 0.60 | | |
| | | | | 4.41 0.77 0.33 | 0.62 | 0.72 0.84 4.46 0.65 0.93 | 0.73 | | |
| | | | | 4.46 0.86 0.39 | 0.68 | 0.81 4.56 0.70 1.08 5.13 | 0.85 | | |
| | | | | 4.77 0.88 0.70 | 0.64 | 0.90 0.73 1.26 5.93 0.74 | 0.96 | | |
| | | | | 5.47 0.94 5.57 | 0.63 | 1.03 1.75 7.51 0.81 | 1.11 | | |
| | | | | 5.94 1.02 6.03 | 0.58 | 1.23 | 1.34 | | |
| | | | | 7.29 1.46 7.40 | 0.68 | 1.89 | 1.99 | | |
| HL | 1.86 | 2.12 | 6.13 | 1.20 | 2.01 | 2.26 5.80 1.35 | 2.22 | 1.97 5.93 1.15 | |

本表报告了预测排序投资组合在30年样本外测试中的表现。

句号。所有股票均根据其下个月的预期收益分为十等分。列“Pred”，

“Avg”、“SD”和“SR”分别表示每个十分位数的预测月收益率、平均实际月收益率和平均实际月收益率。

分别列出收益率、标准差和夏普比率。所有投资组合均采用市值加权。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



表8

机器学习投资组合的回撤、换手率和风险调整后收益

| | OLS-3 | PLS | PCR | ENet +H | GLM +H | RF +H | GBRT +H | NN1 | NN2 | NN3 | NN4 | NN5 +H |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 回撤和换手率（按市值加权） | | | | | | | | | | | | |
| 最大 DD(%) | 69.60 | 41.13 | 42.17 | 60.71 | 37.09 | 52.27 | 48.75 | 61.60 | 55.29 | 30.84 | 51.78 | 57.52 |
| 最大1M损失(%) | 24.72 | 27.40 | 18.38 | 27.40 | 15.61 | 26.21 | 21.83 | 18.59 | 37.02 | 30.84 | 33.03 | 38.95 |
| 营业额（%） | 58.20 | 110.87 | 125.86 | 151.59 | 145.26 | 133.87 | 143.53 | 121.02 | 122.46 | 123.50 | 126.81 | 125.37 |
| 回撤和换手率（权重相同） | | | | | | | | | | | | |
| 最大 DD(%) | 84.74 | 32.35 | 31.39 | 33.70 | 21.01 | 46.42 | 37.19 | 18.25 | 25.81 | 17.34 | 14.72 | 21.78 |
| 最大1M损失(%) | 37.94 | 32.35 | 22.33 | 32.35 | 15.74 | 34.63 | 22.34 | 12.79 | 25.81 | 12.50 | 9.01 | 21.78 |
| 营业额（%） | 57.24 | 104.47 | 118.07 | 142.78 | 137.97 | 120.29 | 134.24 | 112.35 | 112.43 | 113.76 | 114.17 | 114.34 |
| 风险调整后绩效（市值加权） | | | | | | | | | | | | |
| 平均保留率。 | 0.94 | 1.02 | 1.22 | 0.60 | 1.06 | 1.62 | 0.99 | 1.81 | 1.92 | 2.12 | 2.26 | 1.97 |
| FF5+Mom α | 0.39 | 0.24 | 0.62 | −0.23 | 0.38 | 1.20 | 0.66 | 1.20 | 1.33 | 1.52 | 1.76 | 1.43 |
| t(α) | 2.76 | 1.09 | 2.89 | −0.89 | 1.68 | 3.95 | 3.11 | 4.68 | 4.74 | 4.92 | 6.00 | 4.71 |
| R2 | 78.60 | 34.95 | 39.11 | 28.04 | 30.78 | 13.43 | 20.68 | 27.67 | 25.81 | 20.84 | 20.47 | 18.23 |
| 红外光谱 | 0.54 | 0.21 | 0.57 | -0.17 | 0.33 | 0.77 | 0.61 | 0.92 | 0.93 | 0.96 | 1.18 | 0.92 |
| 风险调整后绩效（等权重） | | | | | | | | | | | | |
| 平均回报率： | 1.34 | 2.08 | 2.45 | 2.11 | 2.31 | 2.38 | 2.14 | 2.91 | 3.31 | 3.27 | 3.33 | 3.09 |
| FF5+母α | 0.83 | 1.40 | 1.95 | 1.32 | 1.79 | 1.88 | 1.87 | 2.60 | 3.07 | 3.02 | 3.08 | 2.78 |
| t(α) | 6.64 | 5.90 | 9.92 | 4.77 | 8.09 | 6.66 | 8.19 | 10.51 | 11.66 | 11.70 | 12.28 | 10.68 |
| R2 | 84.26 | 26.27 | 40.50 | 20.89 | 21.25 | 19.91 | 11.19 | 13.98 | 10.60 | 9.63 | 11.57 | 14.54 |
| 红外光谱 | 1.15 | 1.94 | 0.93 | 1.83 | 1.30 | 1.60 | 2.06 | 2.28 | 2.29 | 2.40 | 2.09 | |

前两个面板分别报告了市值加权和等权重投资组合的最大回撤（“最大回撤”）。
最极端的负月度收益（“最大 100 万美元亏损”），以及平均每月百分比变化
持仓量（“周转率”）。底部面板报告平均每月收益率，以百分比表示，以及
α系数、信息比率（IR）和$R^2$，均基于扩展后的Fama-French五因素模型计算得出。
动量因素。

结果不包括纽约证券交易所市值排名低于第20百分位数的股票。
分布。在这种情况下，NN4 多空十分位价差获得夏普比率。
1.69。

正如 Lewellen (2015) 所建议的那样，OLS-3 模型尤其适用于
简洁而稳健的基准模型。他还推荐了一些……
我们报告了包含 7 个或 15 个预测变量的更大的 OLS 基准模型。
见互联网附录表 A.11。较大的 OLS 模型比
OLS-3，但仍然明显逊色于基于树的模型；
神经网络。

表 8 的上半部分报告了每个机器学习模型中 10-1 价差投资组合的回撤、投资组合周转率和风险调整后收益。
模型，适用于价值策略和等权重策略。我们定义最大值
策略回撤

$$\text{MaxDD} = \max_{0 \leqslant t1 \leqslant t2 \leqslant T} (Yt1 - Yt2)$$

其中Yt是从日期 0 到 t 的累计对数收益率。

神经网络投资组合不仅比神经网络投资组合拥有更高的夏普比率。
与其他替代方案相比，它们的回撤幅度也相对较小，特别是对于……
等权重投资组合。NN4 经历的最大回撤



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



价值策略占比为 51.8%,等权重策略占比为 14.7%。
相比之下,OLS-3 的最大回撤分别为 69.6% 和 84.7%。等权重神经网络策略的 1 个月亏损也最为轻微。例如,NN4 的最差 1 个月收益率为 -9.01%,这是所有采用不同权重方案的模型中月度亏损最小的。

我们将该策略的平均月营业额定义为

$$\text{营业额}=\frac{1}{T}\sum_{t=1}^{T}\sum_{i}\left|w_{i,t+1}-\left(1+\frac{w_{i,t}(1+r_{i,t+1})}{\sum_{j}w_{j,t}(1+r_{j,t+1})}\right)\right|,$$

其中$w_{i,t}$表示股票 i 在 t 时刻投资组合中的权重。对于 NN1 至 NN5,月换手率始终在 110% 至 130% 之间,而基于树的方法和惩罚回归的换手率略高。作为参考,短期反转十分位价差的月换手率为 172.6%,而规模十分位价差的月换手率为 22.9%。考虑到所有机器学习方法选择的价格趋势预测因子都发挥着重要作用,它们在相对较高的投资组合换手率下取得优异表现或许并不令人意外。

表 8 的底部面板报告了基于因子定价模型的机器学习投资组合的风险调整后收益。在线性因子模型中,因子本身的切点投资组合代表了经济体中夏普比率最高的投资组合。任何夏普比率高于因子切点投资组合的投资组合相对于该模型都具有超额收益 (alpha)。根据以往的研究,Fama-French 三因子模型和五因子模型的样本外因子切点投资组合的夏普比率分别约为 0.8 和 1.3（Kelly、Pruitt 和 Su,2019）。因此,基于机器学习预测构建的投资组合相对于这些模型获得显著的超额收益也就不足为奇了。六因子模型（在 Fama-French 五因子模型的基础上增加一个动量因子)可以解释基于线性模型的策略平均收益的 40%,但只能解释基于神经网络的投资组合约 10% 到 30% 的波动。因此,神经网络的信息比率介于0.9到2.4之间,具体数值取决于层数和投资组合权重方案。对于树模型和所有神经网络模型,相关alpha值的检验统计量均具有高度显著性。

表 8 的结果在图 9 中以可视化的方式进行了总结,该图展示了部分策略的多空累计表现,以及作为基准的累计市场超额收益。NN4 在多空两端均大幅优于其他模型。值得注意的是,在 2000 年之后的样本中,所有投资组合的空头部分基本保持平稳。<sup>39</sup>最后,我们考虑两种结合所有机器学习投资组合预测结果的元策略。第一种是十分位数的简单等权重平均。

[39] 互联网附录中的图 A.7绘制了等权重策略的相应累计收益。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



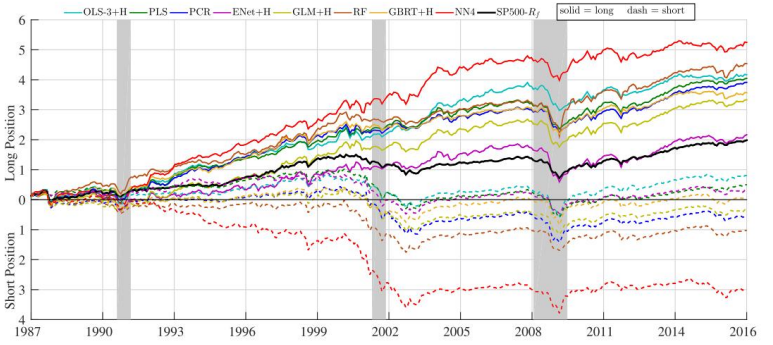



图 9 机器
学习投资组合的累计收益率该图显示了根据样本外机器
学习收益率预测值排序的投资组合的累计对数收益率。实线和虚线分别代表多头头寸（前 10%)和空头头寸（后 10%）。

阴影部分显示的是美国国家经济研究局 (NBER) 预测的经济衰退日期。所有投资组合均采用市值加权。

我们运用十一种机器学习方法构建了多空投资组合。该投资组合的个股预测$R^2$为每月0.43%,等权重十分位价差夏普比率为2.49,这两项指标均高于任何单一方法。市值加权十分位价差夏普比率为1.33,略低于NN4模型。

第二种元策略通过轮换使用不同的机器学习方法,根据相应验证样本的预测$R^2$值,为每个1年测试样本选择最佳的机器学习模型。在我们30年的样本外数据中,该方法选择了NN3 11次,NN1 7次,GBRT 6次,NN2 5次,NN4 1次。该方法获得了最高的整体面板$R^2$值（0.45%）,但在十分位分布夏普比率方面（等权重和值权重下分别为2.42和1.23)却不如独立的NN4模型。值得注意的是,与最佳的独立神经网络模型相比,该元策略的预测$R^2$值提升在统计学上并不显著。

## 3. 结论

我们以收益预测的经验背景为试验场,对机器学习方法进行了比较分析。

从最高层面来看,我们的研究结果表明,机器学习方法有助于提升我们对资产价格的实证理解。神经网络,以及在较小程度上回归树,是表现最佳的方法。

我们追溯了其预测优势的来源,发现其能够处理其他方法无法捕捉到的非线性交互作用。我们还发现,“浅层”学习优于“深度”学习,这与其他领域（例如计算机视觉或生物信息学)的典型结论不同,可能是由于资产定价问题中数据相对匮乏和信噪比低所致。机器学习方法最有价值的用途是……



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



预测更大、流动性更强的股票收益和投资组合。最后,我们发现所有方法都一致认为存在一组相当小的主要预测信号,其中最有效的预测因子与价格趋势相关,包括收益反转和动量。其次有效的预测因子是股票流动性、股票波动性和估值比率。

机器学习算法在收益预测方面取得的整体成功,为经济建模和投资组合选择的实际应用带来了希望。借助机器学习实现更精确的衡量,风险溢价不再受近似值和估计误差的影响,从而降低了识别资产定价现象背后可靠经济机制的难度。最后,我们的研究结果有助于论证机器学习在蓬勃发展的金融科技行业架构中日益重要的作用。

本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

参考

Bishop, CM 1995.模式识别的神经网络。英国牛津:牛津大学出版社。

Box, GEP 1953. 非正态性和方差检验。Biometrika 40:318–35。

Breiman, L. 2001. 随机森林。机器学习45:5–32。

Breiman, L., J. Friedman, CJ Stone 和 RA Olshen. 1984.分类和回归树。佛罗里达州博卡拉顿:CRC 出版社。

Butaru, F., Q. Chen, B. Clark, S. Das, AW Lo 和 A. Siddique. 2016. 信用卡行业的风险与风险管理。 《银行与金融杂志》 72:218–39。

Campbell, JY 和 SB Thompson. 2008. 预测样本外股票超额收益:是否有可能超越历史平均水平?金融研究评论21:1509–31。

Cochrane, JH 2007. 不吠叫的狗:对收益可预测性的辩护。金融研究评论21:1533–75。

Cybenko, G. 1989. sigmoid 函数叠加逼近。控制、信号和系统数学2:303–14。

de Jong, Sijmen. 1993. SIMPLS:偏最小二乘回归的替代方法。
化学计量学和智能实验室系统18:251–63。http ://www.sciencedirect.com/science/article/pii/016974399385002X 。

Diebold, FX 2015. 二十年后的预测准确性比较:关于 Diebold-Mariano 检验的使用和滥用的个人视角。 《商业与经济统计杂志》 33:1–9。

Diebold, FX 和 RS Mariano. 1995. 比较预测准确性。 《商业与经济统计杂志》 13:134–44。

Dietterich, TG 2000. 机器学习中的集成方法。载于国际多分类器系统研讨会， F. Schwenker、F. Roli 和 J. Kittler 编辑,1-15。纽约:Springer。

Dimopoulos, Y., P. Bourret 和 S. Lek. 1995. 使用一些敏感性标准选择具有良好泛化能力的网络。神经处理快报2:1–4。

Eldan, R. 和 O. Shamir. 2016. 深度对前馈神经网络的作用。载于第 29 届学习理论年会论文集， V. Feldman、A. Rakhlin 和 O. Shamir 编辑,907–40。布鲁克莱恩,马萨诸塞州:Microtome 出版社。

Fama, EF 和 KR French. 1993. 股票和债券收益中的共同风险因素。金融经济学杂志33:3–56。

Machine Translated by Google



. 2008. 剖析异常现象。金融杂志63:1653–78。

. 2015. 五因子资产定价模型。 《金融经济学杂志》 116:1–22。http ://dx.doi.org/10.1016/j.jfineco.2014.10.010 。

Fan, J., Q. Li 和 Y. Wang. 2017. 在缺乏对称性和轻尾假设的情况下估计高维均值回归。皇家统计学会杂志 ,B辑79:247–65。

Feng, G., S. Giglio 和 D. Xiu. 即将发表。驯服因子动物园 :新因子的检验。 《金融杂志》 。

Freund, Y. 1995. 通过多数投票提升弱学习算法。信息与计算121:256–85。

Freyberger, J.、A. Neuhierl 和 M. Weber. 2020. 非参数特征剖析。金融研究评论33: 2326–77。

Friedman, J. 2001. 贪婪函数逼近 :梯度提升机。统计年鉴5:1189–232。

Friedman, J.、T. Hastie 和 R. Tibshirani. 2000. 加性逻辑回归 :提升的统计视角。
统计年鉴28:337–74。

Giglio, SW 和 D. Xiu. 2016. 遗漏因素下的资产定价。芝加哥大学技术报告。

Glorot, X.、A. Bordes 和 Y. Bengio. 2011. 深度稀疏整流神经网络。第十四届人工智能与统计学国际会议论文集 ,第 15 卷 ,315–323 页。马萨诸塞州布鲁克莱恩 :
Microtome 出版社。

Goodfellow, I., Y. Bengio 和 A. Courville. 2016.深度学习。剑桥 :麻省理工学院出版社。

Green, J., JRM Hand 和 XF Zhang. 2013. 收益预测信号的概览。会计研究评论18:692–730。

。2017。提供有关美国平均每月股票收益的独立信息的特征。
金融研究评论30:4389–436。

顾思远、BT Kelly 和 D. Xiu. 2019. 自编码器资产定价模型。耶鲁大学工作论文。

Hansen, LK 和 P. Salamon. 1990. 神经网络集成. IEEE模式分析与机器智能汇刊12:993–1001。

Harvey, CR 和 WE Ferson. 1999. 条件变量和股票收益的横截面.金融杂志54:1325–60。

Harvey, CR 和 Y. Liu. 2016. 幸运因素。技术报告 ,杜克大学。

Harvey, CR, Y. Liu 和 H. Zhu. 2016. ... 以及预期收益的横截面。金融研究评论29:5–68。

Hastie, T.、R. Tibshirani 和 J. Friedman. 2009.统计学习要素。纽约 :Springer。

He, K., X. Zhang, S. Ren 和 J. Sun. 2016. 用于图像识别的深度残差学习。载于2016 年 IEEE 计算机视觉与模式识别会议 (CVPR 2016)， 770–78。Piscataway, NJ: IEEE
Publications。

Heaton, JB、NG Polson 和 JH Witte。2016 年。金融领域的深度学习。预印本， https://arxiv.org/abs/1602.06561 。

Hinton, GE, S. Osindero 和 Y.-W. Teh. 2006. 深度信念网络的快速学习算法。神经计算18:1527–54。

Hornik, K.、M. Stinchcombe 和 H. White. 1989. 多层前馈网络是通用逼近器。
神经网络2:359–66。

Huber, PJ 1964. 位置参数的稳健估计。数理统计年鉴35:73–101。

本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



Hutchinson, JM、AW Lo 和 T. Poggio. 1994. 衍生品定价和对冲的非参数方法
通过学习网络进行证券投资。《金融杂志》 49:851–89。

Ioffe, S. 和 C. Szegedy. 2015. 批量归一化:通过减少内部误差加速深度网络训练
协变量偏移。载于第32届国际机器智能会议论文集
Learning， F. Bach 和 D. Blei 编辑,448–56。纽约:ACM。

Jaggi, M. 2013. Lasso 和支持向量机之间的等价性。在正则化、优化中，
核函数和支持向量机， JAK Suykens、M. Signoretto 和 A. Argyriou 编辑,第 1-26 页。博卡拉顿，
FL:CRC出版社。

Jarrett, K.、K. Kavukcuoglu、M. A. Ranzato 和 Y. Lecun. 2009. 什么是最佳的多阶段架构
目标识别？ 2009 年 IEEE 第 12 届国际计算机视觉会议， 2146–53 页。新泽西州皮斯卡塔韦:
IEEE。

Kelly, B. 和 S. Pruitt. 2013. 现值横截面中的市场预期。《金融杂志》
68:1721–56。

. 2015. 三遍回归滤波器:一种使用多个预测变量进行预测的新方法。期刊
计量经济学186:294–316。

Kelly, B.、S. Pruitt 和 Y. Su. 2019. 特征即协方差:风险与收益的统一模型。《期刊》
金融经济学。

Khandani, AE, AJ Kim 和 AW Lo. 2010. 通过机器学习算法构建消费者信用风险模型。
银行与金融杂志34:2767–87。

Kingma, D. 和 J. Ba. 2014. Adam:一种随机优化方法。预印本， https://
arxiv.org/abs/1412.6980。

Koijen, R. 和 SV Nieuwerburgh. 2011. 收益和现金流的可预测性。《财务年度评论》
经济学3:467–91。

Kozak, S. 2019. 横截面的核技巧。工作论文,马里兰大学。

Kozak, S.、S. Nagel 和 S. Santosh. 2020. 缩小横截面。金融经济学杂志135:271–
92.

Lewellen, J. 2015. 预期股票收益的横截面分析。《批判金融评论》 4:1–44。

Lo, AW 和 AC MacKinlay. 1990. 金融资产定价模型检验中的数据窥探偏差。综述
金融研究3:431-67。

Masters, T. 1993. C++实用神经网络配方。纽约:学术出版社。

Moritz, B. 和 T. Zimmermann. 2016. 基于树的条件投资组合排序:过去和未来之间的关系
未来股票收益。工作论文,慕尼黑路德维希-马克西米利安大学。



本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。

Machine Translated by Google



Nair, V. 和 GE Hinton. 2010. 修正线性单元改进受限玻尔兹曼机。载于第 27 届国际机器学习会议 (ICML-10) 会议录， J. Fürnkranz 和 T. Joachims 编辑，807–14。
纽约：ACM。

Rapach, D. 和 G. Zhou. 2013. 预测股票收益。载于《经济预测手册》， G. Elliott 和 A. Timmermann 编辑，第 328-383 页。荷兰阿姆斯特丹：Elsevier 出版社。

Rapach, DE, JK Strauss 和 G. Zhou. 2013. 国际股票收益可预测性：美国的作用是什么？金融杂志68:1633–62。

Rosenberg, B. 1974.证券收益协方差的非市场成分。金融与定量分析杂志9:263–74。

Schapire, RE 1990. 弱可学习性的优势。机器学习5:197–227。

Sirignano, J.、A. Sadhwani 和 K. Giesecke. 2016. 用于抵押贷款风险的深度学习。工作论文，伊利诺伊大学厄巴纳-香槟分校。

Tukey, JW 1960. 从受污染分布中抽样的调查。载于概率与统计文集， I. Olkin、SG Ghurye、W. Hoeding、WG Madow 和 HB Mann 编辑。斯坦福，加利福尼亚州：斯坦福大学出版社。

Welch, I. 和 A. Goyal. 2008. 对股票溢价预测的实证表现进行全面考察。
金融研究评论21:1455–508。

White, H. 1980. 使用最小二乘法逼近未知回归函数。国际经济评论21:149–70。

Wilson, DR 和 TR Martinez. 2003. 梯度下降学习批量训练的普遍低效性。神经网络16:1429–51。

Yao, J., Y. Li, and CL Tan. 2000. 使用神经网络进行期权价格预测. Omega 28:455–66.

本文由芝加哥大学图书馆用户于2020年4月18日从https://academic.oup.com/rfs/article-abstract/33/5/2223/5758276下载。