Machine Translated by Google

吞等人。金融创新（2024)10:118 https://doi.org/10.1186/
s40854-024-00644-0

研究 开放获取

利用机器学习预测标普500指数股票的相对收益率

Htet Htet Htun1*, 迈克尔·比尔1和尼古拉·佩特科夫1

*通讯作者：
hhhtun@rug.nl

[1] 伯努利数学研究所，计算机
科学、人工智能、
格罗宁根大学
荷兰格罗宁根

抽象的

鉴于众多因素都会导致股价波动，预测股价变化极具挑战性。随机游走假说和有效市场假说本质上都表明，不可能系统性地、可靠地预测未来的股价或预测整个股市的变化。尽管如此，利用历史数据的机器学习（ML)技术已被应用于此类预测。以往的研究主要集中于少数股票，且声称取得了一定的成功，但统计置信度有限。在本研究中，我们构建了由多个历史相对收益率组成的特征向量，并应用随机森林（RF）、支持向量机（SVM)和长短期记忆网络（LSTM)等机器学习方法作为分类器，来预测某只股票在未来10天内能否比其指数高出2%。我们将此方法应用于2017年至2022年期间所有标普500指数成分股。

我们使用准确率、精确率和召回率来评估性能，并将结果与随机选择策略进行比较。我们观察到，LSTM 分类器的性能优于 RF 和 SVM，而数据驱动的机器学习方法优于随机选择分类器（ LSTM 准确率的 p 值为 8.46e－17）。因此，我们证明在所考虑的背景下，随机游走假设和有效市场假设成立的概率极小。

关键词：股票收益预测、相对收益、分类、随机森林、支持向量机、长短期记忆网络、机器学习

介绍

鉴于股票市场数据中存在的非线性和非平稳波动，股票市场预测极具挑战性。经济环境、政治事件和投资者情绪等外部因素进一步加剧了这一问题的复杂性。法玛（Fama，1995)提出的随机游走假说认为股票价格变动本质上是随机的；因此，试图准确预测未来股票价格的努力注定失败。同样，有效市场假说（马尔基尔，1989)也指出，无法根据历史数据预测股票价格的未来变动。然而，许多经济学家和股票市场参与者认为，股票价格至少在一定程度上是可以预测的，因为价格变动往往会由于投资者的集体和系统性行为而重复出现（Shah et al. 2019; Chong et al. 2017）。

© 作者 2024。开放获取。本文根据知识共享署名 4.0 国际许可协议授权，允许在任何媒介或格式下使用、共享、改编、分发和复制，前提是您必须注明原作者和来源，提供指向知识共享许可协议的链接，并说明是否进行了修改。本文中的图像或其他第三方材料均包含在本文的知识共享许可协议中，除非材料的署名另有说明。如果材料未包含在本文的知识共享许可协议中，且您的预期用途不符合法定规定或超出许可范围，则您需要直接从版权所有者处获得许可。要查看此许可协议的副本，请访问http://

creativecommons.org/licenses/by/4.0/。

Machine Translated by Google

以往的研究运用基于机器学习（ML)的方法来预测股票价格。
例如,Kumar等人（ 2016)的研究利用多种技术指标作为输入,通过近端支持向量机（PSVM)预测了12个股票指数未来一天的收盘价走势。Aloraini （2015)的研究预测了沙特阿拉伯股市11家上市公司的每日开盘价走势。Nayak等人（ 2021)的研究则采用一种组合方法，即结合粗糙集模型的支持向量机（SVM），预测了两个印度基准指数的收盘价百分比变化。研究表明,在所选数据集上,该混合方法的准确率优于决策树、朴素贝叶斯和人工神经网络（ANN）。Ruxanda和Badea （2014)则利用滞后价格和宏观经济指标构建了人工神经网络，用于预测罗马尼亚BET指数未来一天的数值。

这些研究试图预测未来股价的走势。我们发现这种方法存在两个缺陷：(1)这些研究侧重于股价变动而非相对收益；(2)它们分析的公司数量相对较少,不足以得出具有统计意义的结论。

本研究探讨了一个相对股票收益分类问题,该问题允许基于2017年至2022年期间标普500指数所有股票的时间序列价格数据进行股票选择。我们将基于机器学习的方法与随机选股方法的有效性进行了比较。

本研究的其余部分组织如下。 “相关工作”部分回顾了以往的相关工作。 “数据与方法”部分定义了问题,并详细说明了分析中使用的输入特征、类别标签和机器学习（ML)预测模型。 “结果”部分展示了针对标普500指数股票的实验结果和发现,并与随机选择（RC)分类器进行了比较。 “结论”部分总结了本研究。

相关工作

一般来说,股票市场分析可根据所用数据类型分为两类:基本面分析和技术分析。基本面分析（Heo和Yang，2016)基于公司的盈利、收入、股息以及其他财务业绩指标来预测股票价格。Chen等人（2017)使用营业收入、资产回报率和税前利润等财务指标来选择台湾股市的股票。另一项研究（Li等人， 2022)使用包括市盈率、市净率、市销率和市现率这四个基本面指标在内的35个特征来预测上海证券交易所股票未来一天的收盘价。另一项研究（Yuan et al. 2020)应用了包括净利润、股息和股本回报率在内的各种基本指标,利用支持向量机（SVM）、随机森林（RF)和人工神经网络（ANN)方法来预测中国A股市场的股票收益。

技术分析（Nazario et al. 2017)利用基于历史市场数据（例如价格和成交量)计算出的指标来预测股票价格。多项研究（AI-Shamery and AI-Shamery 2018; Lin 2018; Patel et al. 2015)使用指数移动平均线（EMA）、相对强弱指数（RSI）、随机振荡指标和变化率等技术指标来预测不同股票市场的走势。Picasso et al. （2019）使用十种常用技术指标来生成买卖信号。

Machine Translated by Google

Dai等人（2020)提出了一种涉及纳斯达克100指数中20家公司的交易策略。他们引入并应用了基于EMA和RSI的新技术指标,以提高某些交易策略的可预测性。

股票市场预测中最基本的预测方法之一是统计模型,例如自回归移动平均模型（ARMA）(Lv et al. 2022）,该模型广泛用于根据平稳时间序列数据预测股票市场指数的变化。对于短期股票市场预测,自回归积分移动平均模型（ARIMA）(Jarrett and Schilling 2008)也十分流行。一项研究将ARIMA与人工蜂群算法（ABC)相结合。

Kumar等人（ 2022)提出了一种算法,用于对印度国家证券交易所（NSE)和孟买证券交易所的股票价格进行一步预测和多步预测。支持向量机（SVM)已成为回归和分类问题中常用的机器学习技术。Nabi等人（2019）使用分类器预测了纳斯达克交易所10只股票的月度收盘价走势,并发现基于样本平均准确率,SVM在二元分类方面表现最佳。另一项研究（Siddique和Panda， 2019)将SVM作为回归器,用于预测塔塔汽车的次日收盘价。Chen和Hao （2017)则基于九项技术指标,应用SVM预测了两个中国股票市场指数未来1、5、10、15、20和30天的走势。他们运用信息增益法考察了各指标的相对重要性,并得出结论:支持向量机（SVM)方法稳健可靠,且对其所选指标具有较强的预测能力。Kou等人（2021)应用了四种特征选择方法（包括信息增益法）,以确定用于预测中小企业破产的最佳特征子集。他们探讨了特征选择过程在提升预测模型性能方面的重要性。

Henrique等人（2018)利用常用的技术指标作为支持向量机（SVM)模型的输入,预测了巴西、美国和中国股市中多种股票的价格。结果表明,采用线性核函数的SVM模型优于其他类型的核函数。另一项研究（Nti等人， 2020)将SVM与遗传算法（GA)相结合,考察了过去11年加纳股市两只股票在未来10天股价走势预测方面的表现。

基于树的集成方法也被用于预测股票价格的未来走势（Basak et al. 2019）。多种集成方法,包括随机森林（RF）、XGBoost、bagging、AdaBoost、额外树和投票分类器（Ampomah et al. 2020）,已被应用于预测在纽约证券交易所（NYSE）、纳斯达克（NASDAQ)和印度国家证券交易所（NSE)交易的股票价格。额外树在样本中所有股票的平均F1分数最高,尽管每种分类器对不同股票的准确率有所不同。

在各种基于树的方法中,随机森林（RF）(Breiman 2001)因其方差低、能够提供特征重要性评分且适用于回归和分类问题而备受关注。Patel等人（2015)基于四家公司10年的数据,考察了人工神经网络（ANN）、支持向量机（SVM）、随机森林（RF)和朴素贝叶斯这四种预测模型的整体性能,发现随机森林在趋势预测方面优于其他模型。另一项研究（HongXing等人， 2022)利用13年的数据,将多种机器学习模型应用于波动性极高的巴基斯坦股市,并得出结论:随机森林最适合非线性近似。

Machine Translated by Google

随机森林（RF)也可作为特征选择技术,从而提高价格和收益预测的准确性。Labiad等人（ 2016)的研究利用随机森林提供的平均杂质减少量和平均准确率减少量来选择特征,用于预测摩洛哥股市的超短期波动,例如提前10分钟的预测。

Kumar等人（2016)运用包括随机森林（RF)在内的四种特征选择技术,从55个技术指标中筛选出最佳特征,并将其与倾向得分匹配向量机（PSVM)结合使用,以预测未来一天的收盘价。对于所有选定的数据集,RF-PSVM是唯一在准确率方面优于PSVM模型的混合模型。因此,RF模型在众多股票市场应用中一直保持着顶级预测模型的地位。其他特征选择方法也适用于股票市场预测和其他金融领域。例如,Xu等人（2024)运用包装器方法和遗传算法（GA)来选择特征,以评估北美银行信用评分模型的盈利和风险。

另一项研究（Chandar 2022)应用了一种基于卷积神经网络（CNN)的方法,该方法利用从历史数据中提取的十个技术指标转换而来的价格图表。作者评估了该方法在纳斯达克和纽约证券交易所上市公司的准确率和F1值。为了利用价格图表和股票基本面预测短期股价,Liu等人（ 2022)使用了一种深度神经网络（DNN） ,并得出结论:在预测未来价格走势方面,价格趋势比市盈率等基本面因素更为重要。Aasi等人（2021)则应用了一种长短期记忆（LSTM)模型,利用包括谷歌趋势、推文和SeekingAlpha新闻评论在内的九个情感分析特征,提前一周预测苹果公司的收盘价。

混合模型是目前应用最广泛的股票价格预测机器学习技术之一,因为与单一方法相比,它们能产生更准确的结果。

Chen 等人 (2022)的研究并未采用单一数据集,而是利用 K-means 聚类算法对 16 家上市银行的股票价格进行聚类,以找到价格模式相似的银行。然后,他们基于聚类后的数据训练了一个 LSTM 模型。结果表明,K-means 和 LSTM 的混合模型比仅使用单一银行数据的 LSTM 模型误差更低。Srivinay 等人 (2022)的研究也提出了一种基于预测规则集成 (PRE) 技术的混合股票预测模型。该模型创建了一组预测规则,并基于逻辑语句和深度神经网络 (DNN) 方法生成各种决策树。作者使用移动平均技术指标作为输入,并将 PRE 和 DNN 预测模型的平均值作为最终预测值。他们获得了印度股市更低的均方根误差 (RMSE) 值,并得出结论:所提出的混合模型优于单独的 DNN 和人工神经网络 (ANN) 模型。

先前的一项研究（Chen et al. 2020)比较了随机森林（RF）、支持向量机（SVM)和人工神经网络（ANN)方法在预测标普500指数收益率方面的性能。作者使用10个技术指标作为输入,并应用每种机器学习方法进行预测。在三种方法中,RF在2014年至2018年的整个样本期内,无论是在日收益率还是累计收益率方面,都取得了最佳结果。另一项研究（Krauss et al. 2017)应用了RF、梯度提升树、深度神经网络（DNN)以及这些模型的集成模型,对标普500指数中所有股票的次日简单收益率进行二元分类。作者使用指数中每只股票的滞后一年收益率训练每个模型,然后预测它们的次日收益率。他们发现,所提出的集成方法优于所有单个模型。

Machine Translated by Google

就准确率而言,Fischer 和 Krauss (2018)将 LSTM 应用于二元分类问题,以预测标普 500 指数所有股票未来一天的收益率。他们使用 1992 年至 2015 年的数据,将 LSTM 与其他机器学习方法(包括深度神经网络 (DNN)、逻辑回归分类器和随机森林 (RF))进行了比较。Gaspareniene 等人(2021)使用决策树、随机森林和前馈神经网络方法预测标普 500 指数的月度值。他们发现,随机森林的准确率比使用线性回归的基准模型高出 19%。通过结合基本面和技术面数据,一项研究 (Singh Khushi 2021)预测了标普 500 指数股票未来 10 天收盘价变动的方向,精度为 1%。

现有的大多数研究试图预测收盘价或简单收益率,预测周期可以是小时、天、周或月,并应用各种预测模型、数据集和评估标准。我们观察到,在将机器学习预测模型应用于股票市场时,随机森林(RF)和支持向量机(SVM)是应用最广泛的预测方法,因为它们在分类和回归问题上都具有灵活性。随机森林是最受欢迎的方法之一,因为它具有泛化能力强、简单易用、稳健性高和方差低等优点,因此在预测结果方面表现良好。本研究侧重于预测相对收益率,即个股收益率与市场指数收益率之间的差值,而不是绝对价格或收益率。因此,我们检验机器学习方法在以历史相对收益率作为输入的情况下,预测未来相对收益率的能力。结果表明,在2017年至2022年期间,基于机器学习的分类方法优于使用标普500指数所有公司的随机选股方法。

数据和方法

问题定义

我们描述了一个二分类问题,旨在识别在特定时间段(十个交易日,称为预测期)内相对收益率高于特定阈值(2%)的股票。我们使用由相对收益率构成的特征向量训练股票特定分类器和时间段特定分类器。然后,我们使用每个分类器来预测相应的股票在接下来的十个交易日内是否会产生高于2%阈值的相对收益率(类别1),或者不会(类别0)。

特征和特征向量的定义与计算

我们从雅虎财经(https://finance.

yahoo.com/)。由于我们的数据源在2020年之前缺少11只股票的价格数据,因此我们在实验中使用了494只股票。表1列出了不同行业的标普500指数成分股示例。原始数据集包含日期、开盘价、最高价、最低价、收盘价和交易量。以往的研究(Rana et al. 2019; Al Wadi et al. 2018)表明,在这些输入数据中,收盘价最为重要,因此我们在研究中也使用收盘价来计算特征。

在股票市场预测中,人们使用了不同类型的输入数据,包括历史价格、基于历史价格的技术指标以及基本面指标。选择使用哪种类型的输入数据是成功预测的关键。本研究探讨了历史价格数据对股票市场预测的有效性。

Machine Translated by Google

表1标普500指数不同板块股票示例

不	部门	公司（符号）
1	工业	AOS、MMM、ALK、ALLE、……
2	卫生保健	ABT、ABBV、ALGN、ABC、……
3	信息技术	ADBE、ADP、AKAM、AMD……
4	通信服务	ATVI、GOOGL、CHTR、……
5	公用事业	LNT、AES、AEP、……
6	财务	AON、BLK、COF、……
7	房地产	ARE、BXP、CCI、DLR、……
8	非必需消费品	Etsy、Expe、通用汽车……
9	活力	KMI、SLB、VLO、WMB、……
10	生活必需品	WMT、WBA、PEP、TAP、……
11	材料	LYB、NUE、SHW、……

表 2 GOOGL 股票的特征向量

不	日期（当前日期 i）	X(i,260)	X(i,180) … X(i,15)		X(i,10)	X(i,5)	X(i,1)
1	2018年1月16日	16.96	5.85	… 2.16	3.49	0.43	0.35
2	2018年1月17日	17.59	4.76	… 2.12	2.17	0.5	-0.19
3	2018年1月18日	16.40	4.20	… 2.19	0.94	0.51	-0.113
989.	2021年12月16日	32.19	19.50	… −0.44	−0.96	−2.18	−0.48

每个特征向量包含 13 个不同时期的相对收益率,范围从 1 年 X(i,260) 到 1 天 X(i,1) 不等。

不同时间段（例如日、周、月、季度和年)的相对收益率可以预测未来的相对收益率。我们定义并计算个股在时刻 i 相对于时刻 i − k 的收益率如下：

$$R(i, k) = \frac{P(i) - P(i - k)}{P(i - k)} * 100 \quad (1)$$

其中 P(i) 是股票在 i 时刻（当前日期)的收盘价,P(i-k) 是同一股票在前一日期 i-k 的收盘价,k=260、180、150、120、100、80、60、40、20、15、10、5 和 1。

我们还使用公式 1计算标普 500 指数的收益率RSP (i,k)。为了将个股收益率的变化与市场整体联系起来,我们计算相对收益率 X (i,k),即个股收益率与指数收益率之差：

$$X(i, k) = R(i, k) - RSP(i, k)。 \quad (2)$$

我们使用股票的13个相对收益率来构建一个13维特征向量，

对于每个 k 值,分别用 X(i, 260)、X(i, 180)、X(i, 150)、X(i, 120)、X(i, 100)、X(i, 80)、X(i, 60)、X(i, 40)、X(i, 20)、X(i, 15)、X(i, 10)、X(i, 5) 和 X(i, 1) 来表征该股票在时间 i 的特征。表 2展示了一只股票的示例。我们将这些特征向量作为输入,使用机器学习方法训练一个股票分类器。

Machine Translated by Google

类别标签的定义和计算

我们根据给定股票在当前交易日后10个交易日内的相对收益率,为每个特征向量分配一个二元类别标签。如果未来10个交易日中的某个相对收益率大于指定的阈值d,则将类别标签y(i)设置为1;否则,设置为0。

$$y(i) = \begin{cases} 1,\text{如果 } \max(i+k, k=1,2,\ldots,10) > d; \\ \text{否则为 } 0。 \end{cases} \quad (3)$$

表3显示了使用不同阈值d值时,各类股票被分配到类别1标签的比例。我们使用所有股票在所有交易日中观察到的类别1比例的平均值作为类别1概率p(1)的近似值。我们观察到,随着d的增加,p(1)减小。例如,当d=0.3%时,p(1)=0.77;而当d=10%时,p(1)=0.06。当d=2%时,两类大致平衡,p(1)=0.49,p(0)=0.51。因此,为了避免通常与类别不平衡相关的机器学习问题,我们使用d=2%。

使用正阈值 d 的经济原理在于找到一种方法来筛选出表现优于指数的股票。如果某只股票在第 t 天被正确预测为 1 类,则可以将其作为买入信号,从而在接下来的十个交易日内获得相对收益 d (d>0)。遵循此规则的投资者可以选择在达到阈值 d 时立即卖出股票并锁定相对收益 d,或者如果该股票在相对收益再次达到阈值 d 的当天被预测为 1 类,则选择继续持有。假设对每只被预测为 1 类的股票都投入相同的固定金额,那么一个始终能够给出正确预测的系统……

在10天的时间内,所有股票的总相对收益率等于p(1)d与d的乘积。例如,如果d=0.3%且p(1)=0.77,则p(1)d=0.231%,在这种情况下,可投资股票的比例(即p(1))很高,但每只股票的相对收益率d很低。相反,如果d=10%且p(1)=0.06,则p(1)d=0.6%,每只股票的相对收益率很高,但可投资股票的比例很低。如果d=2%且p(1)=0.49,则p(1)d=0.98%。总相对收益率在d值接近类别平衡时达到峰值,在本例中,d=2%。

达到近似类别平衡所需的 d 值与时间范围(即所考虑的交易日数量)相关。交易日数量越多,达到近似类别平衡所需的 d 值就越高。

表 3每只股票的 1 类比例 p(1) 作为收益阈值 d 的函数,p(0)=1−p(1)

无股票	p(1)	d=0.3%	p(1) d=0.5%	… p(1) d=1.8%	p(1) d=2%	p(1) d=2.2%	… p(1) d=9.5%	p(1) d=10%
1	AMAT	0.82	0.80	… 0.62	0.61	0.59	… 0.12	0.11
2	BSX	0.79	0.75	… 0.50	0.48	0.44	… 0.02	0.02
3	CDNS	0.84	0.82	… 0.61	0.59	0.55	… 0.05	0.05
4	药代动力学	0.82	0.79	… 0.63	0.60	0.56	… 0.09	0.08
493	SIVB	0.80	0.77	… 0.62	0.60	0.57	… 0.14	0.13
494	ZTS	0.83	0.80	… 0.55	0.51	0.47	… 0.02	0.01
	平均值 0.77		0.74	… 0.52	0.49	0.47	… 0.06	0.06

我们使用所有股票和所有交易日中观察到的1类股票比例的平均值作为1类股票概率p(1)的近似值。

Machine Translated by Google

股票必须达到相对收益阈值 d 的天数越多,实现类别平衡所需的阈值 d 就越大。在我们的研究中,实现近似类别平衡的阈值 d=2% 由我们选择的交易日数（即 10 天)决定。

采用滑动窗口方法进行训练和测试

我们使用滑动窗口方法将数据集分为训练集和测试集（图 1）。

对于每只股票,我们使用连续12个月（253个交易日)的数据来训练分类器。经过10个交易日的间隔后,我们使用下个月（21个交易日)的数据来测试该分类器的性能。我们使用2017年的数据来计算特征向量,第一个训练周期为2018年1月16日至2019年1月16日。类别标签取决于接下来10个交易日的相对收益率。因此,每个测试周期的第一天都从相应训练周期的最后一天后10天开始。

第一个测试期为2019年2月1日至2019年3月4日。之后,窗口向前移动一个月,并训练一个新的分类器,然后进行测试。此过程重复23次,最终对标普500指数中的每只股票产生483个预测结果（=21*23）。

随机森林（RF)分类器

我们使用随机森林（RF)作为分类器,其构建方式如下。对于每个训练集,我们生成多个自举数据集,每个数据集的大小与训练集相同,但使用的特征向量是通过对训练集进行有放回的行抽样随机选择的。

对于每个自举数据集,我们使用该数据集构建决策树,并在每次分裂时应用随机特征子集,直到树完全生长或达到停止准则。对于我们训练的每个随机森林,我们使用 1000 棵树,每棵树最多包含 13 个特征,最大深度为 5。我们在 Python 3.7 的 scikit-learn 环境（Pedregosa 等人， 2011)中实现了随机森林分类器。对于每只股票,我们训练 23 个随机森林,分别对应于滑动窗口的 23 个位置。在为给定股票和滑动窗口位置训练好随机森林后,我们使用相应的测试集测试其性能。随机森林分配给特定特征向量的类别是通过随机森林中所有树的多数投票决定的。

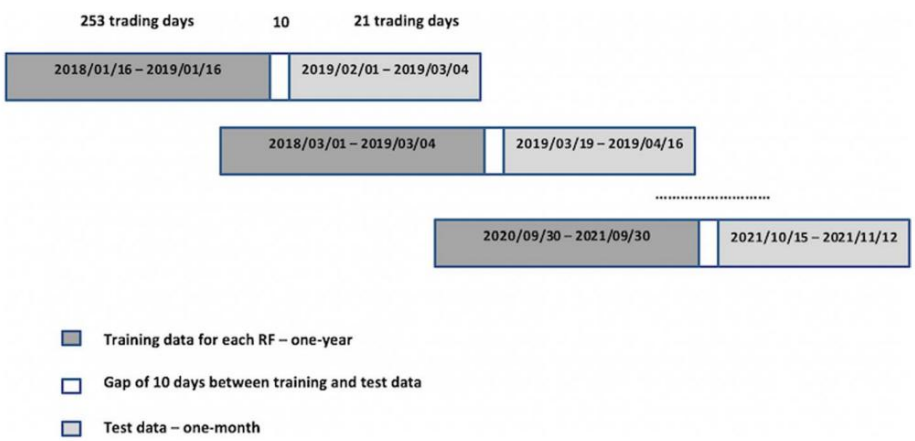


图 1 所示的滑动窗口包含一个连续 253 个交易日的训练数据块,之后是 10 个交易日的间隔,再包含一个 21 个交易日的测试数据块。该窗口以 21 个交易日（1 个月)为单位移动 23 次。

Machine Translated by Google

支持向量机（SVM)分类器

我们还应用了支持向量机（SVM)作为分类器。对于每个训练集,我们使用 scikit-learn 环境（Pedregosa 等， 2011)构建 SVM 分类器。在针对给定股票和滑动窗口位置训练好 SVM 分类器后,我们评估其在相应测试集上的性能。我们测试了基于不同核函数的 SVM 分类器,包括线性核、径向基函数（RBF)核以及正则化参数 C=1.0 的多项式核。我们发现,对于样本中的大多数股票,RBF 核产生了最佳结果（更高的准确率）。

长短期记忆（LSTM)分类器

为了考虑数据的时序性,我们使用与随机森林（RF)和支持向量机（SVM)分类器相同的训练和测试数据集,应用长短期记忆网络（LSTM)方法作为分类器。为了配置我们的LSTM网络,我们调整了几个重要的超参数,包括单元数或隐藏层维度、LSTM层数、批大小和训练轮数（迭代次数）。我们最初的LSTM网络设置只有一个层,单元数和迭代次数都很少。随后,通过一系列实验和基于所有494只股票整体性能的微调,我们最终通过配置网络获得了最高的准确率、精确率和召回率。该网络包含三个LSTM层（每个层包含260个单元）、两个dropout率为0.2的dropout层、一个Dense层、批大小为64、Adam优化器和sigmoid激活函数,并训练了200个epoch。我们使用 Keras 开发 LSTM 分类器,Keras 构建于 Google TensorFlow 库 (https://www.tensorflow.org/) 之上。

结果

我们使用准确率、精确率和召回率来衡量分类性能：

$$\text{一个 准确度} = \frac{TP + TN}{TP + TN + FP + FN} \tag{4}$$

$$P(\text{精度}) = \frac{TP}{TP + FP} \tag{5}$$

$$R(\text{回忆}) = \frac{TP}{TP + FN} \tag{6}$$

其中 TP=真阳性数,TN=真阴性数,FP=假阳性数,FN=假阴性数。

我们基于用于测试的 483 个交易日,以及针对每只股票在滑动窗口 21 个不同位置训练的 23 个分类器（随机森林、支持向量机或长短期记忆网络）,计算每只股票的 A、P 和 R 值。我们比较了随机森林和支持向量机的分类性能,发现对于大多数股票,这两种分类器的性能相近。

我们对不同股票获得的ARF-ASVM、 PRF-PSVM和RRF-RSVM的值集应用单侧配对 t 检验,以检验它们的均值是否为正。

我们得到准确率的 t 值为 −1.93,p 值为 0.054;精确率的 t 值为 2.2,p 值为 0.03;召回率的 t 值为 3.5,p 值为 0.0005。关于准确率和精确率,p 值分别为：

Machine Translated by Google

样本量不足以得出两种方法孰优孰劣的结论。随机森林（RF)在召回率方面优于支持向量机（SVM）（p=0.0005）。因此,接下来我们将RF的分类性能与长短期记忆网络（LSTM)进行比较,并对每只股票的ALSTM-ARF、 PLSTM-PRF和RLSTM-RRF值集应用单侧配对t检验,以检验它们的均值是否为正。我们得到的准确率t值为2.88,p值为0.004;精确率t值为4.05,p值为5.8e-05;召回率t值为8.37,p值为6.04e-16。因此,在所有三个指标（准确率、精确率和召回率)上,LSTM分类器均表现出优于RF和SVM分类器的性能。我们在表 6、表 7 和表 8 中分别以ALST M、 PLST M 和RLST M为列,展示了最佳分类器 LSTM 的准确率、精确率和召回率。

接下来,我们将 LSTM 分类方法与随机选择 (RC) 进行比较。
分类器。对于概率为 p(1) 的 RC 分类器（类别 1）,我们可以证明：

$$TPRC = np(1)p(1) \tag{7}$$

$$TNRC = n(1 - p(1))(1 - p(1)) \tag{8}$$

$$FPRC = np(1)(1 - p(1)) \tag{9}$$

$$FNRC = np(1)(1 - p(1)) \tag{10}$$

其中 n 为用于测试的交易日数。

将式 7–10 分别代入式 4–6 中的TPRC 、 TNRC、 FPRC和FNRC ,得到：

$$ARC = p(1)^2 + (1 - p(1))^2 \tag{11}$$

$$PRC = p(1) \tag{12}$$

$$RRC = p(1) \tag{13}$$

当 p(1)=0.49 时,我们得到：

$$\text{弧度} = 0.5001 \tag{14}$$

$$PRC = 0.49 \tag{15}$$

$$RRC = 0.49 \tag{16}$$

我们的样本期涵盖了2019年（新冠疫情爆发前一年)以及2020年和2021年（新冠疫情爆发期间）。因此,我们分别针对每一年评估了LSTM分类器和RC分类器的性能,以分析不同的市场状况和时期。我们分别确定了每一年的p(1)值,如表4所示。

同样,我们也计算了这些年份的准确率、精确率和召回率（表5）。LSTM 分类器在 2020 年取得了最高值,在 2019 年取得了最低值。在 2019 年至 2021 年的整个样本期内,LSTM 的表现最佳。

Machine Translated by Google

表 4各年份的 p(1) 值,p(0)=1－p(1)

	2019年	2020年	2021年	2019–2021
p(1)	0.43	0.57	0.48	0.49

我们使用所有股票中观察到的1类股票比例的平均值作为1类股票概率p(1)的近似值。

表5 LSTM分类器和RC分类器每年的平均准确率、精确率和召回率

	2019年		2020年		2021年		2019–2021	
	LSTM	遥控车	LSTM	遥控车	LSTM	遥控车	LSTM	遥控车
准确性	0.51	0.51	0.53	0.51	0.52	0.50	0.52	0.50
精确	0.43	0.43	0.58	0.57	0.50	0.48	0.503	0.49
记起	0.52	0.43	0.58	0.57	0.58	0.48	0.56	0.49

LSTM分类器的性能在2020年最高,在2019年最低。

表 6 ALSTM在 LSTM 分类中的准确率值以及ALSTM－ARC与ARC 的差异（ARC=0.5001）,随机选择分类器,类别 1 的概率 p(1)=0.49

不	库存	ALSTM	ALSTM-ARC
1	AMAT	0.59	0.09
2	BSX	0.57	0.07
3	ENPH	0.80	0.31
4	Etsy	0.64	0.14
5	线性纳米管	0.48	－0.02
493	SIVB	0.59	0.09
494	中途岛	0.50	－0.0001
平均值		0.52	0.02
合并价值		0.52	0.02

LSTM 的平均准确率值ALSTM大于随机选择分类器（p=8.46e－17）。

表 7 PLSTM在 LSTM 分类中的精确度值以及PLSTM 与 PRC 的差异（PRC=0.49）,其中 PRC为类别 1 的概率 p(1)=0.49。

不	库存	PLSTM	PLSTM-PRC
1	AMAT	0.71	0.22
2	BSX	0.46	－0.03
3	ENPH	0.83	0.34
4	Etsy	0.73	0.24
5	线性纳米管	0.39	－0.09
493	SIVB	0.66	0.17
494	中途岛	0.52	0.03
平均值		0.503	0.012
合并价值		0.51	0.02

LSTM 的平均精度值PLSTM大于随机选择分类器（p=0.008）。

Machine Translated by Google

表 8 RLSTM对 LSTM 分类的召回率以及RLSTM 与 RRC 的差异（RRC=0.49），其中随机选择分类器（类别 1 的概率 p(1)=0.49）

不	库存	RLSTM	RLSTM-RRC
1	AMAT	0.66	0.17
2	BSX	0.63	0.14
3	ENPH	0.96	0.47
4	Etsy	0.83	0.34
5	线性纳米管	0.48	−0.01
493	SIVB	0.65	0.16
494	中途岛	0.59	0.1
平均值		0.56	0.07
合并价值		0.57	0.08

LSTM 的平均召回率比RLSTM大（p=1.29e−31）。

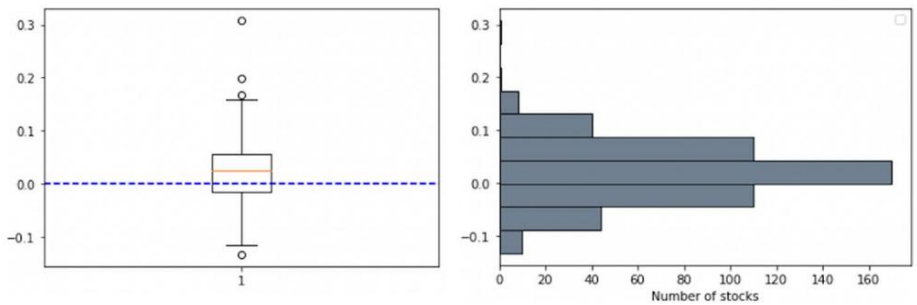


图 2为 LSTM 和 RC 分类器准确率差异的箱线图（左)和直方图（右）。准确率差异为负值的股票数量为 169 只。平均差异为正值（t=8.63,p=8.46e−17）。

分类方法在准确率、精确率和召回率的所有平均值方面都优于 RC 分类器。

表 6、7和8分别显示了所有股票的准确率、精确率和召回率的平均值,以及由所有股票的真阳性 (TP)、真阴性 (TN)、假阳性 (FP) 和假阴性 (FN) 值计算出的“汇总值”。ALSTM 、 PLSTM和RLSTM在所有股票和测试周期内的汇总值均高于随机选择分类器对应的ARC、 PRC和RRC 。准确率、精确率和召回率的平均值也呈现相同的趋势。

为了确定我们能否可靠地断言 LSTM 分类方法优于随机选择分类器,我们对针对个股获得的ALSTM－ARC、PLSTM－PRC和RLSTM－RRC的值集应用了单侧配对 t 检验。我们发现这些差异的均值为正,准确率的 t 值为 8.63,p 值为 8.46e－17;精确率的 t 值为 2.64,p 值为 0.008;随机选择分类器的 t 值为 12.57,p 值为 1.29e－31。

因此,我们可以非常有信心地断言,LSTM 分类方法在所有性能指标（准确率、精确率和召回率)上都优于随机选择分类方法。

在图2、3和4 中,箱线图和直方图展示了 LSTM 分类器和 RC 分类器在所有股票上的准确率、精确率和召回率差异的分布情况。

Machine Translated by Google

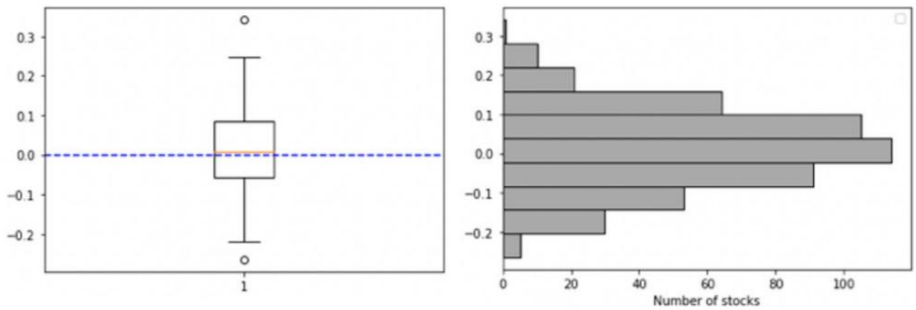


图 3为 LSTM 和 RC 分类器精度差异的箱线图（左)和直方图（右）。精度差异为负值的股票数量为 228 只。平均差异为正值（t=2.64，p=0.008）。

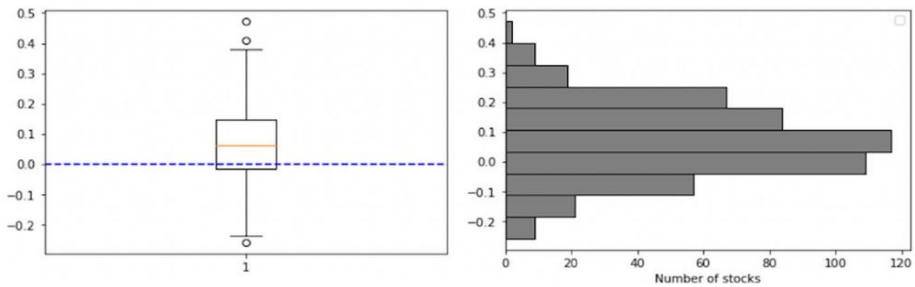


图 4为 LSTM 和 RC 分类器召回率差异的箱线图（左)和直方图（右）。召回率差异为负值的股票数量为 145 只。平均差异为正值（t=12.57,p=1.29 e−31）。

结论

在本研究中,我们使用多个历史相对收益率作为随机森林（RF）、支持向量机（SVM)和长短期记忆网络（LSTM)分类器的输入特征,以识别在特定时间段内（十个交易日的时间跨度)相对于标普500指数产生超过特定阈值（2%)的相对收益率的股票。我们使用2017年1月至2022年1月期间标普500指数中494只股票的数据进行实验,结果表明：

- 随机森林（RF)和支持向量机（SVM)的分类准确率和精确率相近。随机森林在召回率方面优于支持向量机（p=0.0005）。
- 基于均值,LSTM 分类器的性能优于 RF 和 SVM。
  在所有股票中准确率、精确率和召回率。
- 在所有股票的准确率、精确率和召回率的平均值方面,LSTM 分类器也优于随机选择分类器,相应的 t 统计量和 p 值分别为：准确率 t=8.63,p=8.46e−17;精确率 t=2.64,p=0.008;召回率 t=12.57，p=1.29e−31。

- 准确率、精确率和召回率的 p 值都非常小,这表明在所考虑的问题中,随机游走假设和有效市场假设为真的概率可以忽略不计。

- 使用先前相对收益作为输入的机器学习分类器在选股方面比随机选择具有优势。

Machine Translated by Google

在未来的研究中,我们将使用不同类型的特征,包括各种技术指标进行分析。我们还计划探索不同训练和测试周期的影响。此外,我们将扩展预测分析,以涵盖不同的训练窗口大小、时间跨度和收益阈值。

缩写

一个 准确性
ABC 人工蜂群
ANN 人工神经网络
ARIMA 自回归移动平均
ARMA 自回归移动平均
CNN 卷积神经网络
DNN 深度神经网络
EMA 指数移动平均线
有效市场假说 (EMH)
前馈神经网络（FFNN）
前线 假阴性数量
FP 假阳性数量
GA 遗传算法
GBT 梯度提升树
日志 逻辑回归分类器
LSTM 长短期记忆网络
机器学习 机器学习
国家证券交易所 国家证券交易所
P 精确
预 预测规则集合
PSVM 近端支持向量机
拉 记起
RBF 径向基函数
遥控车 随机选择
射频 随机森林
ROA 资产回报率
RSI 相对强度指数
支持向量机 支持向量机
TN 真阴性数量
TP 真阳性数量

致谢
作者谨此感谢格罗宁根大学和缅甸展望组织的支持。

作者贡献

HH负责收集和生成数据,并构建特征向量。HH进行了正式分析、机器学习方法选择、程序实现、训练和测试数据选择,以及结果和发现的调查。HH撰写了论文初稿。NP定义了研究目标和范围,给出了特征向量、类别标签和用于比较的随机选择分类器的定义;推荐了机器学习方法、性能比较方法和测试以及结果展示形式;撰写了部分文本并为HH争取了研究经费;NP和MB审阅并编辑了稿件,并指导了研究工作。所有作者均阅读并批准了最终稿件。

资金
这项研究工作由格罗宁根大学和缅甸展望组织资助。

数据和材料的可用性
本研究过程中生成或分析的所有数据均已公开,并包含在本文中。

声明

利益冲突
作者声明不存在利益冲突。

收稿日期:2022年11月29日 接受日期:2024年2月27日
Published online: 20 April 2024

Machine Translated by Google

参考

Aasi B、Imtiaz SA、Qadeer HA、Singarajah M、Kashef R (2021) 使用多元多步 LSTM 进行股票价格预测：
情感和公众参与分析模型。载于：IEMTRONICS，第1-8页。

Al Wadi S、Almasarweh M、Alsaraireh AA (2018) 使用 ARIMA 模型预测收盘价时间序列数据。现代应用科学
12(11):181–185

Aloraini A (2015) 时间序列环境中隐藏关联的惩罚集成特征选择方法
研究：沙特阿拉伯证券交易所的股票公司。进化系统 6:93–100

Al-Shamery E, Al-Shamery AA (2018) 基于技术指标增强纳斯达克股票市场预测. 工程学报
应用科学 13:4630–4636

Ampomah EK、Qin Z、Nyame G (2020) 基于树的集成机器学习模型在预测股票价格走势方面的评估。信息 11:332

Basak S、Kar S、Saha S、Khaidem L (2019) 使用基于树的分类器预测股票市场价格方向。北美
《经济与金融杂志》47：552–567

Breiman L (2001) 随机森林.机器学习 45:5–32

Chandar SK (2022) 基于技术指标的股票交易卷积神经网络. Autom Softw Eng 29:1–14

Chen Y, Hao Y (2017) 基于特征加权支持向量机和K近邻算法的股票市场指数预测. Expert Syst Appl 80:340–355

Chen YJ, Chen YM, Lu CL (2017) 基于改进的基本面分析方法增强股票市场预测. Soft Comput 21:3735–3757

Chen C, Chen C, Liu T (2020) 机器学习的投资绩效：标普500指数分析. 国际经济与金融杂志
第10期：59-66页

Chen Y, Wu J, Wu Z (2022) 基于新型 K-means-LSTM 混合方法的中国商业银行股票价格预测。
专家系统应用 202:117370

Chong E、Han C、Park FC (2017) 用于股票市场分析和预测的深度学习网络：方法论、数据
表示方法和案例研究。专家系统应用 83:187–205

戴志强、董旭、康杰、洪磊 (2020) 股票市场收益预测：新的技术指标和两步经济约束法. 北美经济与金融杂志 53:101216

Fama EF (1995) 股票市场价格的随机游走。金融分析杂志 51(1):75–80

Fischer T, Krauss C (2018) 基于长短期记忆网络的深度学习在金融市场预测中的应用。欧洲期刊
运筹学 270:654–669

Gaspareniene L, Remeikiene R, Sosidko A, Vebraite V (2021) 基于美国经济指标的标普500指数价格建模：机器学习方法。工程经济学 32:362–375

Henrique BM、Sobreiro VA、Kimura H (2018) 使用支持向量回归对日线及未来几天的股票价格进行预测
分钟价格。金融数据科学杂志 4:183–201

Heo J, Yang JY (2016) 基于财务报表的SVM股票价格预测. 混合信息技术杂志 9(2):57–66

HongXing Y、Naveed HM、Answer MU、Memon BA、Akhtar M (2022) 评估 MLM 的最优预测性能
基于高波动性金融市场数据。国际计算机科学与应用高级期刊 13

Jarrett JE, Schilling J (2008) 法兰克福证券交易所（股票市场)的日波动及股票市场收益预测。J
商业经济管理 9:189–198

Kou G, Xu Y, Peng Y, Shen F, Chen Y, Chang K, Kou S (2021) 基于交易数据和两阶段多目标特征选择的中小企业破产预测. 决策支持系统 140:113429

Krauss C、Do XA、Huck N (2017) 深度神经网络、梯度提升树、随机森林：统计套利
标准普尔 500。欧洲 J 操作研究 259:689–702

Kumar D、Meghwani SS、Thakur M (2016) 基于近端支持向量机的混合预测模型在金融市场趋势预测中的应用。计算机科学杂志 17:1–13

Kumar R、Kumar P、Kumar Y (2022) 基于 ARIMA 和进化算法的多步时间序列分析与预测策略
算法。国际信息技术杂志 14:359–373

Labiad B、Berrado A、Benabbou L (2016) 用于短期股票走势分类的机器学习技术
摩洛哥证券交易所。载于：第十一届SITA会议，摩洛哥穆罕默迪亚，2016年。

李刚、张安、张强、吴丹、詹超 (2022) 基于皮尔逊相关系数的广义性能提升
用于股票价格预测的学习系统。IEEE 电路与系统汇刊 II 69:2413–2417

Lin Q (2018) 技术分析与股票收益可预测性：一种协调一致的方法. 金融市场杂志 38:103–123

Liu Q, Tao Z, Tse Y, Wang C (2022) 基于深度学习的股票市场预测：以中国为例。金融研究快报
46:102209

吕鹏，吴强，徐杰，舒勇（2022)基于时间序列分解和混合模型的股票指数预测. 熵
24:146

Malkiel BG (1989) 有效市场假说。载于：金融学。Springer出版社，第127-134页。

Nabi RM、Ab S、Saeed M、Harron HB、Fujita H (2019) 股票市场价格走势的最终预测。计算机科学杂志
15(12):1795–1808

Nayak RK、Tripathy R、Mishra D、Burugari VK、Selvaraj P、Sethy A、Jena B (2021) 基于印度股市预测的印度股市预测
粗糙集和支持向量机方法。载于：智能与云计算、智能创新、系统与技术，第153卷。

Nazario RTF、Silva JL、Sobreiro VA、Kimura H (2017) 股票市场技术分析文献综述。《经济季刊》
金融 66:115–126

Nti K、Adekoya AF、Weyori BA (2020) 使用集成支持向量机进行高效的股票市场预测。开放获取
计算机科学 10(1):153–163

Patel J、Shah S、Thakkar P、Kotecha K (2015) 使用趋势确定性预测股票和股票价格指数的变动
数据准备和机器学习技术。专家系统应用 42:259–268

Pedregosa F、Varoquaux G、Gramfort A、Michel V、Thirion B (2011) Scikit-learn：Python 中的机器学习。机器学习杂志
Res 12:2825–2830

Machine Translated by Google

Picasso A、Merello S、Ma Y、Oneto L、Cambria E (2019) 市场趋势的技术分析和情感嵌入
预测。专家系统应用 135:60–70
Rana M、Uddin MM、Hoque MM (2019) 激活函数和优化器对股票价格预测的影响
LSTM循环神经网络。载于 :CSAI ,北京 ,中国 ,2019 ,第354-358页。
Ruxanda G, Badea LM (2014) 配置人工神经网络进行股票市场预测。技术经济发展经济学
20:116–132
Shah D、Isah H、Zulkernine F (2019) 股票市场分析 :预测技术的回顾与分类。国际金融杂志
7:26
Siddique M, Panda D (2019) 基于主成分分析的塔塔汽车股票指数预测混合预测模型
成分分析、支持向量回归和粒子群优化。IJ Eng Adv Tech 9:3032–3037
Singh J, Khushi M (2021) 股票价格预测的特征学习表明分析师评级起着重要作用。应用系统
创新 4:17
Srivinay、Manujakshi BC、Kabadi MG、Naik N (2022) 基于 PRE 和深度神经网络的混合股票价格预测模型
网络。数据 7、51
TensorFlow。https ://www.tensorflow.org/。
Xu Y, Kou G, Peng Y, Ding K, Ergu D, Alotaibi FS (2024) 参数不确定性下的利润和风险驱动型信用评分 :a
多目标方法。Omega 125:103004
雅虎财经。https ://finance.yahoo.com/。
Yuan X, Yuan J, Jiang T, Ain QU (2020) 基于特征选择和机器学习算法的中国股票市场长期选股模型. IEEE Access 8:22672–22685

出版商说明

Springer Nature 对已出版地图中的管辖权主张和机构隶属关系保持中立。